МІНІСТЕРСТВО ОСВІТИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ

імені Ігоря Сікорського»
НАВЧАЛЬНО-НАУКОВИЙ КОМПЛЕКС
«ІНСТИТУТ ПРИКЛАДНОГО СИСТЕМНОГО АНАЛІЗУ»

Кафедра Системного проектування

Лабораторна робота №3

з дисципліни “Інтелектуальний аналіз даних”

на тему: “Ознайомитися та отримати навички кластеризації даних за допомогою Data Mining GUI бібліотеки Weka ”

Виконав:
Студенд 2-го курсу
Групи ДА-11
Сидько Нікіта Сергійович
Варіант 22

Київ – 2023

Мета: Ознайомитися та отримати навички кластеризації даних за допомогою Data Mining GUI бібліотеки Weka

Завдання: Виконати кластеризацію тестових даних за допомогою методу кластеризації.

Хід роботи

1)Підготовка даних

Завантажимо дані про автомобілі з сайту :
http://archive.ics.uci.edu/ml/datasets/Car+Evaluation

Attribute Information:

Class Values:

unacc, acc, good, vgood

Attributes:

buying: vhigh, high, med, low.
maint: vhigh, high, med, low.
doors: 2, 3, 4, 5more.
persons: 2, 4, more.
lug_boot: small, med, big.
safety: low, med, high.

Рис.1 Атрибути

```
@relation cars-weka.filters.unsupervised.instance.Resample-S0-Z30.0-no-replacement-V

@attribute buying {vhigh,high,med,low}
@attribute maint {vhigh,high,med,low}
@attribute doors {2,3,4,5more}
@attribute persons {2,4,more}
@attribute lugboot {small,med,big}
@attribute safety {low,med,high}
@attribute class {unacc,acc,good,vgood}
```

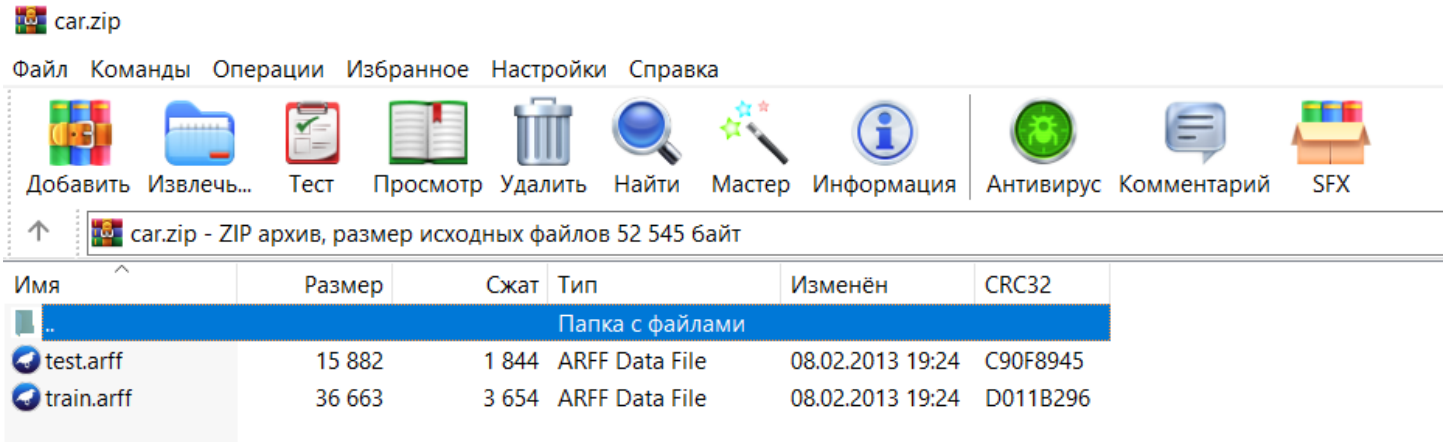


Рис.2 Завантажені дані

Маємо 2 завантажені файли, а саме test та train. Перший файл містить 1/3 даних (test – для тестування моделі), другий файл 2/3 даних (train – для побудування моделі)

2) Завантаження даних у Weka

Натиснувши **Weka** -> **Explorer** відкривається вікно зображене на рис.3

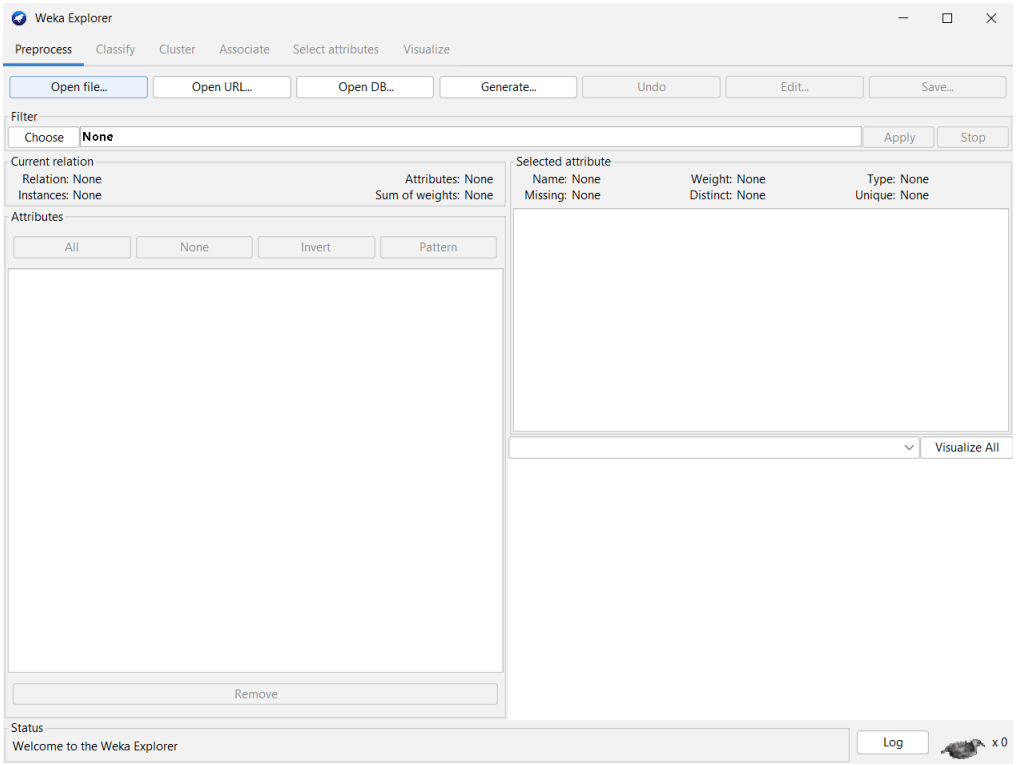


Рис.3

Натиснувши **Open file** обираємо файл train, тоді відкриється вікно зображене на рис.4

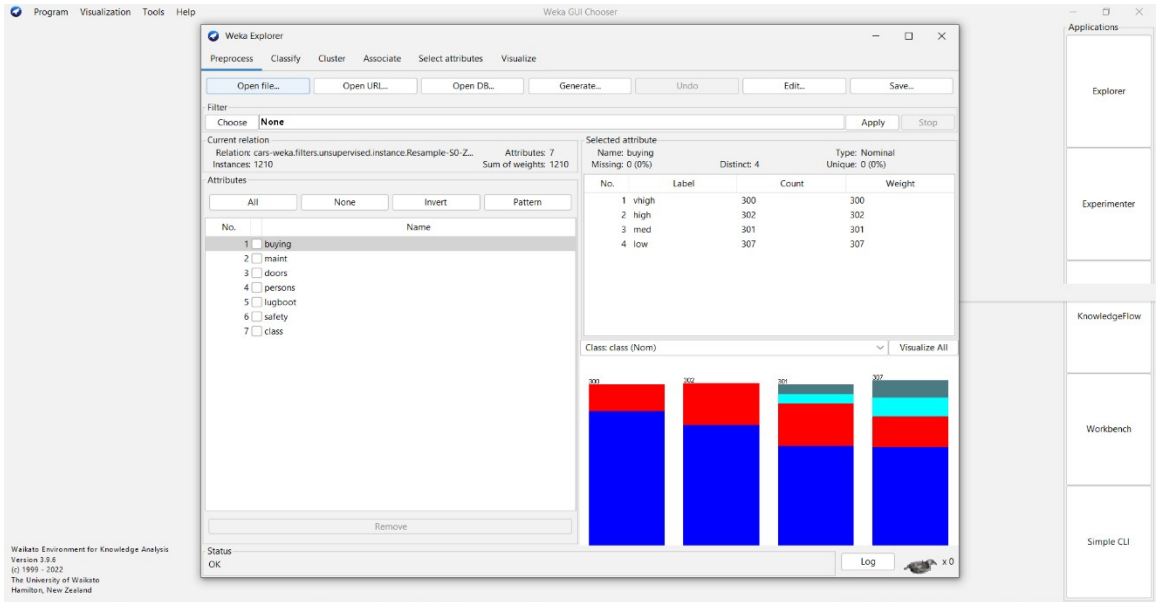


Рис.4

3) Модель кластеризації

1.У відкритому вікні (рис.4) відкриваємо вкладку **Cluster**

2. Вибираємо метод кластеризації за варіантом (в моєму випадку **FarthestFirs**)

3. Вибираємо значення **numClusters** (по дефолту 2)

4. **Cluster mode** має бути **Use training set**

5. Натискаємо старт

На рисунку 5, зображено по пунктах, що і за чим потрібно робити.

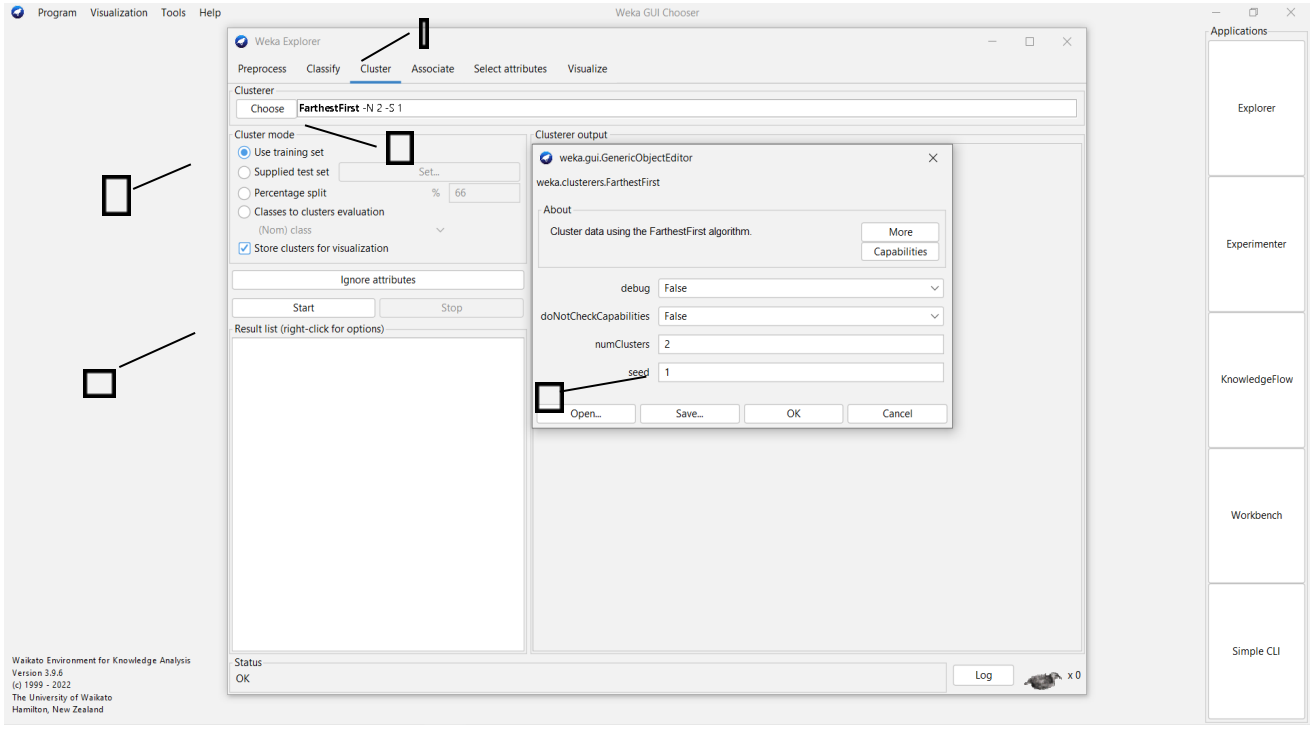


Рис.5

Після натискання **Start** маємо :

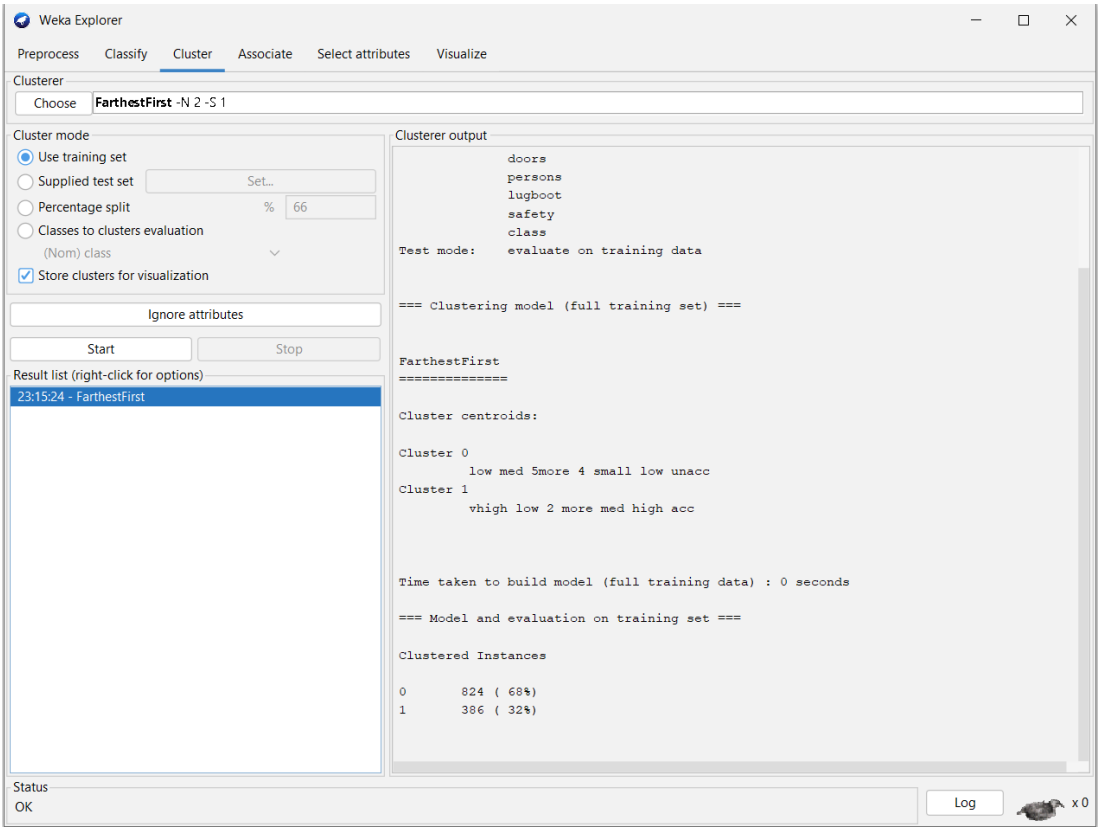


Рис.6

Графічне зображення залежності атрибутів **buying** від **safety** зробимо натиснувши на **Resoult list -> Visualize cluster assignments**

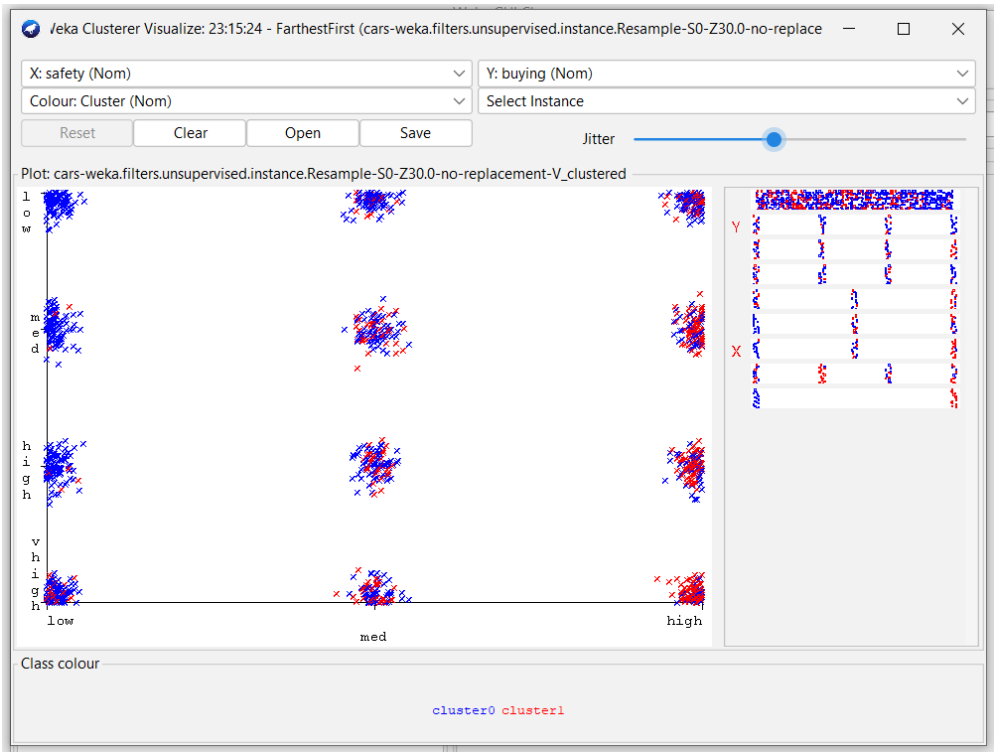


Рис.7

Для покращення видимості атрибутів можна налаштувати **Jilter**

Зробимо тестування моделі

Для цього в **Cluster mode** обираємо **Supplied test set** де ми вибираємо папку **car -> test**

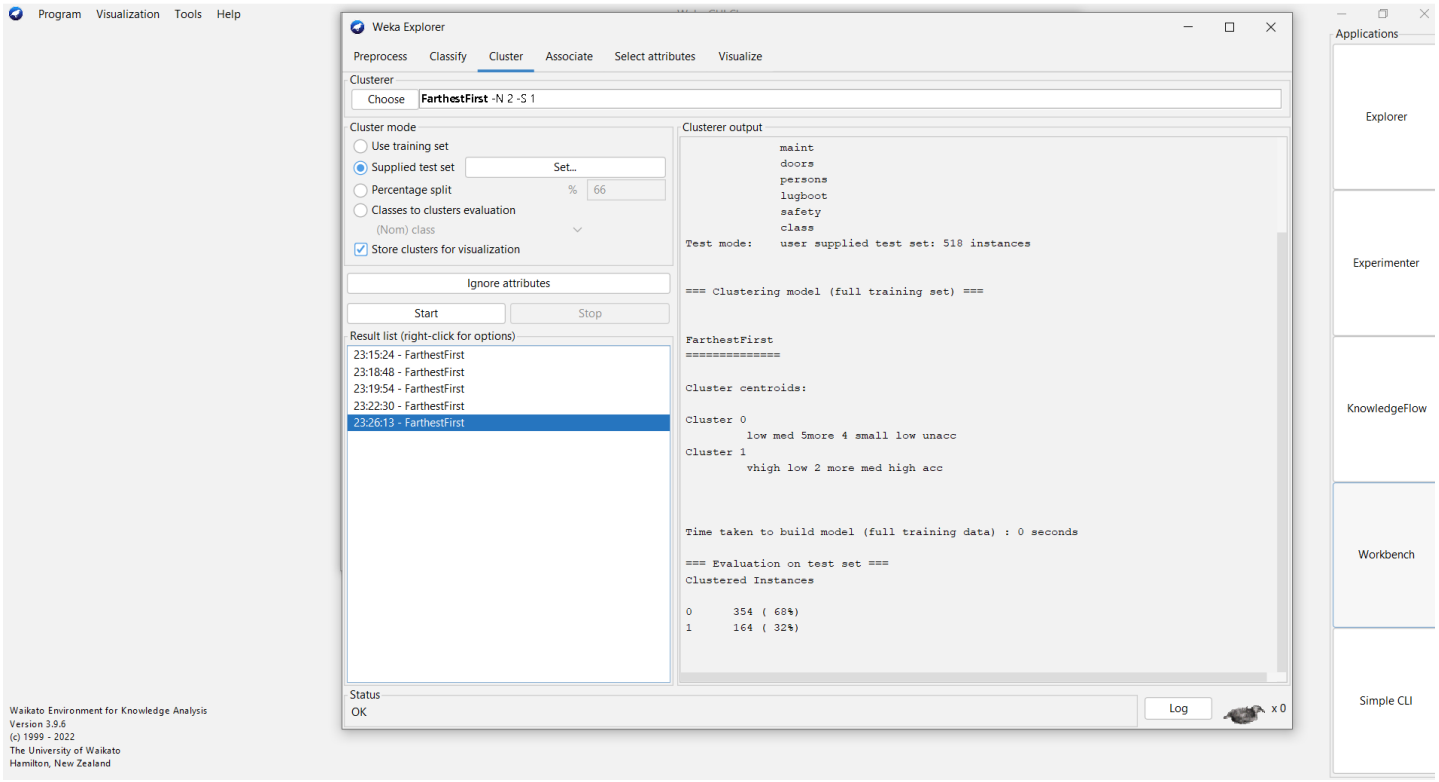


Рис.8

Графічне зображення буде мати вигляд :

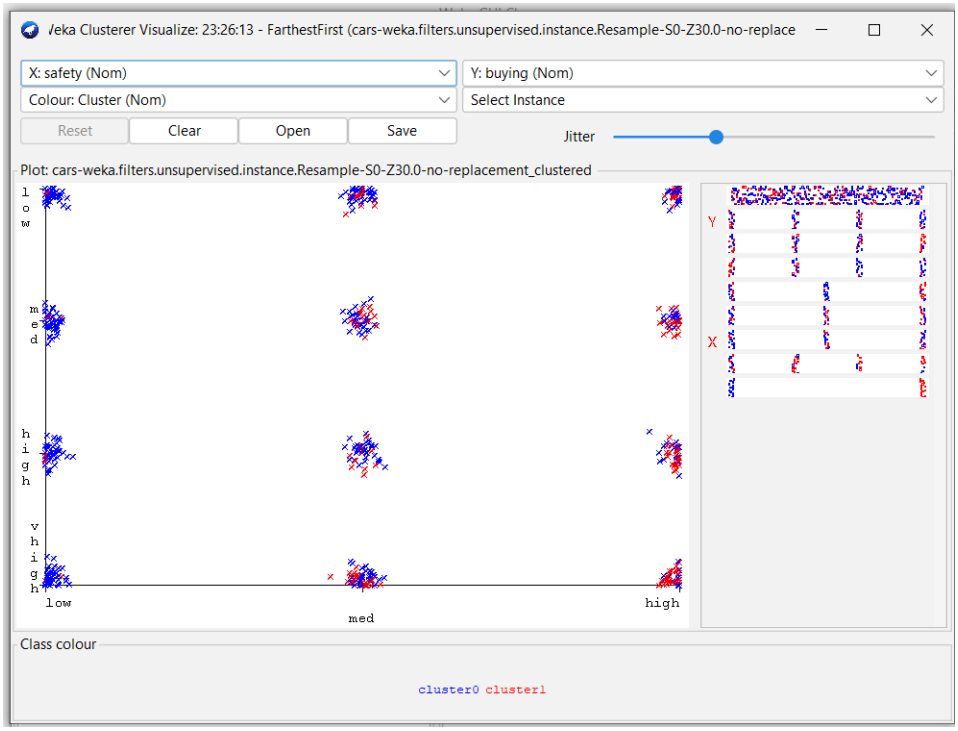


Рис.9

З рисунку видно, що кількість кластерів (2) є недостатньою, то збільшимо кількість до 3

Натиснувши на **FarthestFirst** відкриється вікно, де ми змінюємо **numClusters** з 2 на 3

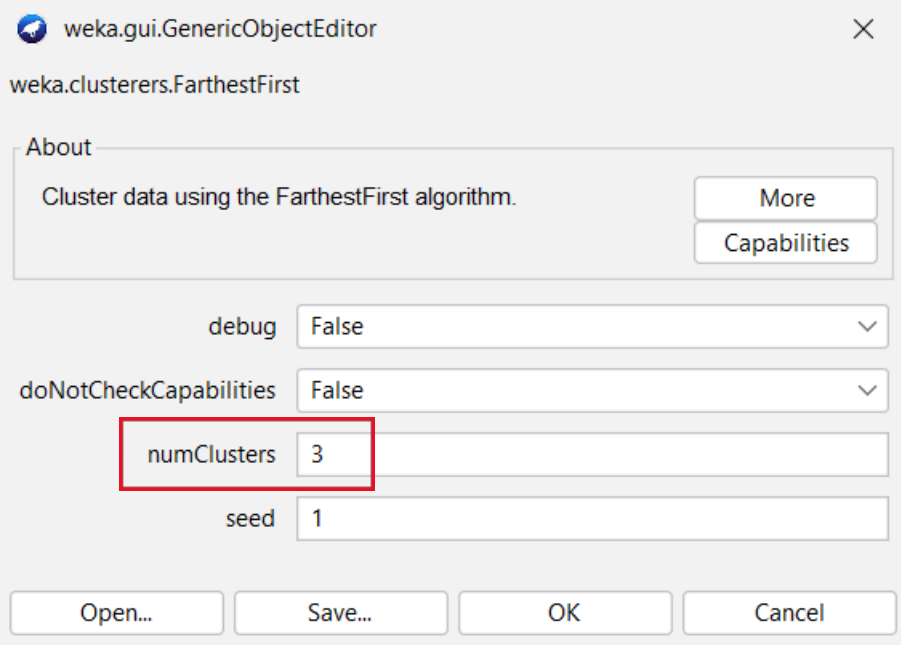


Рис.10

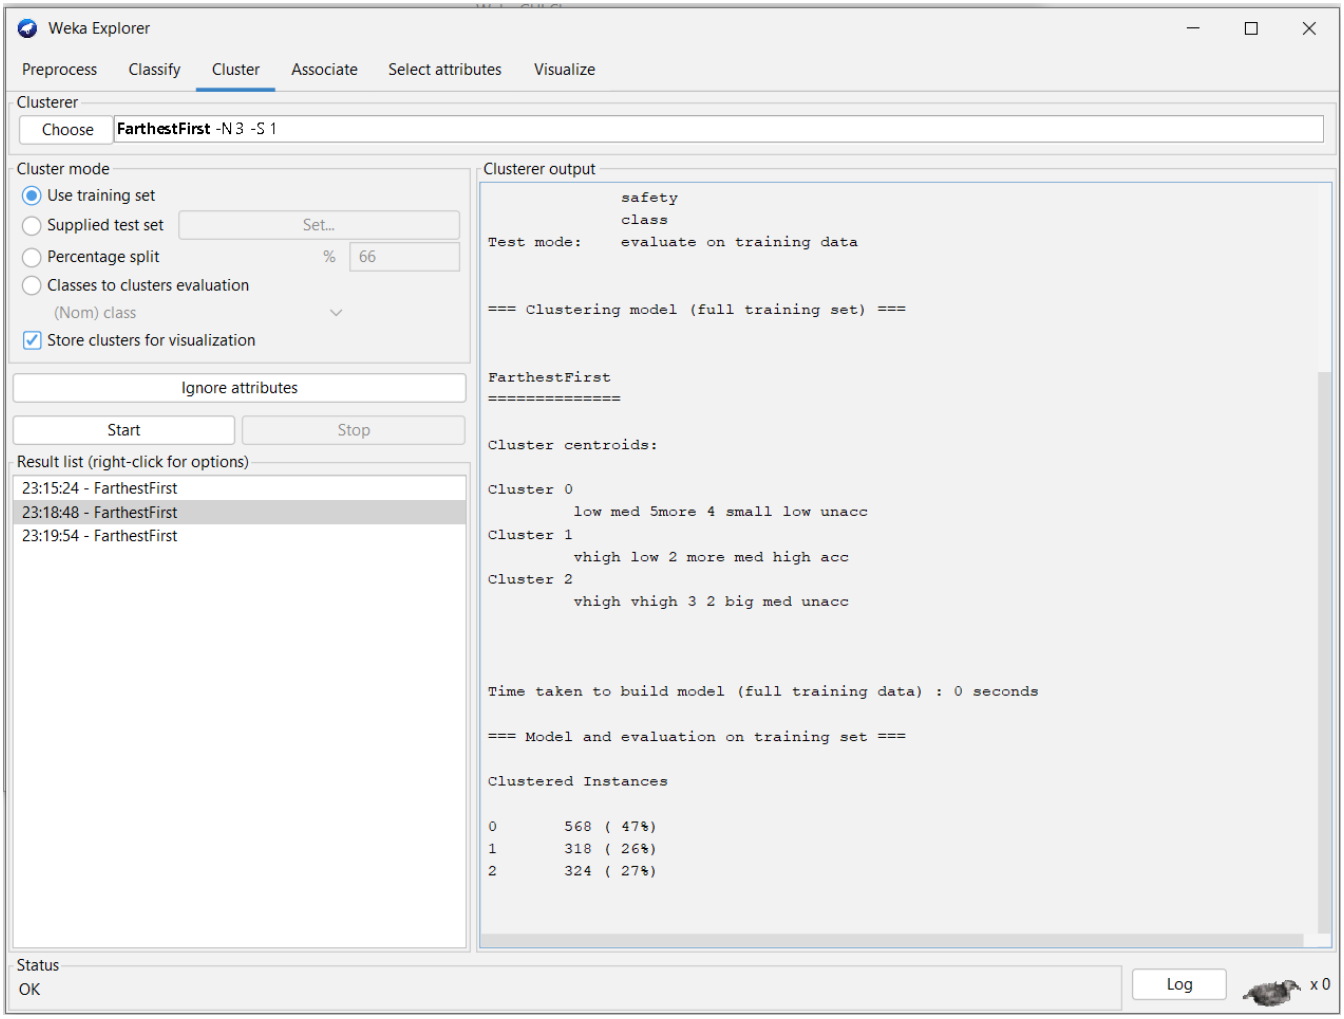


Рис.11

Графічне зображення буде мати вигляд :



Рис.13

Знову робимо тестування моделі аналогічне до рис.8, тоді маємо:

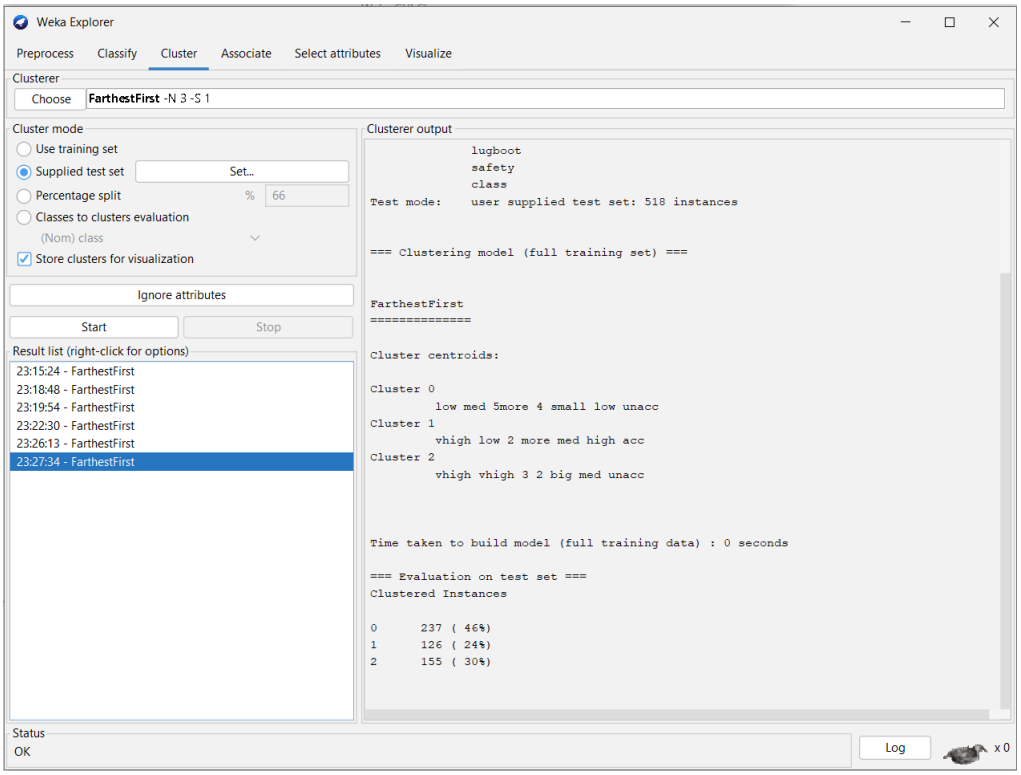


Рис.14

Графічне зображення при numClusters рівним 3 :

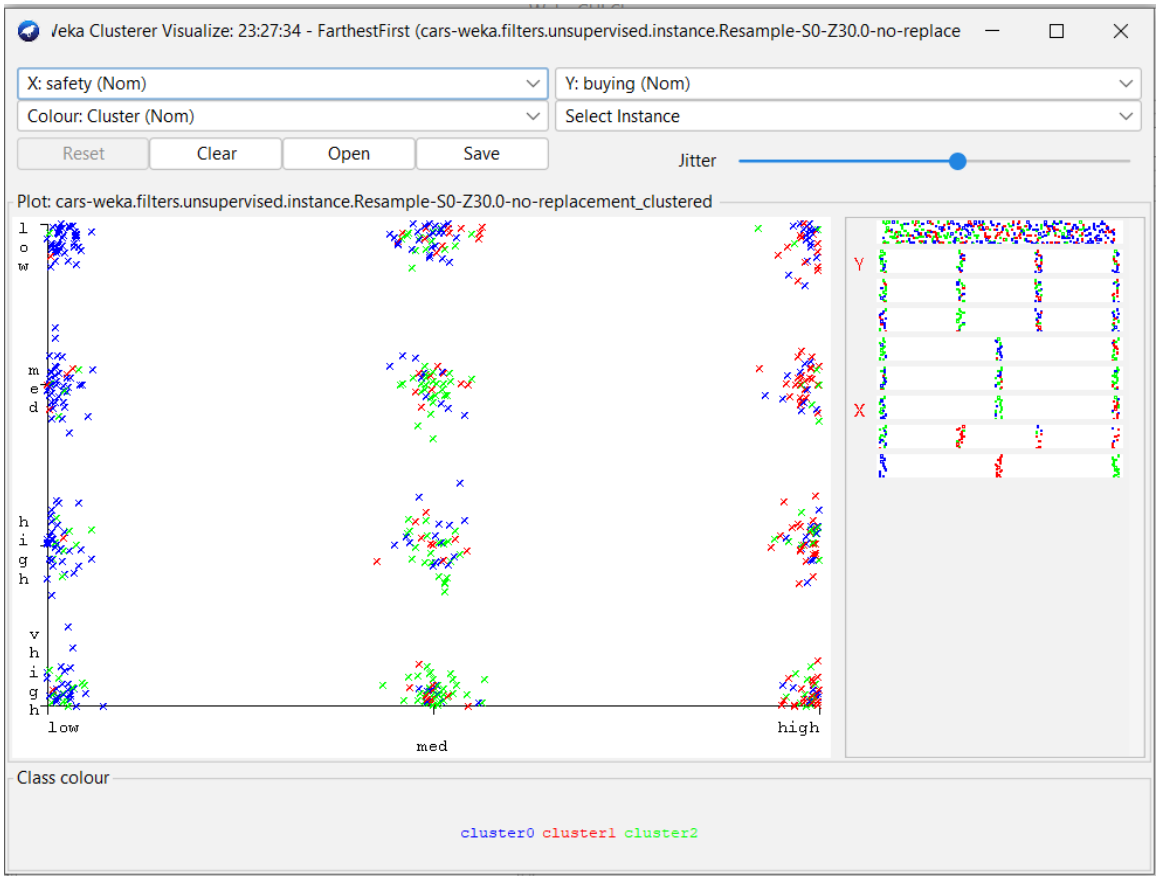


Рис.15

Висновок

У ході лабораторної роботи №3 було досліджено набір даних **car** та здійснено кластеризацію у **Weka** за допомогою методу **FarthestFirst** також було проведено тестування моделі. Протестувавши моделі та зробивши графічне зображення, з рисунків 9 (2 кластери) та 15 (3 кластери) можна зробити висновок що використання трьох кластерів є більш вдалим адже видно більш менш чітке розподілення ніж при двох кластерах. При подальшому збільшенні кластерів рисунки будуть накладатися один на одного і в цьому немає сенсу.