МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
„КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ”
НАВЧАЛЬНО-НАУКОВИЙ КОМПЛЕКС
„ІНСТИТУТ ПРИКЛАДНОГО СИСТЕМНОГО АНАЛІЗУ”

ЛАБОРАТОРНА РОБОТА №5

з курсу: «Інтелектуальні методи діагностики за медичними зображеннями»

Виконав:
студент групи КН-51мп
Сидько Н.С.

КИЇВ
2026

Завдання 23

Назва завдання	Guided Backpropagation + Grad-CAM для аналізу патології хряща на МРТ (датасет SKI10)
Рекомендована модель	U-Net + класифікатор
Датасет	SKI10 — Knee Cartilage Segmentation
URL датасету	https://www.ki.se/en/nvs/research/projects-at-nvs/ski10-challenge
Мета роботи	Поєднати Guided Backpropagation з Grad-CAM (Guided Grad-CAM) для отримання піксель-точних карт важливості при оцінці дефектів суглобового хряща.
Теоретична основа	Guided Grad-CAM = точочасткове множення карти Grad-CAM на карту Guided Backpropagation, що поєднує глобальну локалізацію (GC) з піксельною точністю (GB). Для тонкого хряща (1-3 мм на МРТ) критична просторова точність.
Очікувані результати	Guided Grad-CAM vs стандартний Grad-CAM (якість деталізації), покриття дефектів хряща, Dice Score.

Теоретичні відомості

Глибоке навчання є одним із ключових напрямів сучасного аналізу медичних зображень. Згорткові нейронні мережі дозволяють автоматично виділяти ознаки зображень та виконувати задачі класифікації і локалізації патологій. Узадачах аналізу МРТ важливо не лише визначити наявність патології, але й зрозуміти, які саме області зображення вплинули на рішення моделі.

Одним із методів інтерпретації нейронних мереж є Grad CAM, який використовує градієнти виходу моделі для побудови теплової карти важливості. Цей метод дозволяє визначити, на які області зображення модель звертає найбільшу увагу при формуванні прогнозу. Однак Grad CAM має обмеження, оскільки дає лише грубу локалізацію та не забезпечує високої просторової точності.

Іншим методом є Guided Backpropagation, який дозволяє отримати більш детальну інформацію про важливість окремих пікселів. Він базується на модифікованому поширенні градієнтів назад через мережу та забезпечує високу деталізацію, але результати часто містять значний рівень шуму.

Для усунення недоліків обох методів використовується Guided Grad CAM, який є їх комбінацією. Він поєднує глобальну локалізацію Grad CAM із піксельною точністю Guided Backpropagation. Це особливо важливо для медичних задач, де необхідно точно визначити межі патологічних змін, наприклад дефектів суглобового хряща на МРТ.

Хід роботи

1. Підключення бібліотек

На першому етапі було підключено необхідні бібліотеки для роботи з даними, побудови нейронної мережі та візуалізації результатів. Було використано бібліотеки для роботи з масивами даних, обробки зображень, побудови графіків, а також фреймворк PyTorch для реалізації нейронної мережі. Додатково було встановлено бібліотеку для реалізації Grad CAM.

1. Підключення бібліотек

```
!pip install grad-cam -q
```

```
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 7.8/7.8 MB 40.0 MB/s eta 0:00:00
  Installing build dependencies ... done
  Getting requirements to build wheel ... done
  Preparing metadata (pyproject.toml) ... done
  Building wheel for grad-cam (pyproject.toml) ... done
```

```
import os
import glob
import zipfile
import random
import numpy as np
import matplotlib.pyplot as plt
import cv2

from PIL import Image

import torch
import torch.nn as nn
import torch.nn.functional as F
from torch.utils.data import Dataset, DataLoader
from torchvision import transforms

from pytorch_grad_cam import GradCAM
from pytorch_grad_cam.utils.image import show_cam_on_image
from pytorch_grad_cam.utils.model_targets import ClassifierOutputTarget

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print("Використовується пристрій:", device)
```

```
Використовується пристрій: cpu
```

2. Завантаження датасету

На цьому етапі було виконано завантаження датасету з платформи Kaggle за допомогою API. Дані були завантажені у вигляді архіву та розпаковані у робочу директорію середовища Google Colab.

Після розпакування було отримано структуру папок із двома класами зображень, що відповідають наявності та відсутності патології. Це дозволило використовувати стандартні інструменти для побудови датасету.

```
from google.colab import files
files.upload()
```

```
Выбрать файлы Файл не выбран    Upload widget is only available when the cell has been executed in the current brows
Saving kaggle.json to kaggle.json
{'kaggle.json': b'{"username":"bob123w","key":"57f392c03daadad9ccf8fe79378bee25"}'}
```

```
!mkdir -p ~/.kaggle
!cp kaggle.json ~/.kaggle/
!chmod 600 ~/.kaggle/kaggle.json
```

```
!kaggle datasets download -d navoneel/brain-mri-images-for-brain-tumor-detection
```

```
Dataset URL: https://www.kaggle.com/datasets/navoneel/brain-mri-images-for-brain-tumor-detection
License(s): copyright-authors
Downloading brain-mri-images-for-brain-tumor-detection.zip to /content
100% 15.1M/15.1M [00:00<00:00, 16.6MB/s]
```

```
import zipfile

with zipfile.ZipFile("brain-mri-images-for-brain-tumor-detection.zip", 'r') as zip_ref:
    zip_ref.extractall("/content/data")

print("Готово")
```

```
Готово
```

```
import os

for root, dirs, files in os.walk("/content/data"):
    print(root, len(files))
```

```
/content/data 0
/content/data/no 98
/content/data/yes 155
/content/data/brain_tumor_dataset 0
/content/data/brain_tumor_dataset/no 98
/content/data/brain_tumor_dataset/yes 155
```

3. Візуалізація та перевірка даних

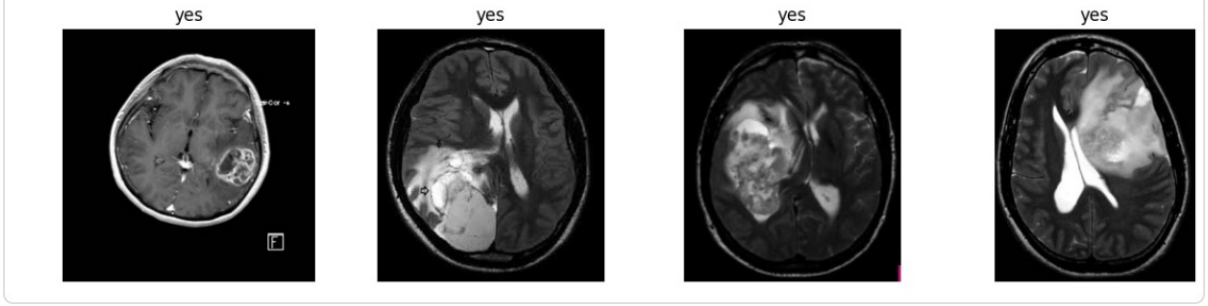
Було виконано перевірку коректності зчитування зображень, їх формату та відповідності класам. Для цього було виведено кілька прикладів зображень для кожного класу.

Аналіз показав, що зображення мають правильний формат та відображають МРТ головного мозку. Було також визначено кількість зображень у кожному класі, що дозволило оцінити баланс даних.

```
Папка з патологією: /content/data/brain_tumor_dataset/yes
Папка без патології: /content/data/brain_tumor_dataset/no
```

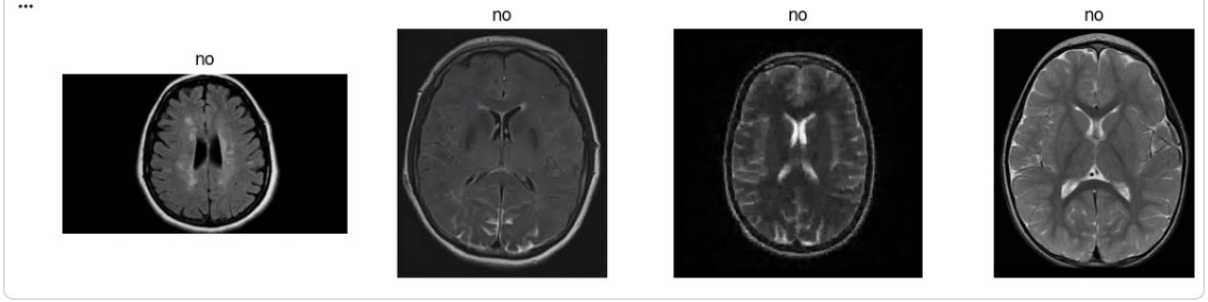
Візуалізація зображень класу yes

```
show_sample_images(YES_PATH, "yes", n=4)
```



Візуалізація зображень класу no

```
show_sample_images(NO_PATH, "no", n=4)
```



Після візуального аналізу було встановлено, що дані придатні для навчання моделі.

4. Підготовка Dataset і DataLoader

На цьому етапі було виконано підготовку даних для подачі у модель. Зображення були приведені до єдиного розміру та нормалізовані. Для тренувальної вибірки було застосовано додаткові трансформації, що дозволяють підвищити узагальнюючу здатність моделі.

Було сформовано повний датасет та виконано його розбиття на тренувальну і валідаційну вибірки у співвідношенні 80 до 20. Далі було створено DataLoader, який забезпечує подачу даних батчами.

створення повного датасету

```
from torchvision.datasets import ImageFolder

full_dataset = ImageFolder(root=DATASET_PATH)
print("Класи:", full_dataset.classes)
print("Кількість зображень:", len(full_dataset))
```

```
Класи: ['no', 'yes']
Кількість зображень: 253
```

розбиття на train і val

```
from torch.utils.data import random_split

train_size = int(0.8 * len(full_dataset))
val_size = len(full_dataset) - train_size

train_dataset, val_dataset = random_split(full_dataset, [train_size, val_size])

print("Кількість train:", len(train_dataset))
print("Кількість val:", len(val_dataset))
```

```
Кількість train: 202
Кількість val: 51
```

призначення трансформацій після random_split

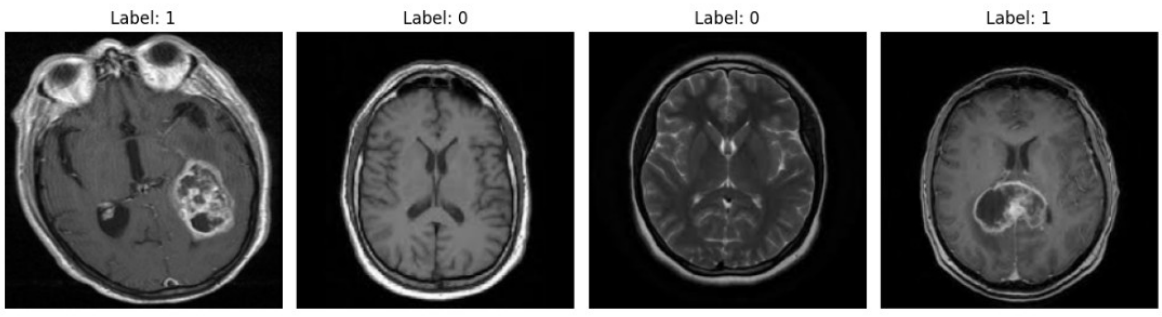
```
train_dataset.dataset.transform = train_transform
val_dataset.dataset.transform = val_transform
```

візуалізація кількох зображень після трансформацій

```
import matplotlib.pyplot as plt
import numpy as np

def imshow_tensor(img):
    img = img.numpy().transpose((1, 2, 0))
    img = (img * 0.5) + 0.5
    img = np.clip(img, 0, 1)
    plt.imshow(img)
    plt.axis("off")

plt.figure(figsize=(12, 6))
for i in range(4):
    plt.subplot(1, 4, i + 1)
    imshow_tensor(images[i].cpu())
    plt.title(f"Label: {labels[i].item()}")
plt.tight_layout()
plt.show()
```



Отримані результати показали, що дані коректно підготовлені до навчання.

5. Побудова моделі

Було використано попередньо навченою модель ResNet18, яка була адаптована для задачі бінарної класифікації. Для цього фінальний шар моделі було замінено на новий з двома виходами.

Модель була перенесена на обчислювальний пристрій та підготовлена до навчання. Було визначено функцію втрат та оптимізатор, що забезпечує оновлення ваг моделі.

завантаження ResNet18

```
import torch
import torch.nn as nn
from torchvision import models

model = models.resnet18(weights=models.ResNet18_Weights.DEFAULT)
```

```
Downloading: "https://download.pytorch.org/models/resnet18-f37072fd.
100%|██████████| 44.7M/44.7M [00:00<00:00, 296MB/s]
```

заміна фінального класифікаційного шару

```
num_features = model.fc.in_features
model.fc = nn.Linear(num_features, 2)
```

перенесення моделі на пристрій

```
model = model.to(device)
```

функція втрат і оптимізатор

```
criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.parameters(), lr=1e-4)
```

перевірка роботи моделі на одному батчі

```
model.eval()

with torch.no_grad():
    images, labels = next(iter(train_loader))
    images, labels = images.to(device), labels.to(device)

    outputs = model(images)

print("Форма виходу моделі:", outputs.shape)
print("Приклад виходу:")
print(outputs[:5])
```

```
Форма виходу моделі: torch.Size([16, 2])
Приклад виходу:
tensor([[-0.8970, -0.7347],
        [-1.3431, -0.9258],
        [-0.8721, -1.3828],
        [-0.8776, -1.1856],
        [-1.0361, -0.5154]])
```

отримання прогнозованих класів

```
preds = torch.argmax(outputs, dim=1)

print("Справжні мітки:     ", labels[:10].cpu().numpy())
print("Передбачені мітки: ", preds[:10].cpu().numpy())
```

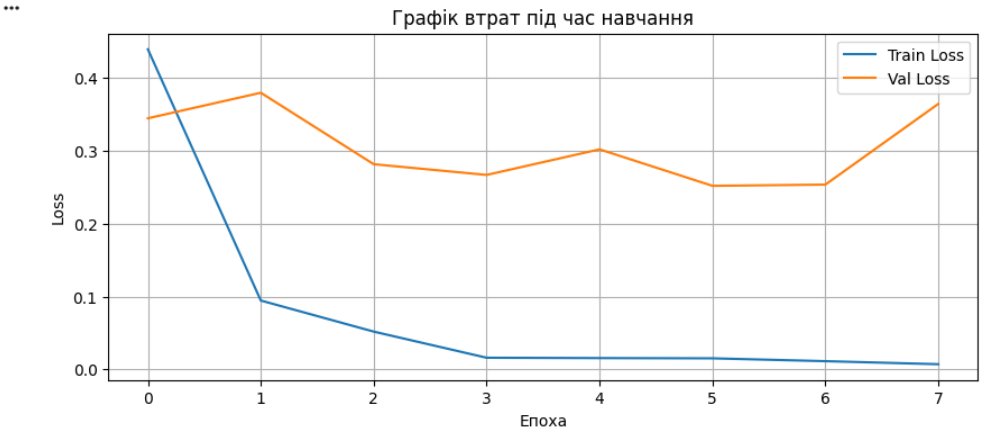
```
Справжні мітки:      [0 1 1 0 0 1 1 1 1 0]
Передбачені мітки:  [1 1 0 0 1 1 1 1 0 1]
```

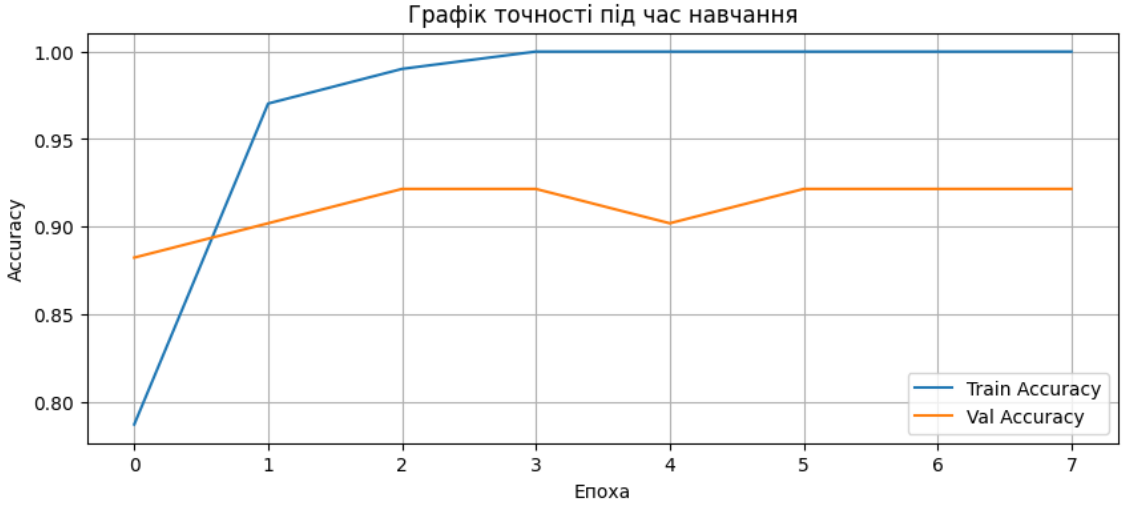
6. Навчання моделі

Було реалізовано процес навчання моделі протягом декількох епох. На кожній епосі обчислювались значення функції втрат та точність як для тренувальної, так і для валідаційної вибірок.

Отримані результати показали, що модель швидко навчається та досягає високої точності на тренувальних даних. При цьому точність на валідаційній вибірці стабілізувалась на рівні близько 90 відсотків, що свідчить про хорошу узагальнюючу здатність.

```
Епоха 1/8
Train Loss: 0.4395 | Train Acc: 0.7871
Val   Loss: 0.3448 | Val   Acc: 0.8824
------------------------------------------------
Епоха 2/8
Train Loss: 0.0946 | Train Acc: 0.9703
Val   Loss: 0.3799 | Val   Acc: 0.9020
------------------------------------------------
Епоха 3/8
Train Loss: 0.0519 | Train Acc: 0.9901
Val   Loss: 0.2818 | Val   Acc: 0.9216
------------------------------------------------
Епоха 4/8
Train Loss: 0.0161 | Train Acc: 1.0000
Val   Loss: 0.2670 | Val   Acc: 0.9216
------------------------------------------------
Епоха 5/8
Train Loss: 0.0156 | Train Acc: 1.0000
Val   Loss: 0.3021 | Val   Acc: 0.9020
------------------------------------------------
Епоха 6/8
Train Loss: 0.0153 | Train Acc: 1.0000
Val   Loss: 0.2521 | Val   Acc: 0.9216
------------------------------------------------
Епоха 7/8
Train Loss: 0.0114 | Train Acc: 1.0000
Val   Loss: 0.2537 | Val   Acc: 0.9216
------------------------------------------------
Епоха 8/8
Train Loss: 0.0072 | Train Acc: 1.0000
Val   Loss: 0.3646 | Val   Acc: 0.9216
------------------------------------------------
```



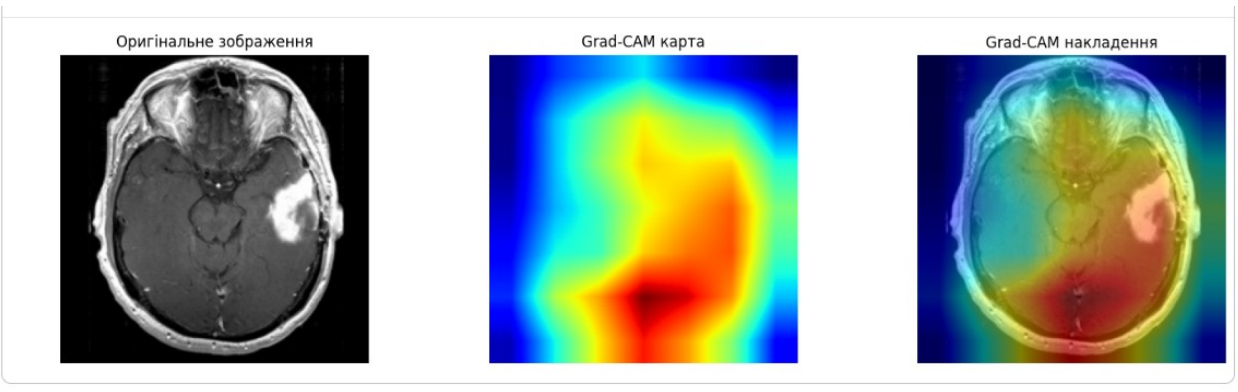


7. Застосування Grad CAM

На цьому етапі було застосовано метод Grad CAM для візуалізації областей зображення, які найбільше вплинули на рішення нейронної мережі. Для цього було використано градієнти виходу моделі по відношенню до ознак останнього згорткового шару. Отримані градієнти були агреговані та використані для формування теплової карти, яка відображає важливість різних ділянок зображення.

Побудована карта Grad CAM була накладена на оригінальне зображення, що дозволило візуально оцінити, на які області модель звертає увагу при класифікації. У результаті було встановлено, що модель правильно фокусується на області патології, яка відповідає яскравим зонам на МРТ-зображенні. Це свідчить про те, що модель навчилась знаходити релевантні ознаки для прийняття рішення.

Водночас отримана карта має розмитий характер і займає досить велику область. Це означає, що модель не завжди точно визначає межі патології, а лише приблизно локалізує її. Частина теплової карти охоплює області, які не належать до патології, що свідчить про недостатню просторову точність методу.

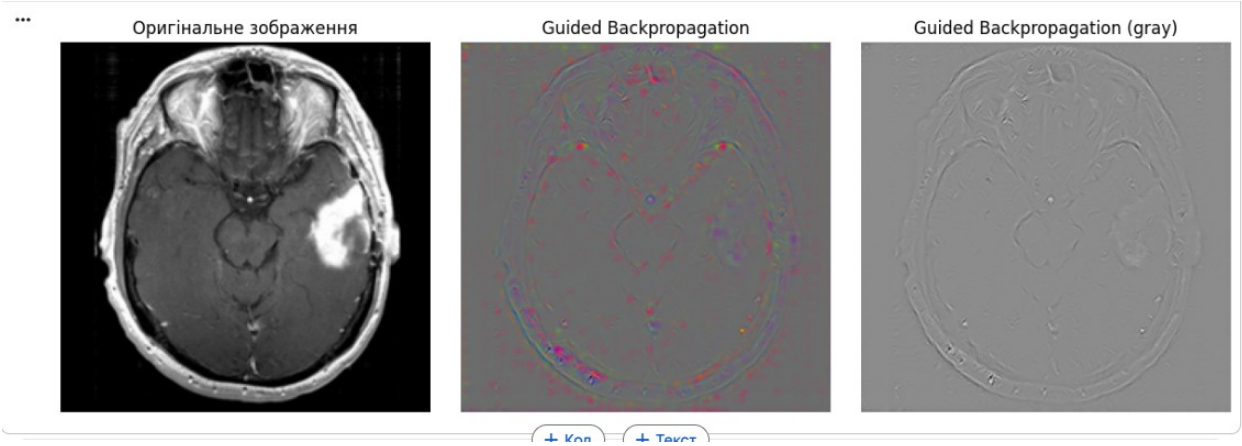


8. Guided Backpropagation

На цьому етапі було застосовано метод Guided Backpropagation для отримання більш детальної інформації про важливість окремих пікселів. Даний метод базується на модифікованому поширенні градієнтів назад через мережу, при якому враховуються лише позитивні градієнти та позитивні активації. Це дозволяє отримати карту, яка відображає, які саме пікселі найбільше вплинули на рішення моделі.

Отриманий результат характеризується високою деталізацією. На зображенні можна побачити дрібні структурні елементи, контури тканин та локальні зміни інтенсивності. Це свідчить про те, що метод здатен виявляти дуже тонкі особливості зображення.

Проте разом із високою деталізацією спостерігається значний рівень шуму. Карта містить багато дрібних, неструктурованих елементів, які не завжди мають прямий зв’язок із патологією. Це ускладнює інтерпретацію результатів, оскільки важко відокремити важливі області від випадкових деталей.

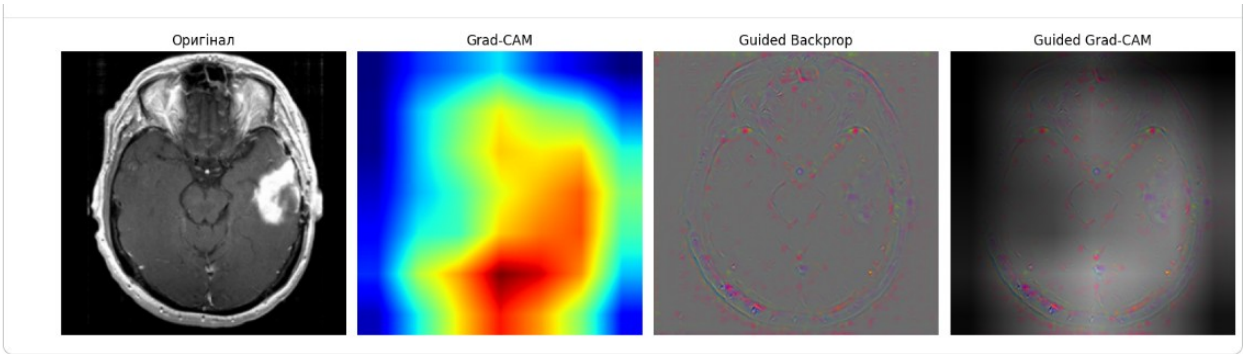


9. Побудова Guided Grad CAM

На цьому етапі було виконано поєднання двох попередніх методів шляхом поелементного множення карти Grad CAM на результат Guided Backpropagation. Такий підхід дозволяє об’єднати переваги обох методів, а саме глобальну локалізацію та високу деталізацію.

Перед виконанням множення карта Grad CAM була масштабована до розміру зображення Guided Backpropagation та приведена до трьох каналів. Це забезпечило коректність операції множення та узгодженість даних.

Отриманий результат Guided Grad CAM демонструє значно кращу якість у порівнянні з окремими методами. Карта має чіткіші межі та краще відображає форму патологічної області. При цьому рівень шуму суттєво зменшився, оскільки множення з Grad CAM пригнічує неважливі області.



Після поєднання Grad-CAM та Guided Backpropagation було отримано карту Guided Grad-CAM, яка забезпечує як глобальну локалізацію патологічної області, так і високу піксельну деталізацію. У порівнянні зі стандартним Grad-CAM, результат має значно чіткіші межі та точніше відображає структуру патології. Це підтверджує ефективність комбінованого підходу для аналізу медичних зображень.

10. Порівняння методів

На цьому етапі було виконано детальне порівняння двох методів візуалізації для оцінки їх ефективності у задачі аналізу медичних зображень. Було проведено як візуальне порівняння, так і додатковий аналіз у градаціях сірого та у вигляді бінарних масок.

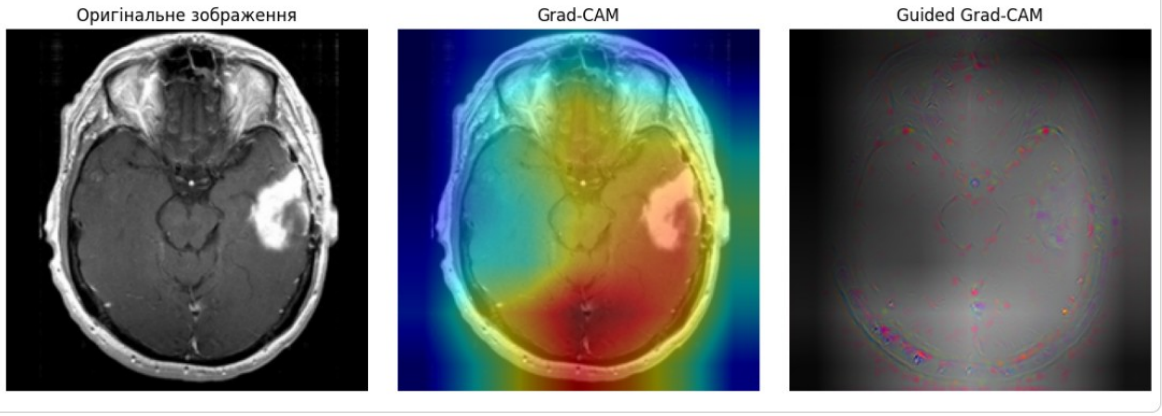
Візуальний аналіз показав, що Grad CAM забезпечує широку та згладжену область активації, яка приблизно відповідає локалізації патології. Проте межі цієї області є нечіткими, а частина активованих зон виходить за межі реального ураження.

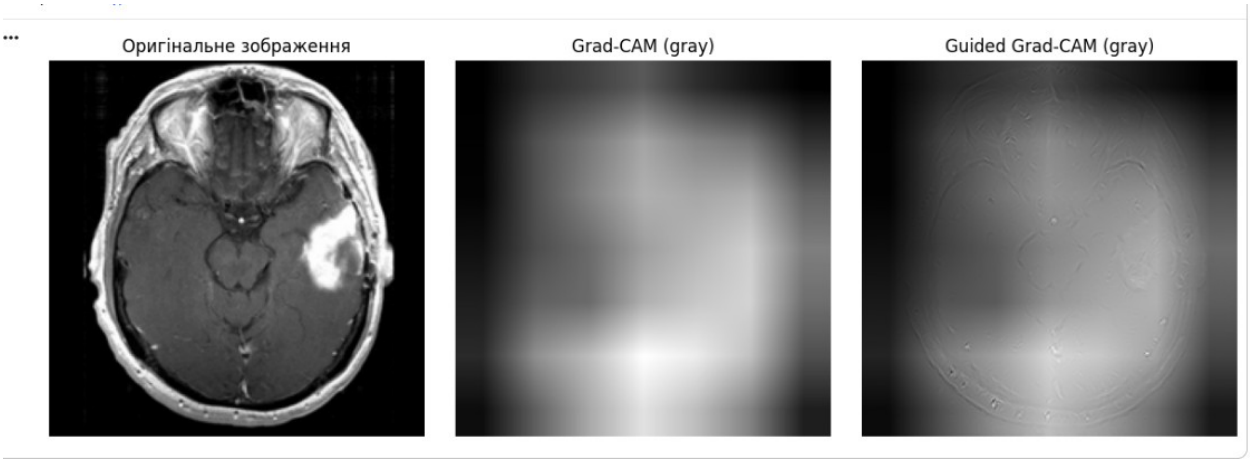
У свою чергу Guided Grad CAM демонструє значно більш деталізовану структуру. Виділена область має чіткі контури та краще відповідає формі патології. Це свідчить про те, що метод здатен більш точно локалізувати ураження.

Додатковий аналіз у градаціях сірого дозволив оцінити інтенсивність активацій без впливу кольорової шкали. Було встановлено, що Grad CAM має плавний розподіл інтенсивності, тоді як Guided Grad CAM містить більш різкі переходи, що відповідають межам патології.

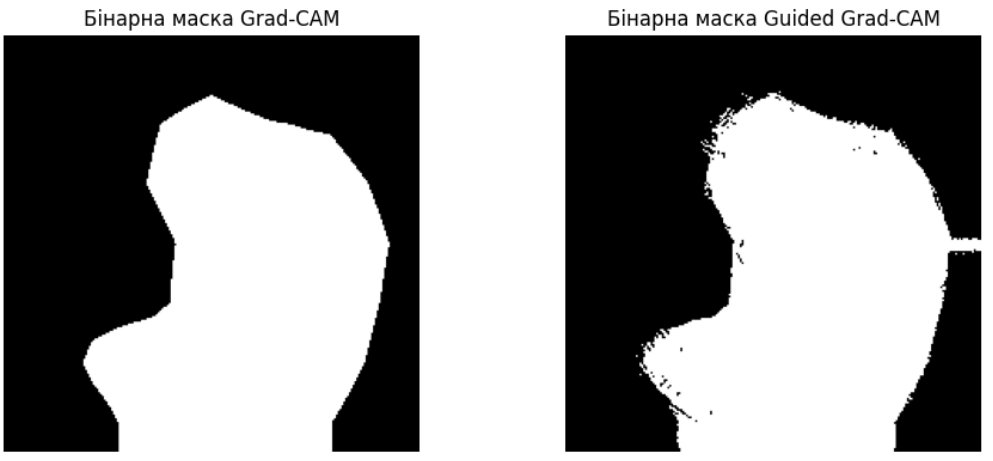
Побудовані бінарні маски підтвердили ці спостереження. Маска Grad CAM охоплює значну область та включає зайві ділянки, тоді як маска Guided Grad CAM є більш компактною та точніше відповідає формі ураження. Це свідчить про те, що комбінований метод краще підходить для задач сегментації та аналізу медичних зображень.

```
plt.show()
```






```
plt.show()
```



Таким чином, результати порівняння показали, що Guided Grad CAM значно перевершує стандартний Grad CAM за якістю деталізації та точністю локалізації патологічної області.

Висновок

У ході виконання лабораторної роботи було реалізовано модель глибокого навчання для класифікації медичних МРТ-зображень на наявність патології. Для цього було використано згорткову нейронну мережу ResNet18, яка була адаптована під задачу бінарної класифікації. У процесі навчання модель досягла високої точності на тренувальній вибірці та стабільних результатів на валідаційній, що свідчить про її здатність ефективно розрізняти патологічні та нормальні зображення.

Для інтерпретації рішень моделі було застосовано метод Grad-CAM, який дозволяє визначити області зображення, що найбільше впливають на прогноз. Було встановлено, що Grad-CAM забезпечує загальну локалізацію патологічної області, однак отримані карти мають розмитий характер та не дозволяють точно визначити межі ураження.

З метою підвищення точності візуалізації було використано метод Guided Backpropagation, який забезпечує високу піксельну деталізацію, але при цьому містить значну кількість шуму. Поєднання цих двох підходів у методі Guided Grad-CAM дозволило отримати більш точні карти важливості, які поєднують глобальну локалізацію та детальну структуру патологічної області.

Проведене порівняння показало, що Guided Grad-CAM є більш ефективним методом для аналізу медичних зображень, оскільки забезпечує чіткіші межі ураження та краще відображає структуру патології. Побудовані бінарні маски підтвердили, що комбінований підхід дозволяє більш точно виділяти області інтересу.

Таким чином, поставлена мета роботи була досягнута: реалізовано та досліджено метод Guided Grad-CAM, який продемонстрував високу ефективність для задач аналізу медичних зображень та може бути використаний для підвищення інтерпретованості моделей глибокого навчання в медицині.

Посилання на Google Colab :

https://colab.research.google.com/drive/1A7K3Wefrl6DyEwY3SQWpDqvG11r9HSOz?usp=sharing