НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»
Інститут прикладного системного аналізу
Кафедра системного проектування

Звіт

про виконання комп'ютерного практикуму №1
з дисципліни «Основи молекулярної біології та біоінформатики»

студент 3го курсу
групи ДА-11
Сидько Нікіта Сергійович

Київ-2024

Комп’ютерний практикум №1. Оцінка якості даних секвенування. Технологія покращення якості даних.

Мета: ознайомитись з особливостями оцінки якості даних секвенування.

Основні задачі роботи:
1)Вміти оцінювати якість отриманих даних та навчитись проводити очистку «reads» перед асемблюванням геномів.
2)Ознайомитись з особливостями запису інформації про біологічні послідовності . Формати FastQ, Fasta.

Порядок виконання роботи

1) Завантаження парних рідів, що отримані для патогеннго бактеріального організму Escherichia coli O104:H4.

2) Завантаження на комп’ютер програми FastQC. Аналіз файлів.

3) Завантаження на комп’ютер програми Trimmomatic. Покращення якості рідів за допомогою програми

1) Завантаження парних рідів

Escherichia coli O104:H4 є патогенним штамом бактерії Escherichia coli, що відомий своєю здатністю викликати серйозні захворювання у людини.

E. coli O104:H4 відрізняється від інших штамів E. coli своїми антигенними характеристиками та особливостями вірулентності. Цей штам належить до ентероагрегативних E. coli (EAEC), що зазвичай викликають тривалі діарейні захворювання, і різко відрізняється тим, що має фактори вірулентності шига-токсинопродукуючих E. coli (STEC).

Для виконання роботи спочатку завантажимо файли, зображені на рис.1

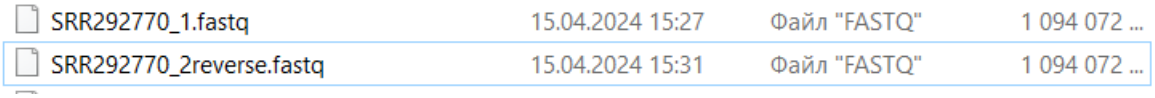


Рис.1 Завантаження рідів

За допомогою команди ***find /c /v “”*** переглянемо дані файлів прямих та зворотніх рідів.

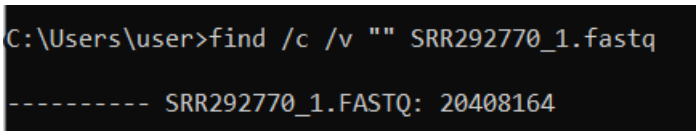


Рис.2 Кількість рядків файлу

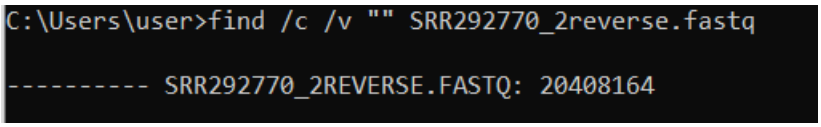


Рис.3 Кількість рядків файлу

Файли з розширенням .fastq є стандартним форматом для зберігання біологічних послідовностей, зокрема секвенційного вивчення нуклеотидів (ДНК, РНК), отриманих в результаті високопродуктивного секвенування. Цей формат дуже поширений у біоінформатиці, оскільки він дозволяє не тільки зберігати самі послідовності, але й відповідну інформацію про якість кожного нуклеотида.

Кожна послідовність у файлі .fastq описується чотирма рядками:

- Перший рядок: Завжди починається з символу '@', за яким слідує унікальний ідентифікатор послідовності. Цей ідентифікатор може містити додаткові деталі, такі як інформація про секвенатор, експеримент та інше
- Другий рядок: Містить саму нуклеотидну послідовність. Це лінійний рядок символів, де кожен символ представляє один з чотирьох нуклеотидів (A, T, C, G для ДНК або A, U, C, G для РНК).

- Третій рядок: Завжди починається зі знаку '+'. Цей рядок може бути пустим або може містити той самий ідентифікатор, що і перший рядок. Зазвичай, він лишається порожнім і служить як роздільник між нуклеотидною послідовністю та рядком оцінки якості.
- Четвертий рядок: Містить послідовність символів, що відповідають якості кожного нуклеотида, зазначеного в другому рядку. Якість кодується за шкалою Phred, де кожен символ (зазвичай ASCII символи) має числове значення, що вказує на ймовірність помилки при визначенні відповідного нуклеотида. Вищі значення вказують на вищу впевненість.

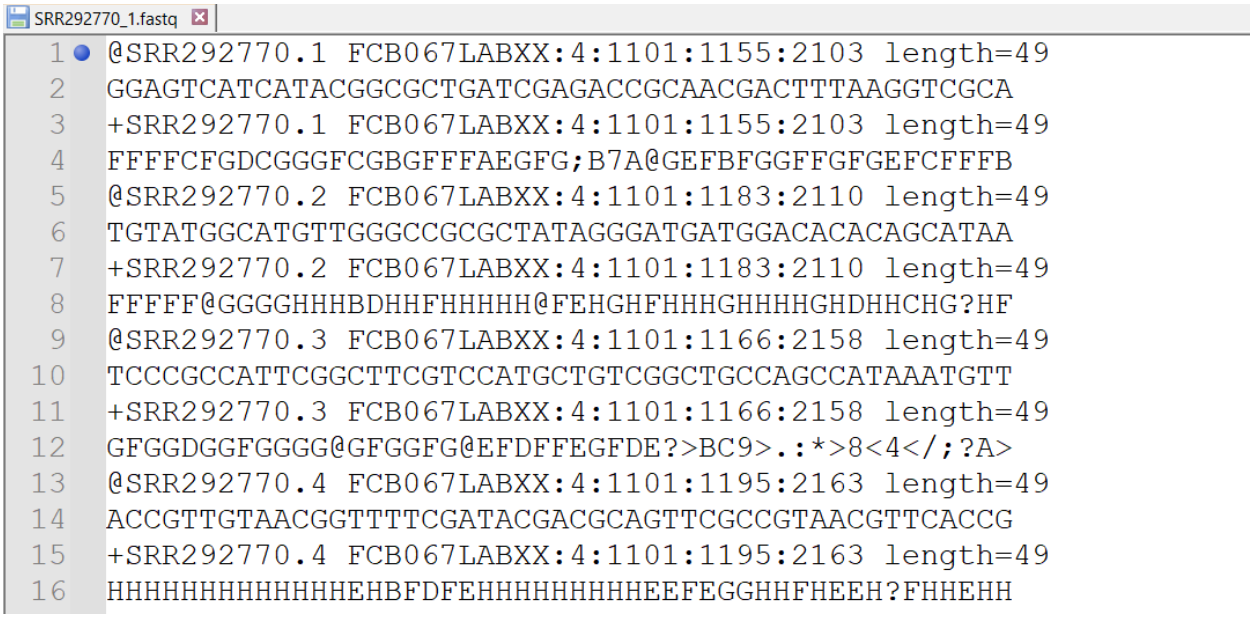


Рис.4 Файл SRR292770_1

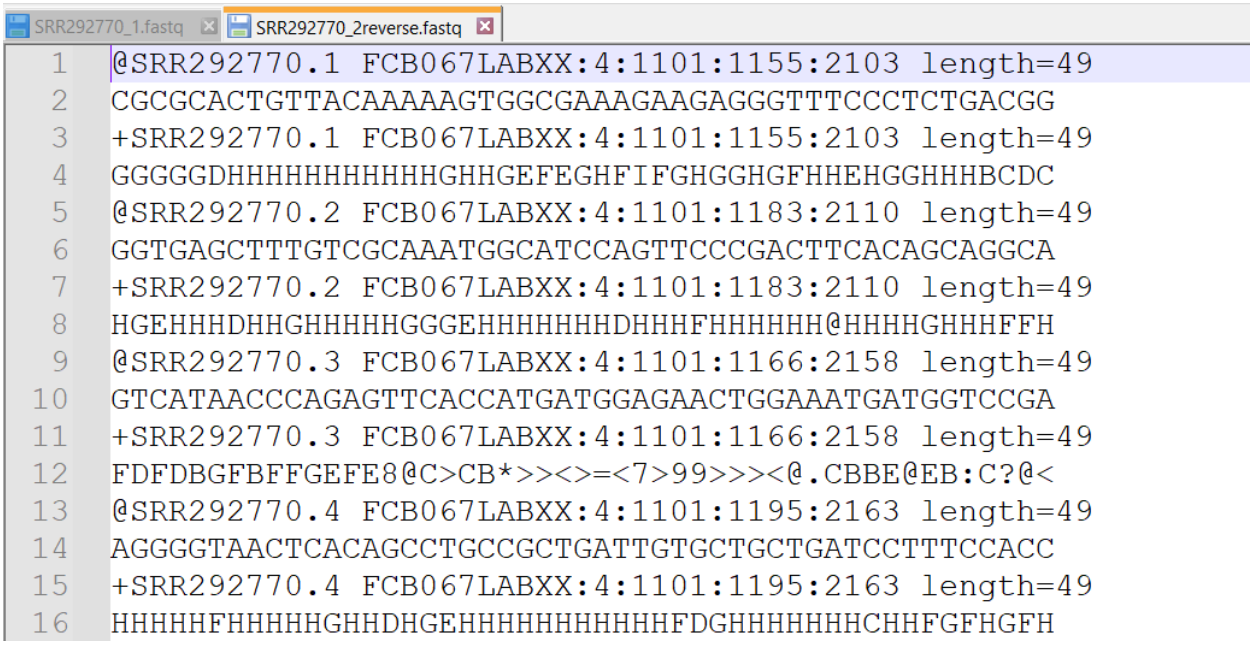


Рис.5 Файл SRR292770_2reverse

2)Завантаження на комп’ютер програми FastQC. Аналіз файлів.

Завантажимо FastQC, для подальшого виконання 2го пункту завдання.

FastQC

Function	A quality control tool for high throughput sequence data.
Language	Java
Requirements	A suitable Java Runtime Environment The Picard BAM/SAM Libraries (included in download)
Code Maturity	Stable. Mature code, but feedback is appreciated.
Code Released	Yes, under GPL v3 or later.
Initial Contact	Simon Andrews

Download Now

Рис.6 FastQC

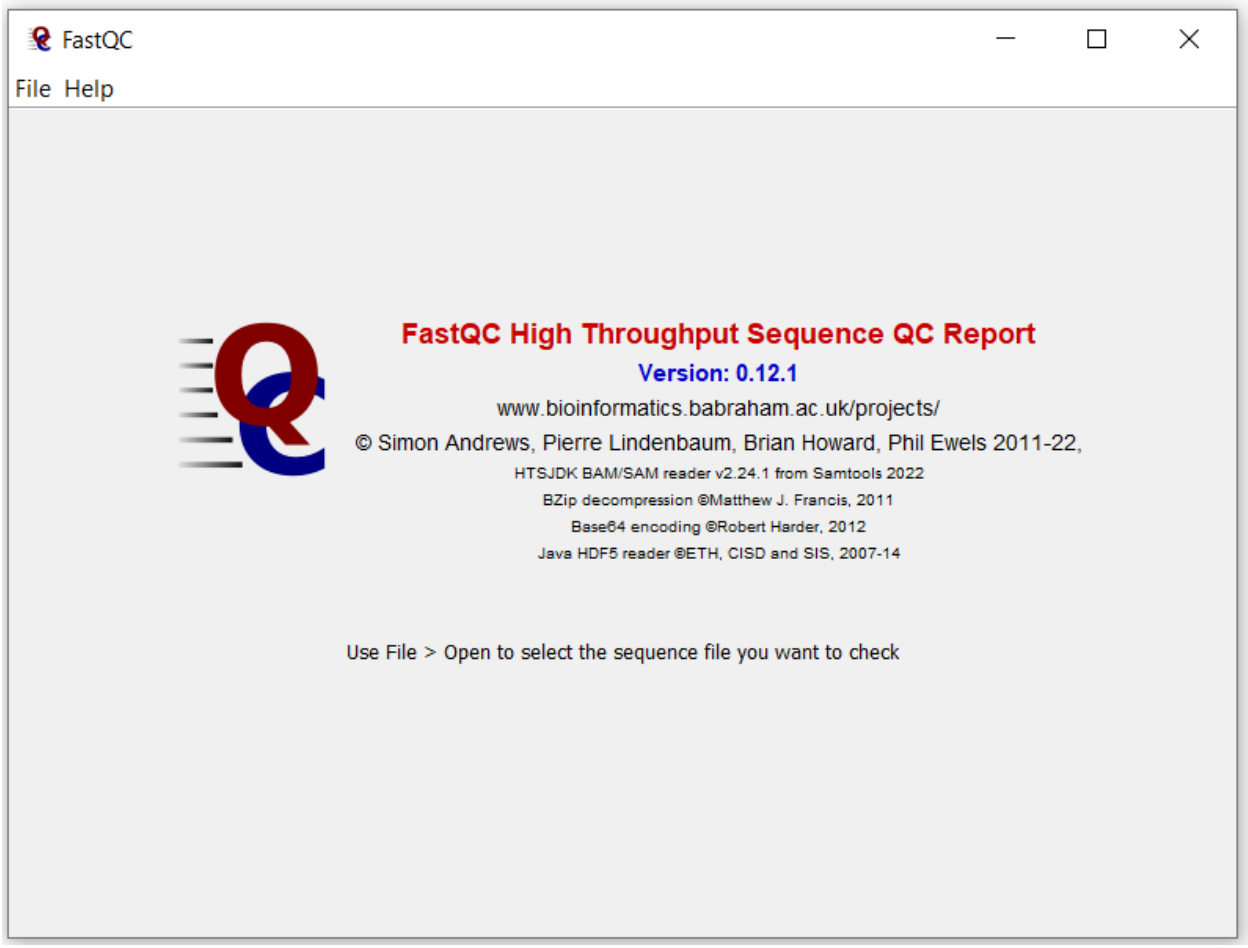


Рис.7 Програма

Зробимо аналіз файлів з рідами, для цього скористаємося нашою програмою.

Basic sequence stats	
Measure	Value
Filename	SRR292770_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	5102041
Total Bases	250 Mbp
Sequences flagged as poor quality	0
Sequence length	49
%GC	50

Рис.8 Базова статистика SRR292770_1

SRR292770_1.fastq відноситься до першої частини парних рідів.

Filename – ім’я файлу, яке вказує на конкретний набір даних секвенування, що аналізується.
File type – тип файлу, який підтверджує, що дані представлені у вигляді звичайних викликів нуклеотидних баз (Conventional base calls).
Encoding – це схема кодування, яка використовується для представленняякості послідовностей. **Sanger / Illumina 1.9** є стандартом кодування якості для файлів .fastq, який використовує ASCII символи для представлення значень якості нуклеотидів, починаючи з символу з ASCII кодом 33.
Total Sequences – це загальна кількість рідів, що містяться в файлі.У кожному файлі представлено 5102041 послідовностей. Це число вказує на кількість окремих рідів секвенування.
Total Bases – загальна кількість нуклеотидних баз у всіх послідовностях файлу, що в даному випадку складає 250 Mbp (мегабаз пар), що є сумарною довжиною всіх рідів.
Sequences flagged as poor quality – кількість послідовностей, позначених як низькоякісні. В обох файлах таких послідовностей немає (0), що свідчить про загально хорошу якість даних.
Sequence length – довжина послідовностей. У даному випадку всі ріди мають фіксовану довжину 49 нуклеотидів.
%GC – 50% Цей показник вказує на вміст гуаніну (G) та цитозину (C) в послідовностях, які складають файл рідів. Відсоток GC важливий, оскільки послідовності з високим вмістом GC зазвичай більш стабільні. Вміст GC може варіюватися для різних організмів, але середній вміст для багатьох бактерій складає близько 50%. У цьому випадку, 50% вмісту GC означає, що половина від загальної кількості нуклеотидів у даному файлі рідів складається з гуаніну та цитозину.

Basic sequence stats	
Measure	Value
Filename	SRR292770_2reverse.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	5102041
Total Bases	250 Mbp
Sequences flagged as poor quality	0
Sequence length	49
%GC	49

Рис.9 Базова статистика SRR292770_2reverse

Filename: **SRR292770_2reverse.fastq**
Ім'я файлу, яке вказує на зворотні ріди, отримані в ході секвенування.
File type: Conventional base calls. Тип файлу позначає, що дані містять звичайні виклики баз, або нуклеотидів, які зазвичай включають інформацію про нуклеотидну послідовність та її якість.
Encoding: Sanger / Illumina 1.9. Тип кодування якості секвенування. "Sanger / Illumina 1.9" означає, що якість секвенування використовує стандарт Sanger, який використовує ASCII символи, починаючи з символу '!' (33 в ASCII) для представлення якісних оцінок. Це найбільш поширене кодування якості.
Total Sequences: 51020413агальна кількість послідовностей у файлі. Кожна послідовність представлена чотирма рядками в форматі FASTQ.
Total Bases: 250 Mbp. Загальна кількість нуклеотидних баз у всіх послідовностях, виміряна в мегабазах пар (Mbp).
Sequences flagged as poor quality: 0 Кількість послідовностей, які були позначені як поганої якості. У цьому випадку немає послідовностей позначених як поганої якості.
Sequence length: 49. Стандартна довжина послідовностей (рідів) у файлі. Це означає, що кожна послідовність містить 49 нуклеотидів.
%GC: 49%. Відсоток гуаніну (G) та цитозину (C) від загальної кількості нуклеотидних баз у всіх послідовностях. Вміст GC є важливим індикатором, який може впливати на структуру ДНК та стійкість до різних умов, а також на ефективність секвенування та ампліфікації. У даному випадку він складає 49%, що є типовим для багатьох організмів.

Порівняння графіків файлів

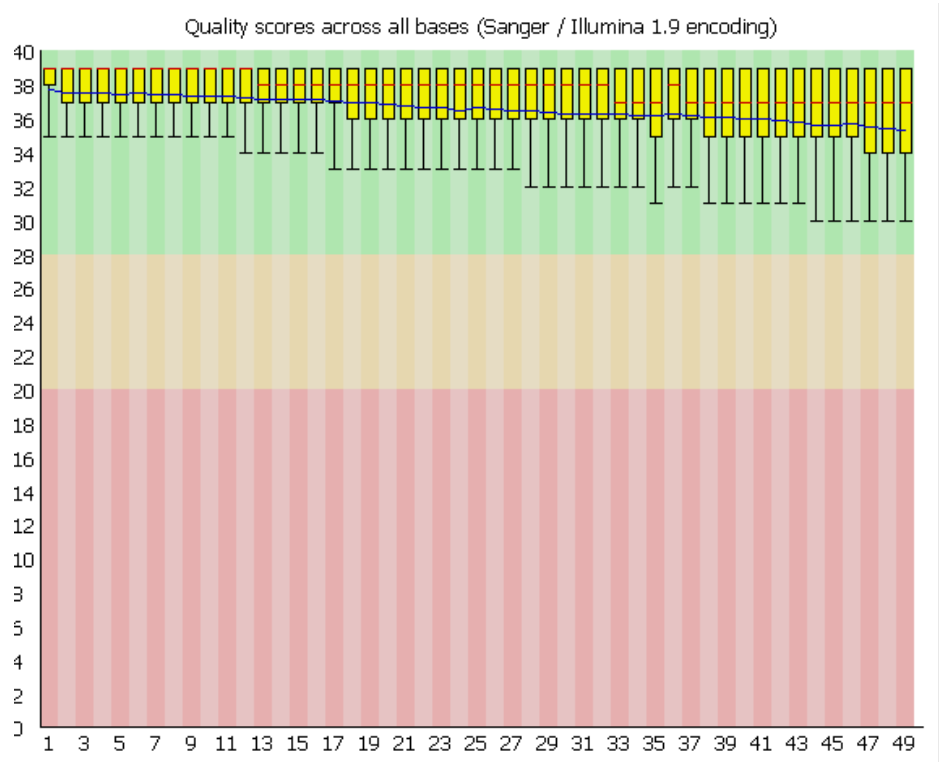


Рис.10 Якість послідовності SRR292770_1

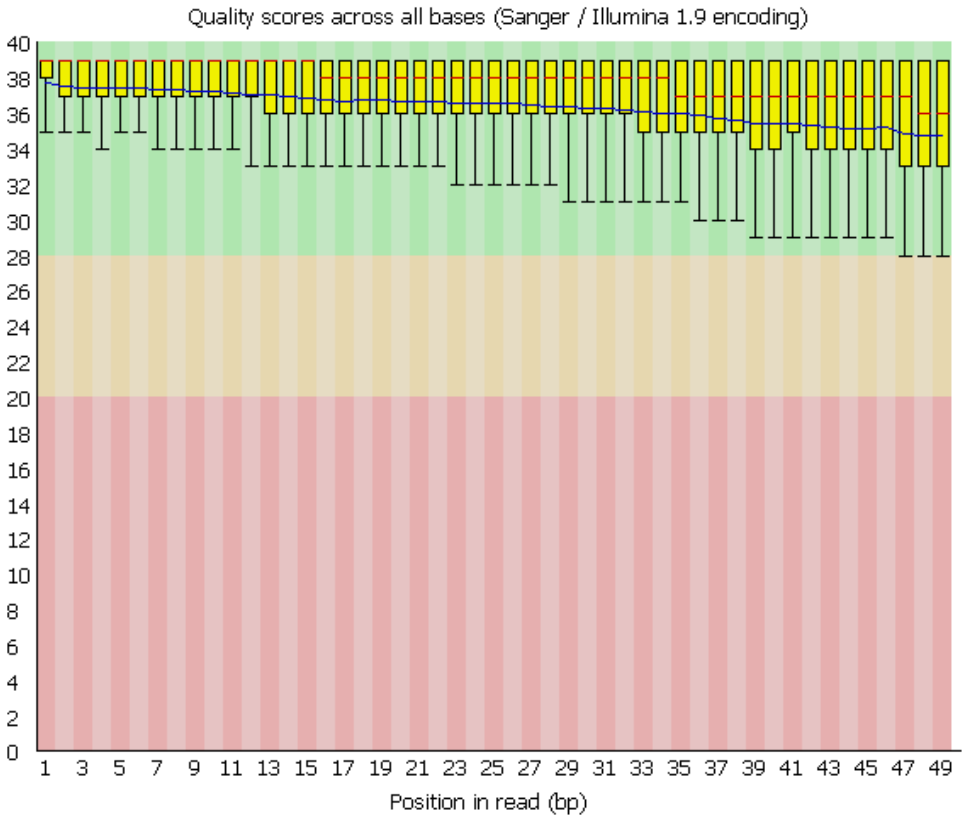


Рис.11 Якість послідовності SRR292770_2reverse

Показує якість кожного нуклеотида вздовж усіх послідовностей, що дозволяє ідентифікувати ділянки з низькою якістю

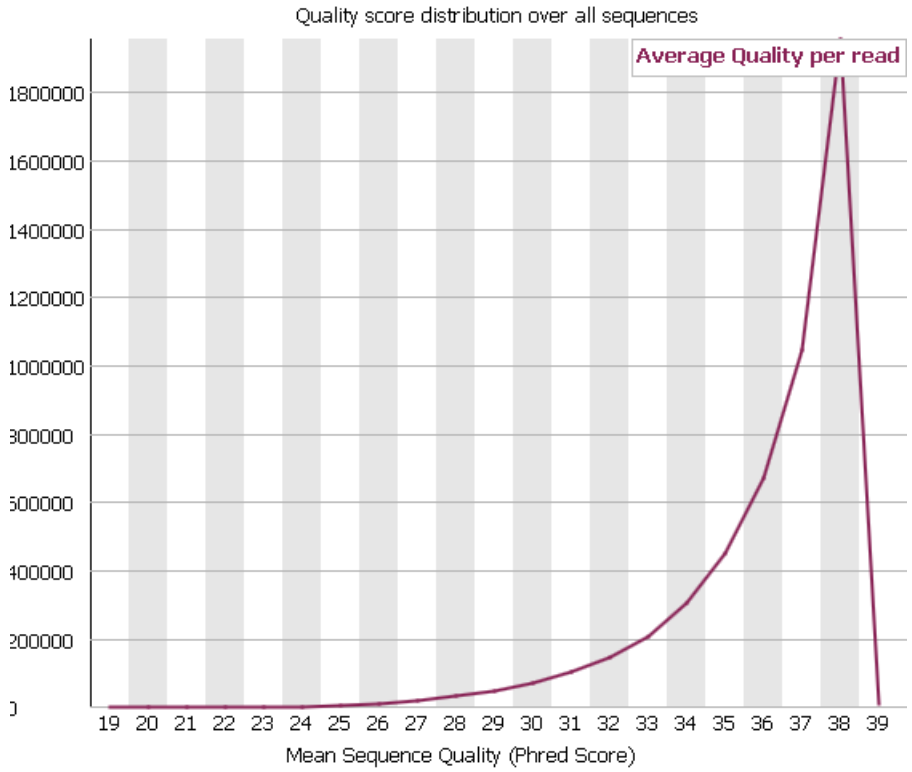


Рис.12 Оцінки якості SRR292770_1

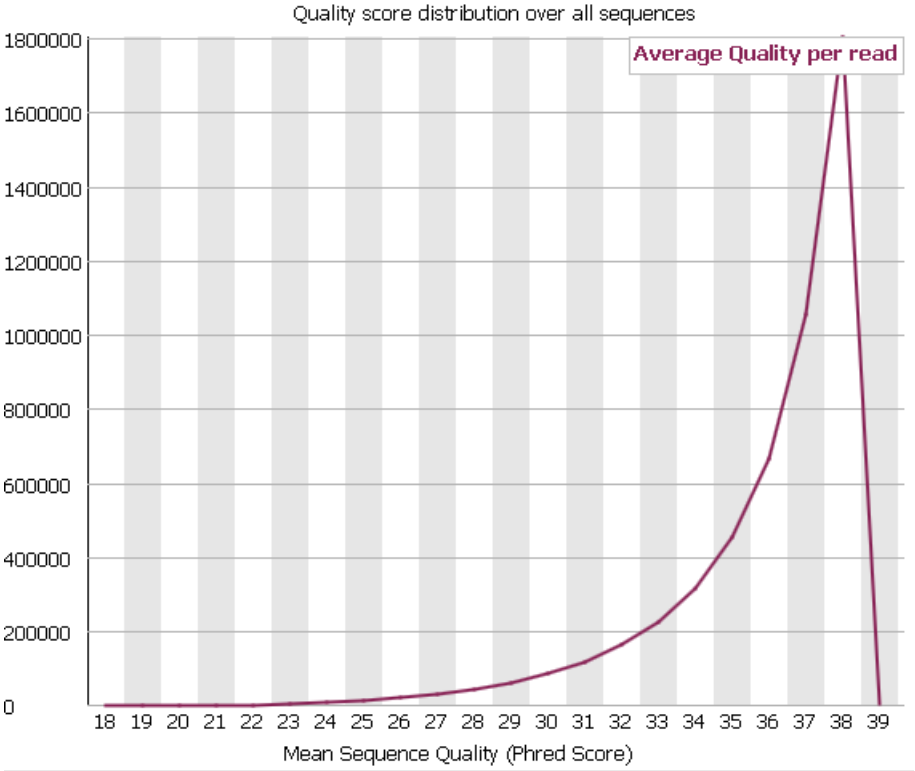


Рис.13 Оцінки якості SRR292770_2reverse

Оцінка середньої якості для кожної окремої послідовності, що використовується для виявлення низькоякісних послідовностей.

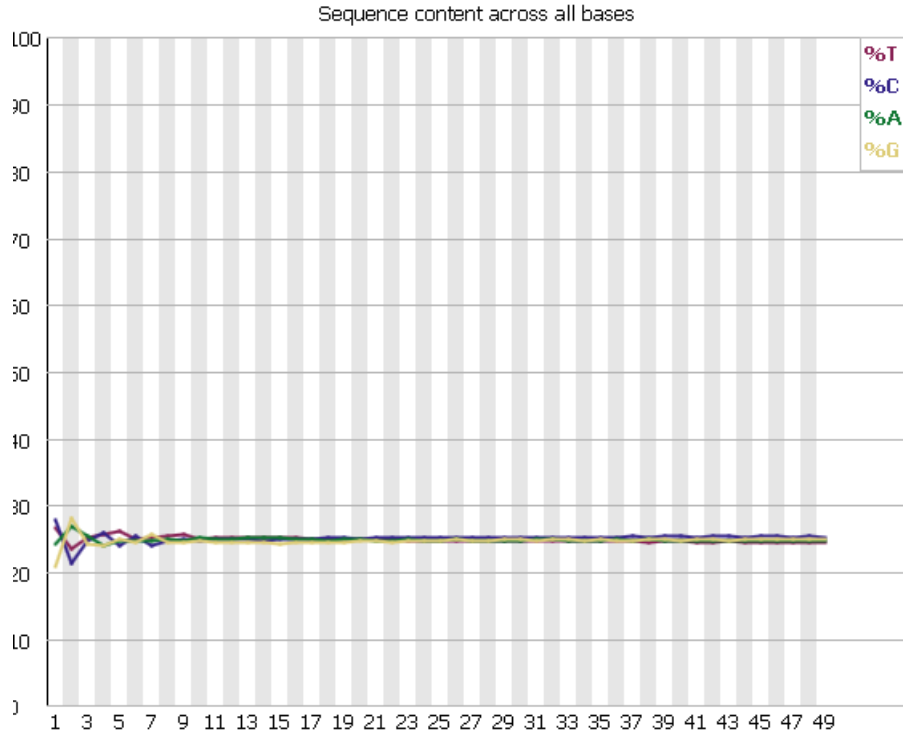


Рис.14 Вміст послідовності SRR292770_1

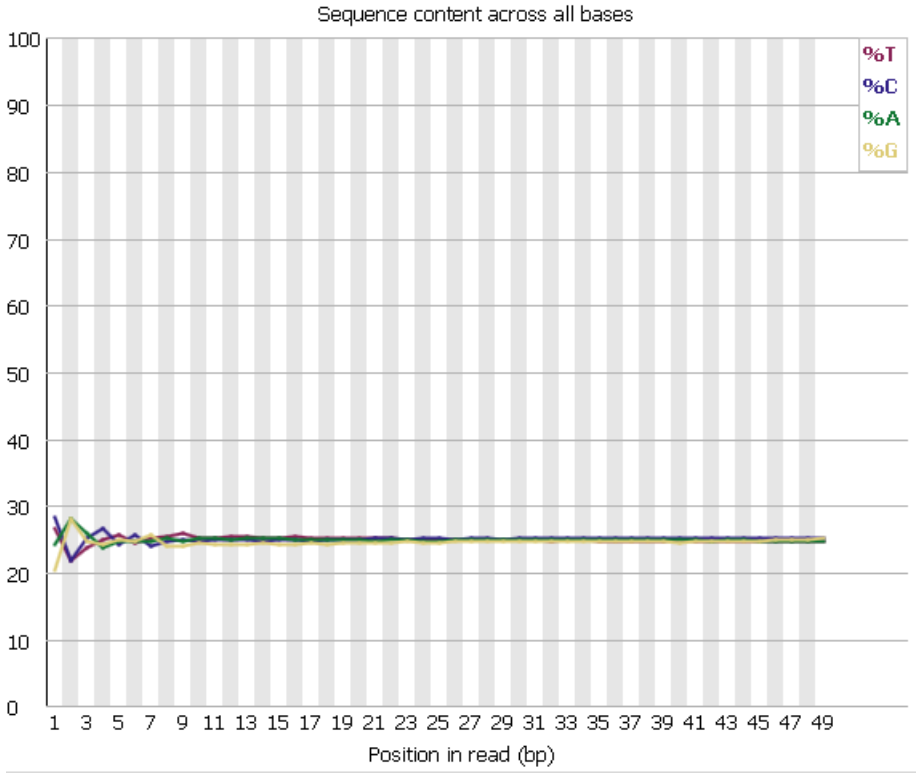


Рис.15 Вміст послідовності SRR292770_2reverse

Проаналізує вміст кожного нуклеотида (A, T, C, G) у всіх послідовностях, щоб переконатися у балансі баз.

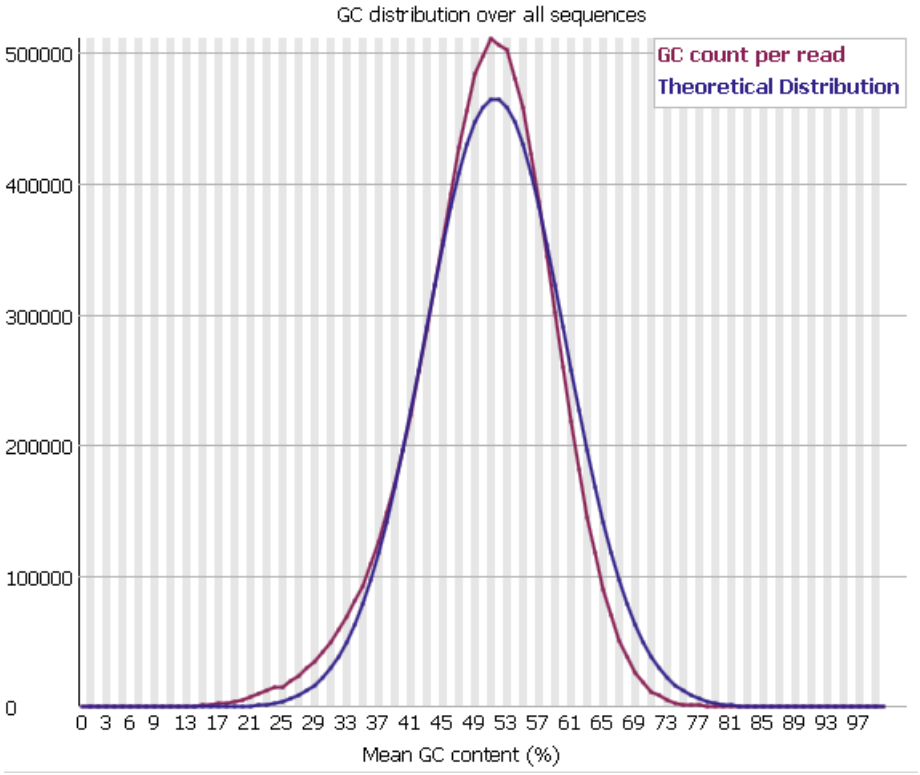


Рис.16 Вміст GC для SRR292770_1

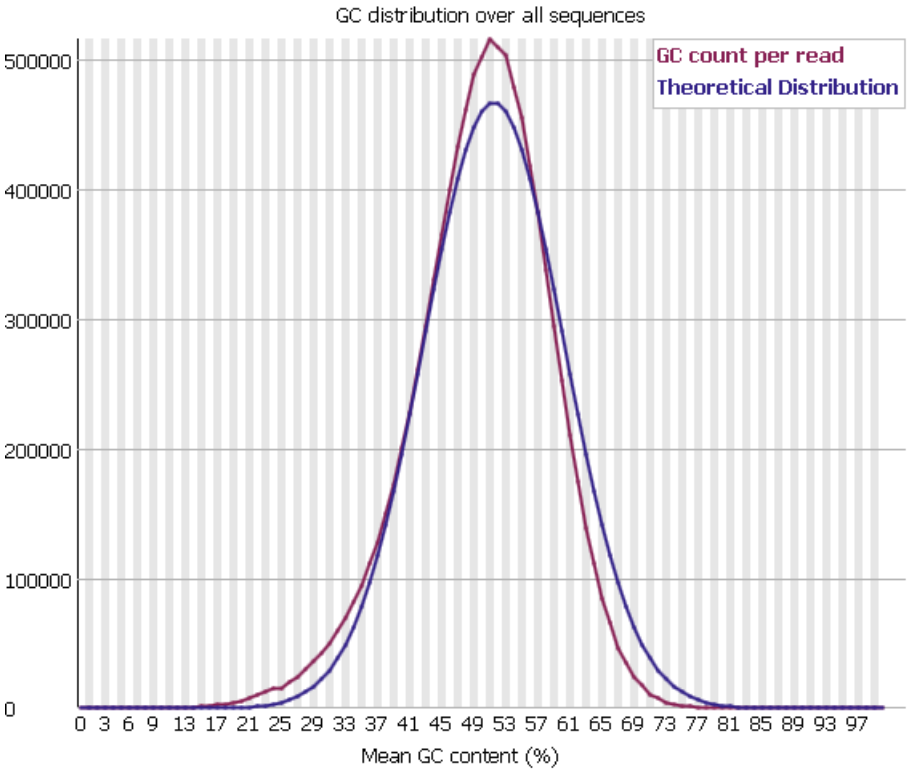


Рис.17 Вміст GC для SRR292770_2reverse

Відображає розподіл вмісту GC у всіх послідовностях, корисний для виявлення аномальних рівнів GC, які можуть вказувати на забруднення або інші проблеми.

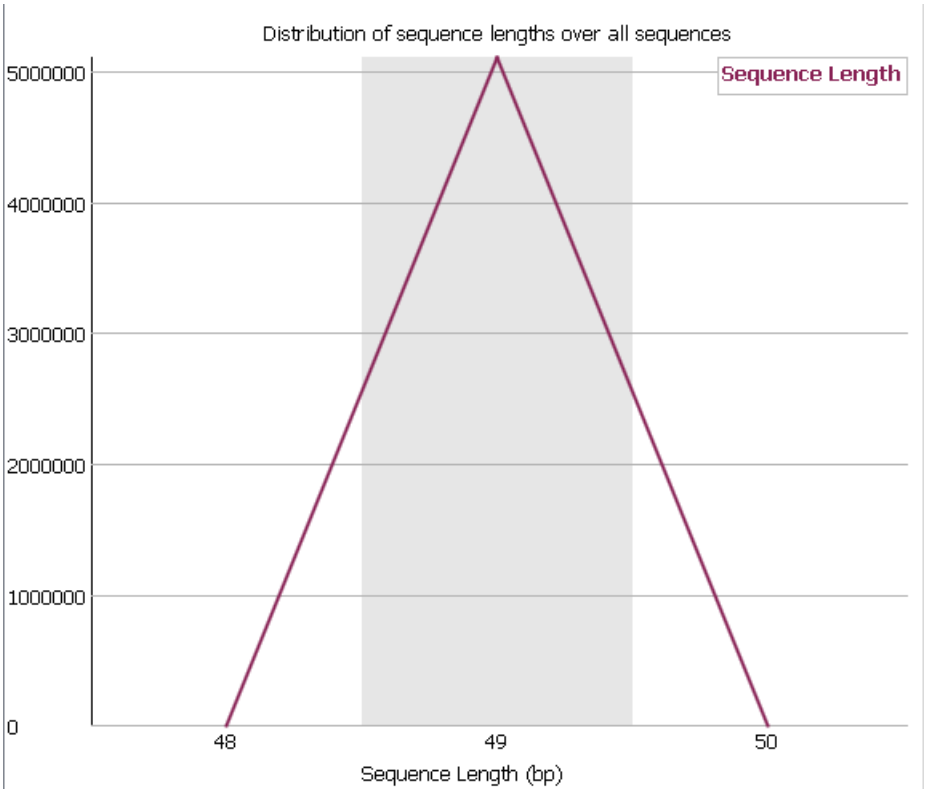


Рис.18 Розподіл довжини SRR292770_1

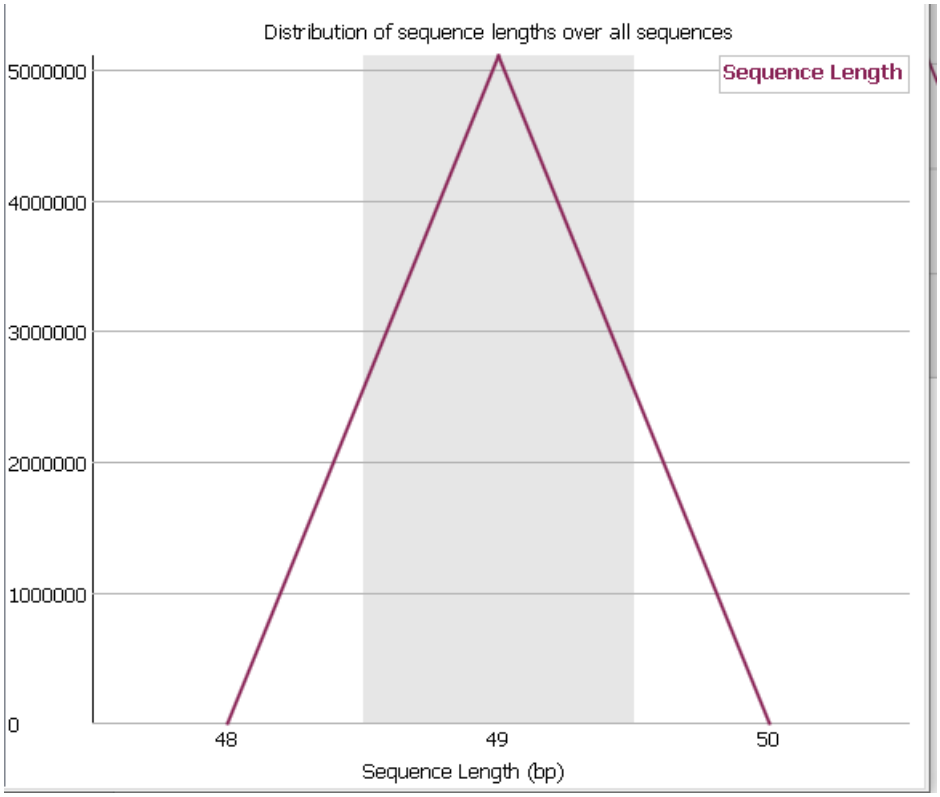


Рис.19 Розподіл довжини SRR292770_2reverse

Розподіл довжини всіх послідовностей у наборі даних; корисний для підтвердження уніформності та очікуваної довжини рідів.

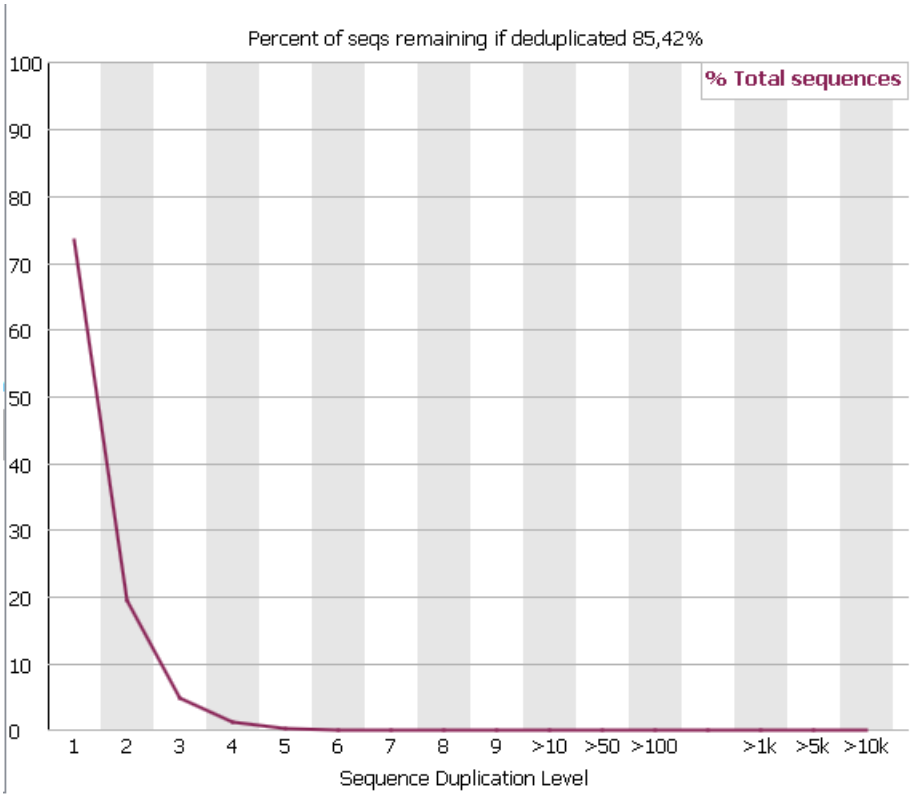


Рис.20 Рівні дублікації SRR292770_1

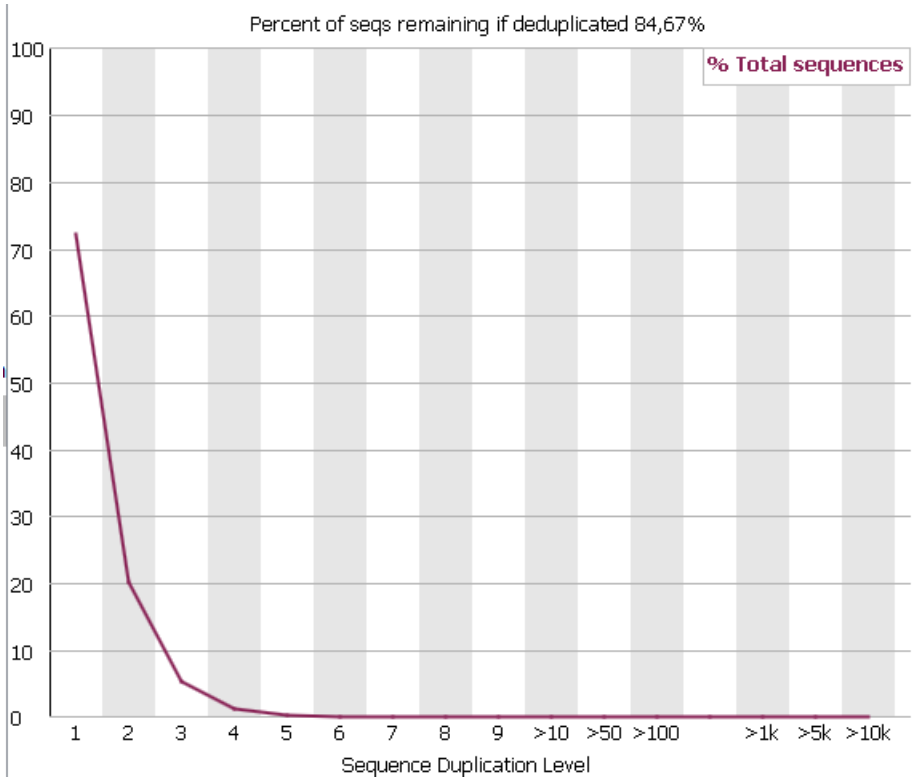


Рис.21 Рівні дублікації SRR292770_2reverse

Виявляє рівень дублікації послідовностей, може вказувати на потенційні проблеми зразка.

3) Завантаження на комп'ютер програми Trimmomatic. Покращення якості рідів за допомогою програми

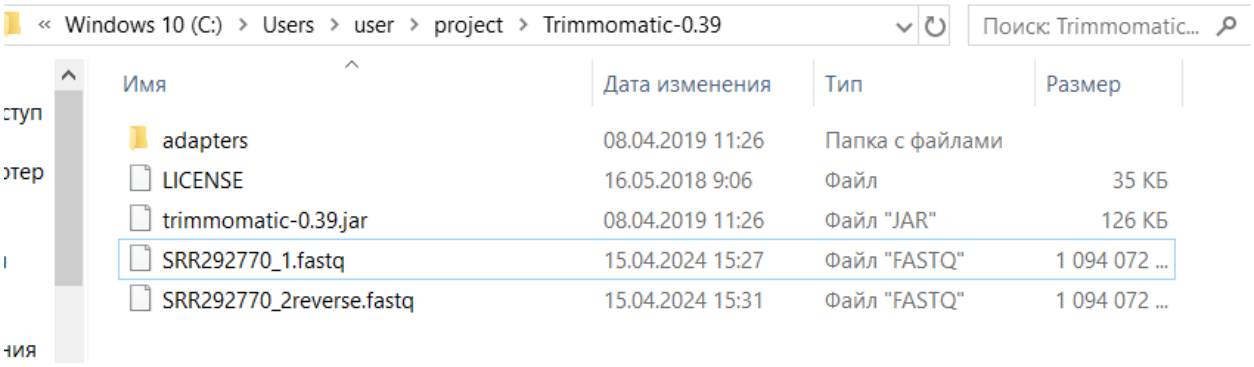


Рис.22 Завантаження Trimmomatic

Відріжемо з початку та з кінця кожного ріда нуклеотиди з якістю нижче 30. Використовуючи функції **Leading/Training/Minlen.**

Спочатку вказують, що ріди парні PE (ми працюємо з парними рідам, що отримані за допомогою платформи Illumina). На наступному кроці необхідно вказати шкалу оцінки якості рідів –phred33 або - phred 64. Потім записують вихідні дані (назву файлів з прямими та зворотними рідами) SRR292770_1.fastq SRR292770_2.fastq. На наступному кроці вказують назви файлів, що будуть зберігати інформацію по прямим рідам, які мають пару (наприклад forvardPe_1.fq) та прямим рідам, для яких пара була втрачена, що пов`язано з низькою якістю ріда (singlePe_1.fq). Аналогічну процедуру виконати тільки для зворотних рідів (reversePe_2.fq та singlePe_2.fq).

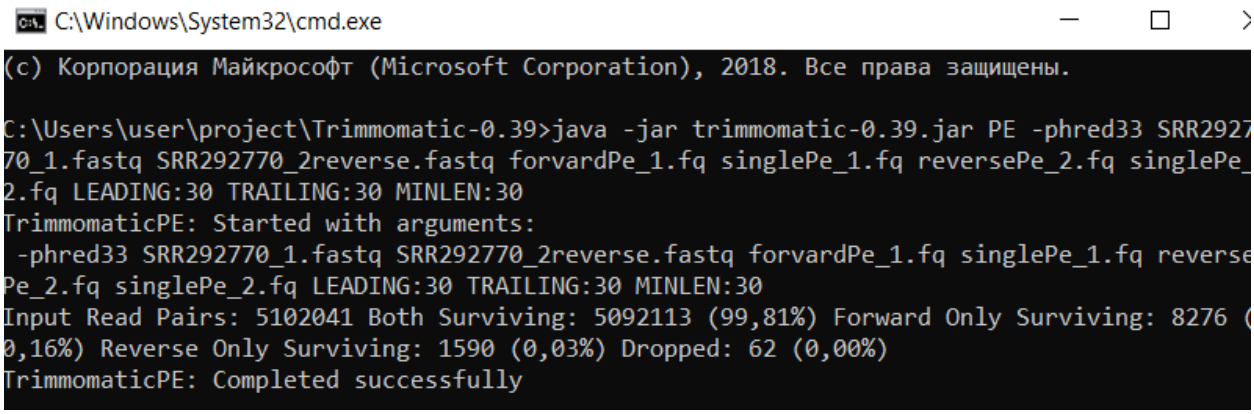


Рис.23 Команди

Basic sequence stats	
Measure	Value
Filename	forvardPe_1.fq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	5092113
Total Bases	248.2 Mbp
Sequences flagged as poor quality	0
Sequence length	30-49
%GC	50

Рис.24 Базова статистика

Basic sequence stats	
Measure	Value
Filename	reversePe_2.fq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	5092113
Total Bases	247.5 Mbp
Sequences flagged as poor quality	0
Sequence length	30-49
%GC	49

Рис.25 Базова статистика

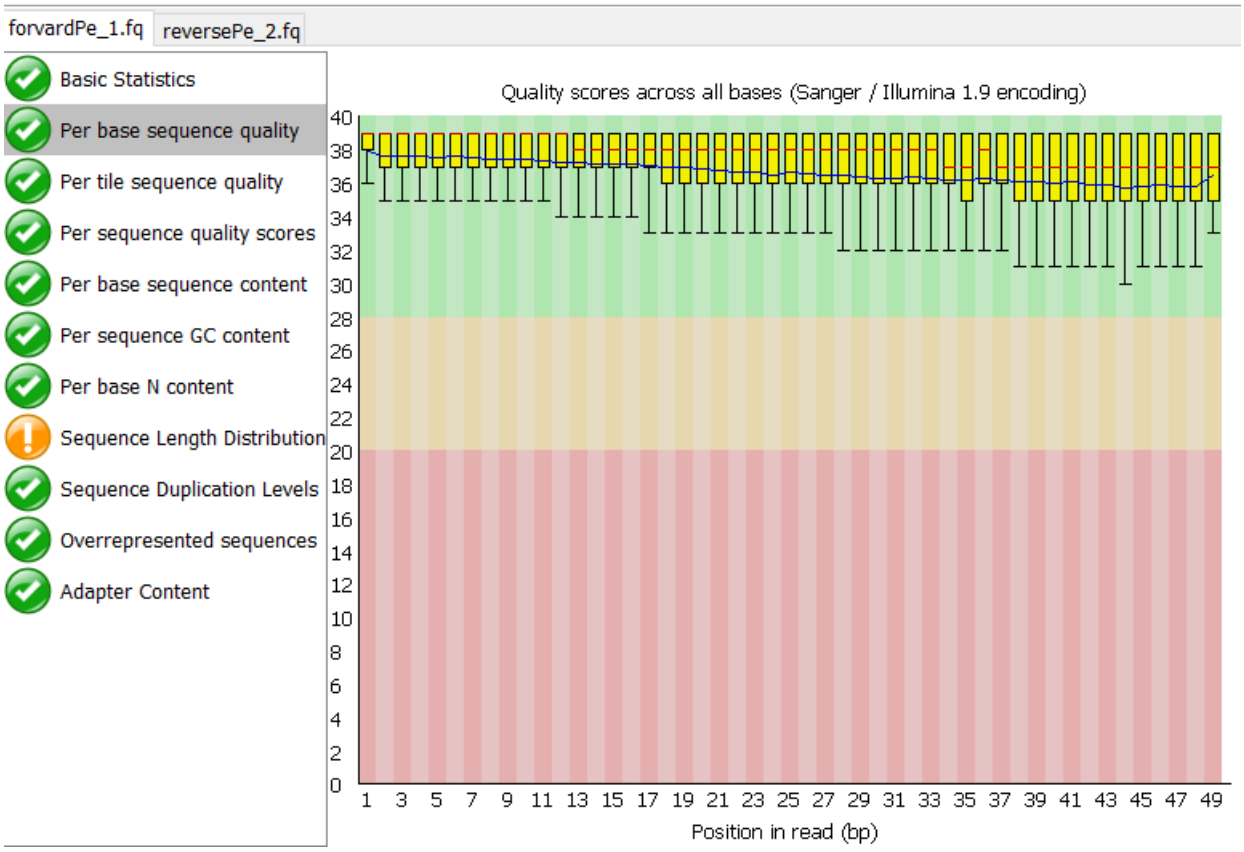


Рис.26 Розподіл якості

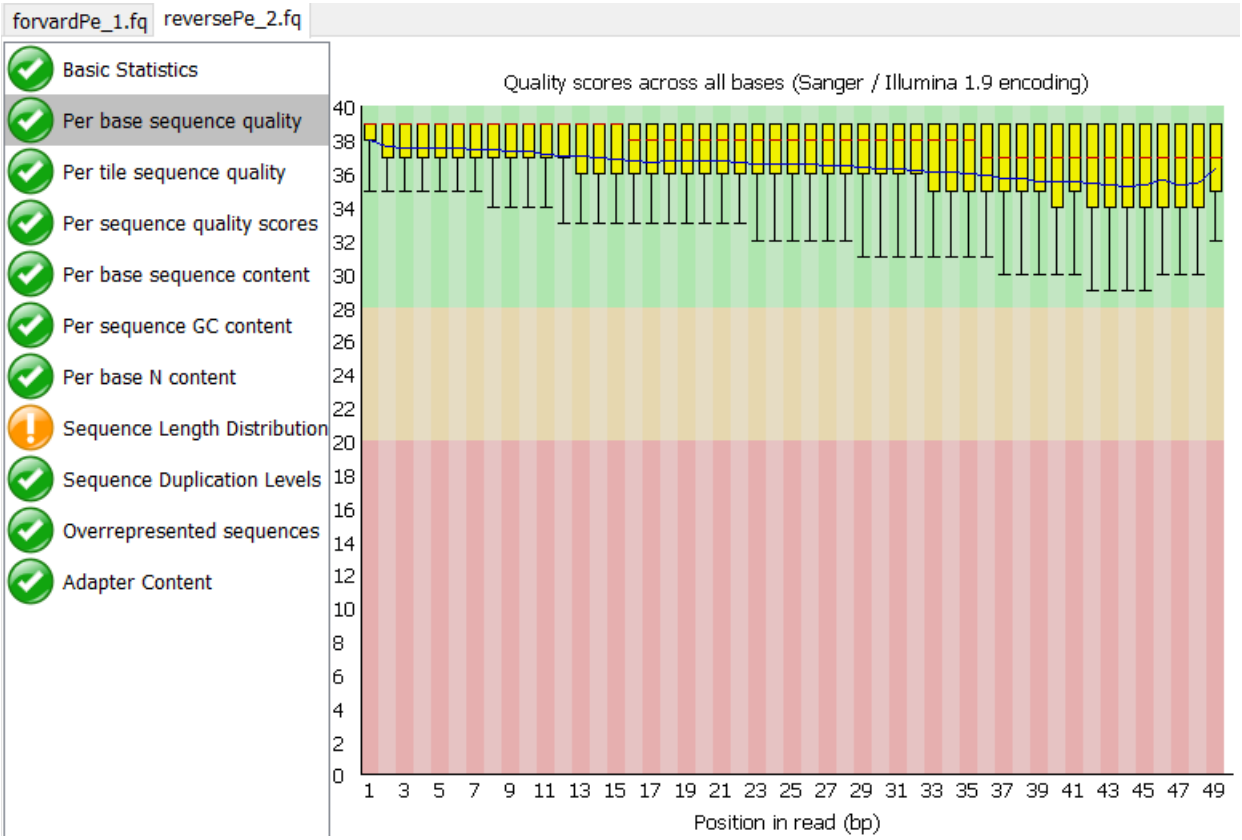


Рис.27 Розподіл якості

Можна побачити що:

- прочитано 5102041 пар рідів, залишилось 5092113 пар рідів (99,81%)
- лише прямі: 8276 (0,16%)
- лише зворотні: 1590 (0,03%)
- випали: 62 (0,00%)

Висновок

В рамках лабораторного дослідження успішно проведено аналіз первинних даних секвенування для штаму Escherichia coli O104:H4. Інструментарій FastQC дозволив виконати комплексний огляд .fastq файлів, оцінити параметри якості та вміст послідовностей. Отримані результати ілюструються у другому розділі звіту. Додатково, застосування Trimmomatic сприяло оптимізації даних шляхом відсікання фрагментів з низьким рівнем якості та скорочення рідів, які не відповідали заданим критеріям довжини. Ці дії забезпечили вищу достовірність подальших біоінформаційних аналізів, деталі яких представлено у третьому розділі.