НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»
Інститут прикладного системного аналізу
Кафедра системного проектування

Звіт

про виконання комп'ютерного практикуму №2
з дисципліни «Основи молекулярної біології та біоінформатики»

студент 3го курсу
групи ДА-11
Сидько Нікіта Сергійович

Київ-2024

Мета роботи: навчитись асемблювати геноми про/та еукаріотичних організмів та оцінювати якість отриманої збірки.

Основні задачі роботи:

1. Ознайомитись з алгоритмом Overlap layout consensus (OLC)
2. Ознайомитись з алгоритмом збірки геномів на основі графів де Брейна.

Алгоритм Overlap layout consensus (OLC)

На сьогоднішній день для задач асемблювання геномів використовують два основних алгоритма. Перший з них був запропонований у 1980 році та отримав назву Overlap layout consensus. Це інтуїтивно зрозумілий алгоритми який передбачає спочатку попарне порівняння та вирівнювання всіх рідів. Після чого будується граф, в якому вузлами є ріди. Якщо перекриття між рідами виявляється не менше, ніж задана порогова величина T, вузлу прописують зв'язок (ребро).

Наприклад, якщо у нас є ріди ACGT, CGTT, TTAA и нам потрібно зібрати фрагмент геному при пороговому значенні T=2. Після проведення вирівнювання ми бачимо, що ріди перекриваються. Побудуємо граф, в якому ребра будуть поєднувати вершини графу (ріди) за умов перекриття. Граф буде мати вигляд ACGTCGTTTTAA. Задача встановлення первинної послідовності нуклеотидів зводиться до знаходження загального підрядка для заданих рядків. Гамільтонів цикл проходить по кожній вершині графа рівно один раз. Такий шлях по графу дозволяє визначити послідовність нуклеотидів геному. Для даного прикладу послідовність фрагменту геному буде мати вигляд ACGTTAA.

OLC алгоритм збірки геному використовуються багатьма програмами-асемблерами, такими як: Arachne, CAP3, Phusion, Celera Assembler.

Ребро – це що відображає певний рід. Вершини поєднуються в структурі графа, якщо префікс співпадає з суфіксом.

Граф де Брейна

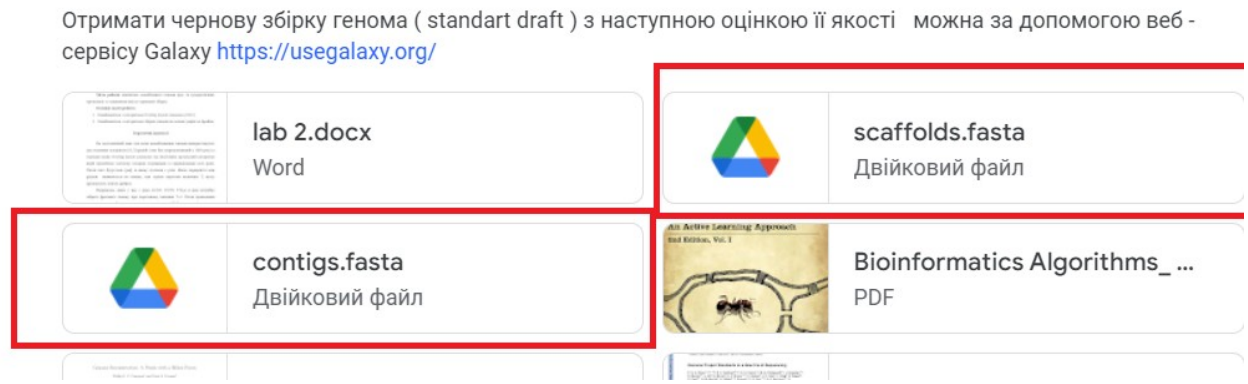
Задачу знаходження шляху по вершинам графу можна вирішити за експоненційний час, що є недопустимим, враховуючи велику кількість вихідних даних секвенаторів NGS.

Для NGS використовується інший алгоритм збірки геномів. Алгоритм базується на використанні графів де Брейна. Для кожного ріда формується префікс та суфікс однакової довжини k (k-мери). Кожний рід в структурі графа містить дві вершини, що поєднується ребром. Ребро – це k+1- мер, що відображає певний рід. Вершини поєднуються в структурі графа, якщо префікс співпадає з суфіксом k-мера. Знайдений Ейлеров цикл в графі дозволяє отримати послідовність нуклеотидів геному. Складність такого алгоритму O(N). Такий лінійний алгоритм можливо ефективно використовувати для вихідних даних секвенаторів NGS.

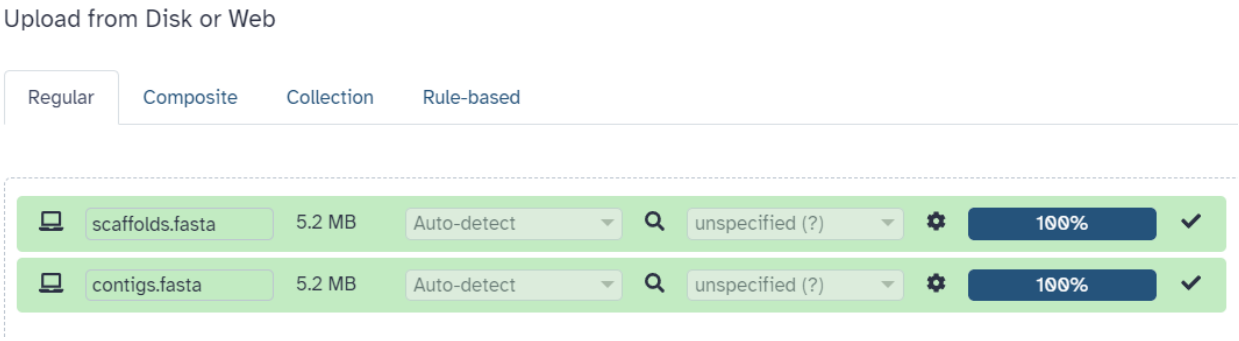
Виконання роботи

Для початку перейдемо на сайт : https://usegalaxy.org/

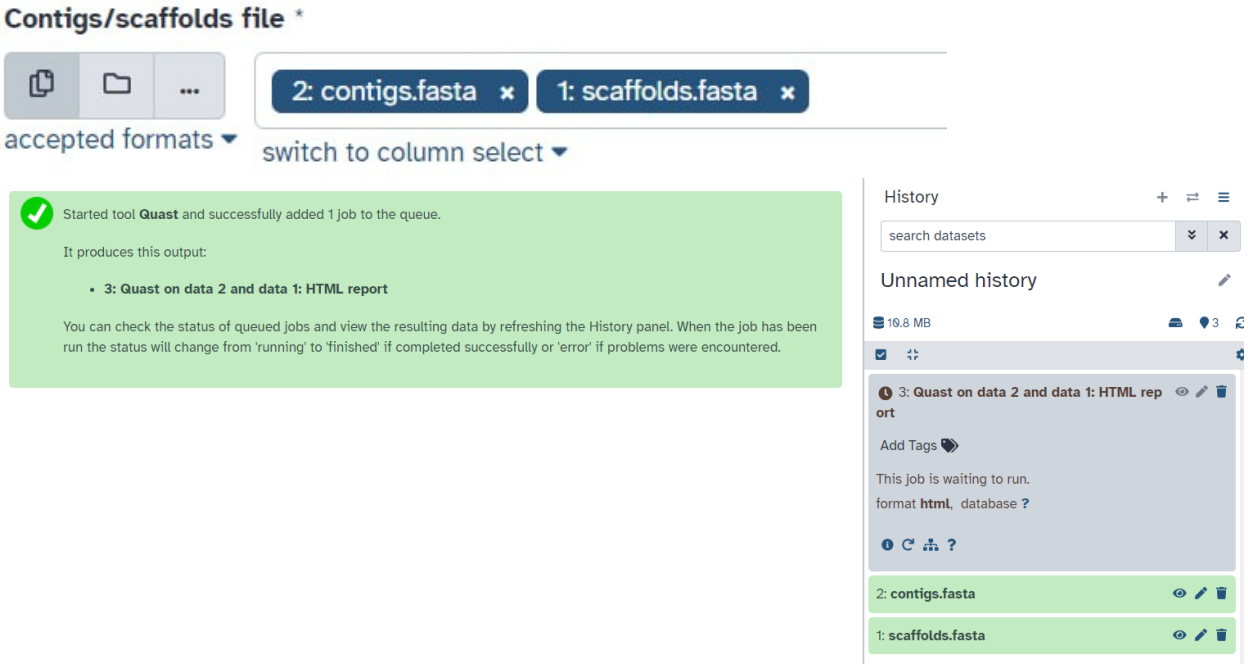
Після чого завантажимо файли



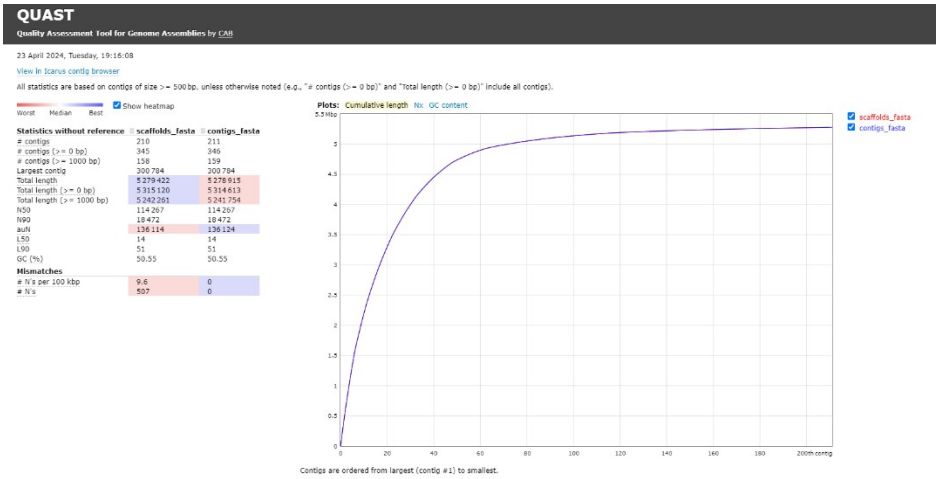
Та перекинемо їх на сайт



Завантиживши файли натиснемо Run і отримуємо:



Отримуємо посилання на наступну сторінку, де можемо побачити графіки та дані:



Почнемо з отриманих даних:

Statistics without reference	scaffolds_fasta	contigs_fasta
# contigs	210	211
# contigs (>= 0 bp)	345	346
# contigs (>= 1000 bp)	158	159
Largest contig	300 784	300 784
Total length	5 279 422	5 278 915
Total length (>= 0 bp)	5 315 120	5 314 613
Total length (>= 1000 bp)	5 242 261	5 241 754
N50	114 267	114 267
N90	18 472	18 472
auN	136 114	136 124
L50	14	14
L90	51	51
GC (%)	50.55	50.55
Mismatches		
# N's per 100 kbp	9.6	0
# N's	507	0

- Загальна довжину скафолдів та контигів (підписано нижче)

Statistics without reference	scaffolds_fasta	contigs_fasta
Total length	5 279 422	5 278 915

- Максимальну довжину контигів та скефолдів

Statistics without reference	scaffolds_fasta	contigs_fasta
Largest contig	300 784	300 784

- Загальну довжину скефолдів, враховуючи фрагменти довжиною менше 500 нуклеотидів

Statistics without reference	scaffolds_fasta	contigs_fasta
Total length (>= 0 bp)	5 315 120	5 314 613

- N50 для скафолдів

Statistics without reference	scaffolds_fasta
N50	114 267

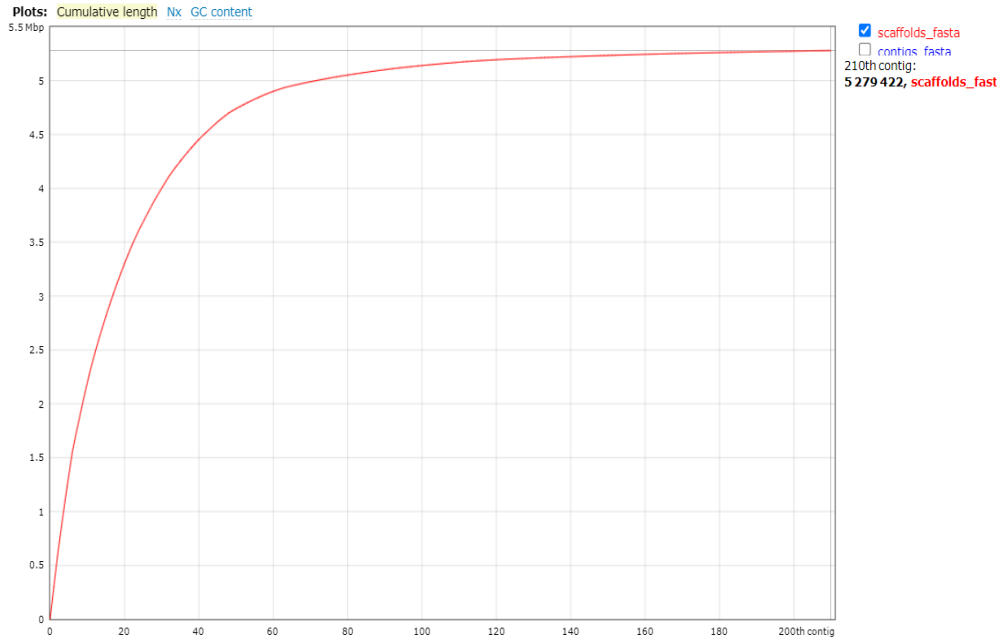
- L50 для скафолдів

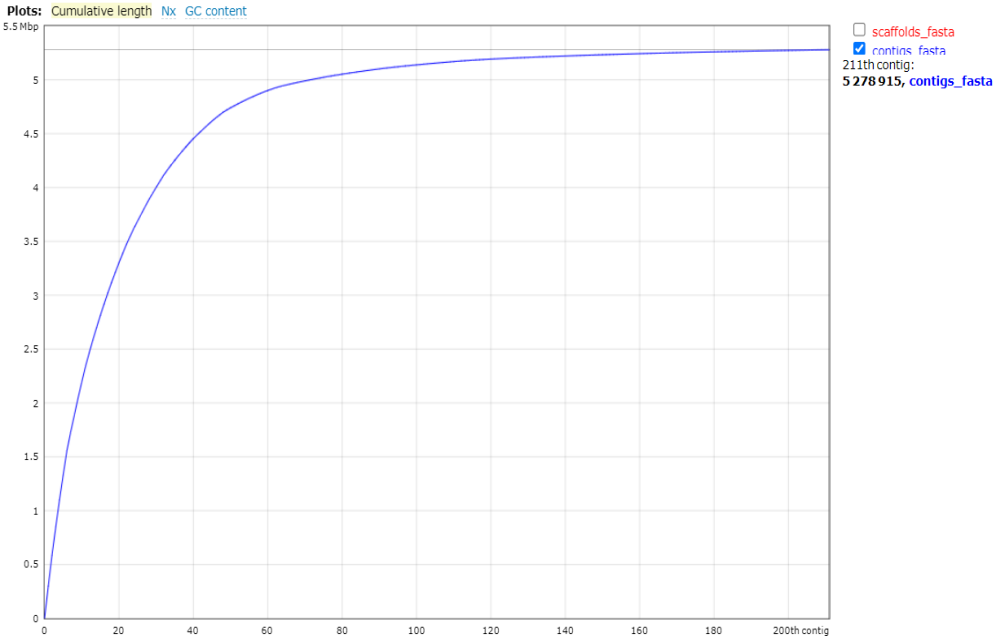
Statistics without reference	scaffolds_fasta
L50	14

- Загальну кількість пропусків (гепів) для скафолдів

Statistics without reference	scaffolds_fasta
# N's	507

Далі перейдемо до графіків:



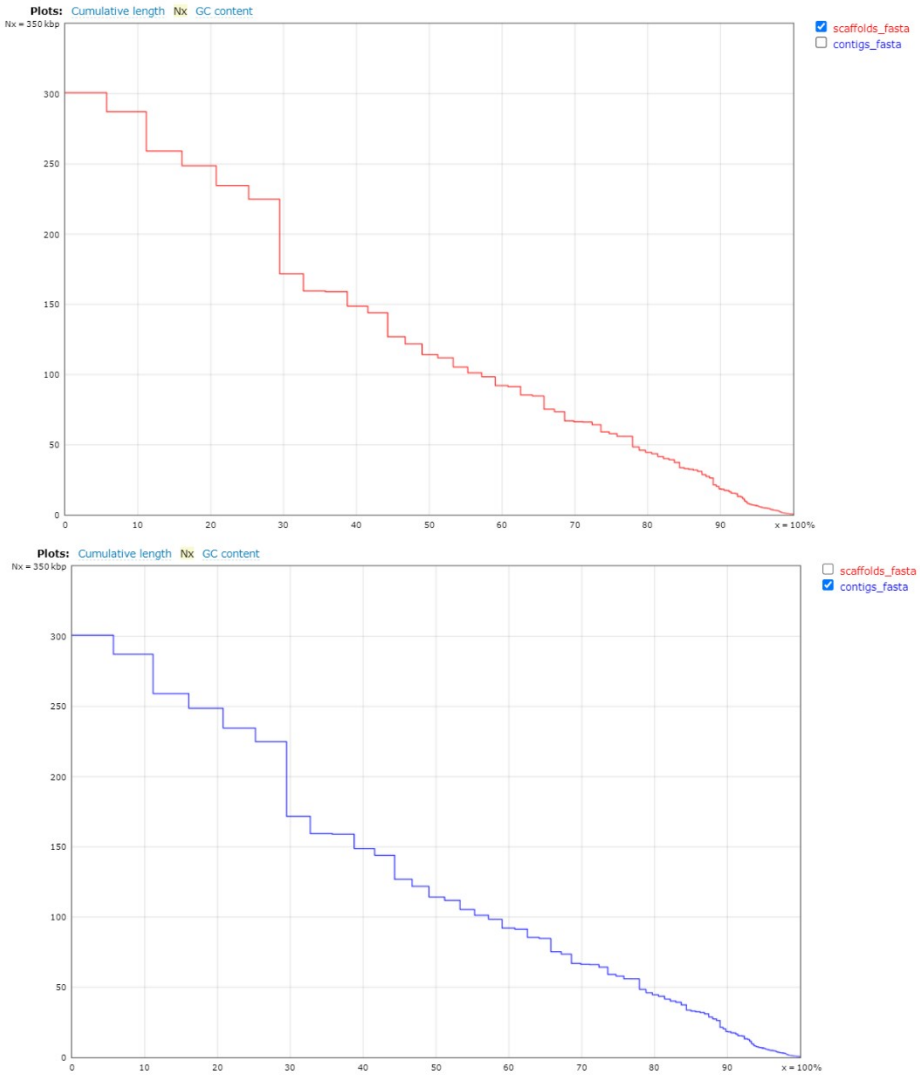


Визначемо довжину перший та останній контиги

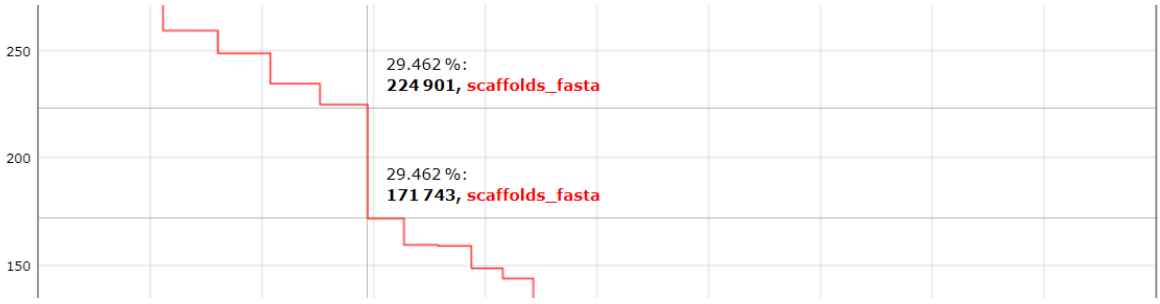
1st contig:
300 784 scaffolds_fasta
300 784 contigs_fasta

211th contig:
5 279 422, scaffolds_fasta
5 278 915, contigs_fasta

Визначити сусідні скафолди, для яких розбіжність по довжині буде максимальною, в порівнянні з іншими скафолдами ?



З графіків можна побачити наступне:



Чому деякі значення (наприклад total length >=1000) для контигів та скафолдів не співпадають ?

Скафолди можуть включати гепи (прогапи узгодження, які позначаються як "N"), які вставляються між контигами, щоб створити більш повні сегменти геномної послідовності. Ці гепи збільшують загальну довжину скафолдів порівняно з контигами. У таблиці зазначено, що є 507 "N's" в скафолдах, але 0 в контигах.

Процес асемблювання: Під час створення скафолдів, окремі контиги можуть бути з'єднані за допомогою гепів на основі інформації з парних кінців (mate pairs) або зчитувань з мостиками. Таке з'єднання може внести додаткову довжину до скафолдів.

З'єднання перекриваючихся контигів: Якщо два контиги частково перекриваються і це перекриття було ідентифіковане та використане для створення скафолда, загальна довжина може зменшитись порівняно з сумою індивідуальних контигів.

Висновок

У ході виконання лабораторної роботи №2 ми навчилися використовувати програму QUAST для аналізу геномних збірок, які містять набори contigs та scaffolds. Ми отримали важливу інформацію про структуру геному Escherichia coli, включно із загальними та максимальними довжинами цих послідовностей, а також визначили кількість та розміщення пропусків у зібраних скафолдах. Додатково, за допомогою графічного аналізу, нам вдалося встановити довжини крайніх контігів та ідентифікувати скафолди з найбільшою розбіжністю у довжині, що є важливим для розуміння структури генома та відповідності зібрання з очікуваним результатом. Ця робота дала нам можливість глибше зрозуміти процеси збірки геномів та оцінки їх якості