НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»
Інститут прикладного системного аналізу
Кафедра системного проектування

Звіт

про виконання комп'ютерного практикуму №3
з дисципліни «Основи молекулярної біології та біоінформатики»

студент 3го курсу
групи ДА-11
Сидько Нікіта Сергійович

Київ-2024

Комп’ютерний практикум №3 Пошук гомологічних послідовностей за допомогою алгоритму BLAST

Мета роботи: використовуючи алгоритм пошуку схожих послідовностей BLAST (Basic Local Alignment Search Tool) знайти гіпотетичних гомологів відповідного білка.

Основні задачі роботи:

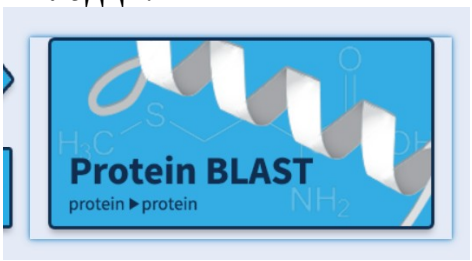
1. Ознайомитись з особливостями алгоритмів, що використовують хешування. Хеш-функція. Алгоритм BLAST.

2. Ознайомитися з основними принципами побудови матриць замін амінокислот PAM та Blosum.

Варіант 24

	Білок	Гомолог
24.	RESA_BACSU	RESA_GEOKA

1.Пошук гіпотетичних гомологів досліджуваного білка в різних базах даних.
Перейдемо за посиланням : http://blast.ncbi.nlm.nih.gov
Перейдемо по наступній вкладці :

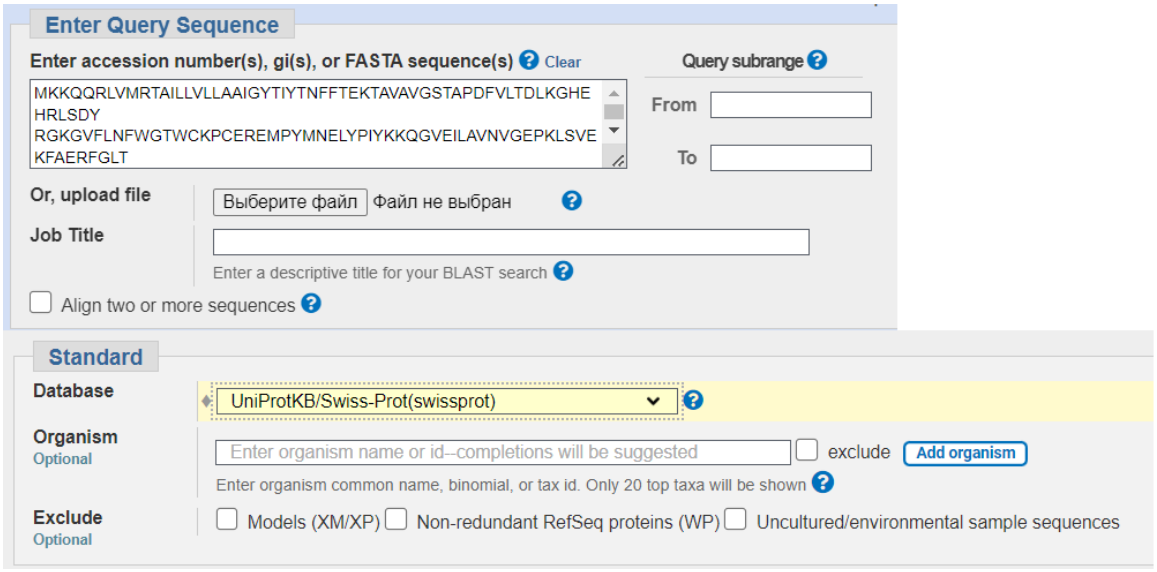


Для білка/гомолога маємо наступне:

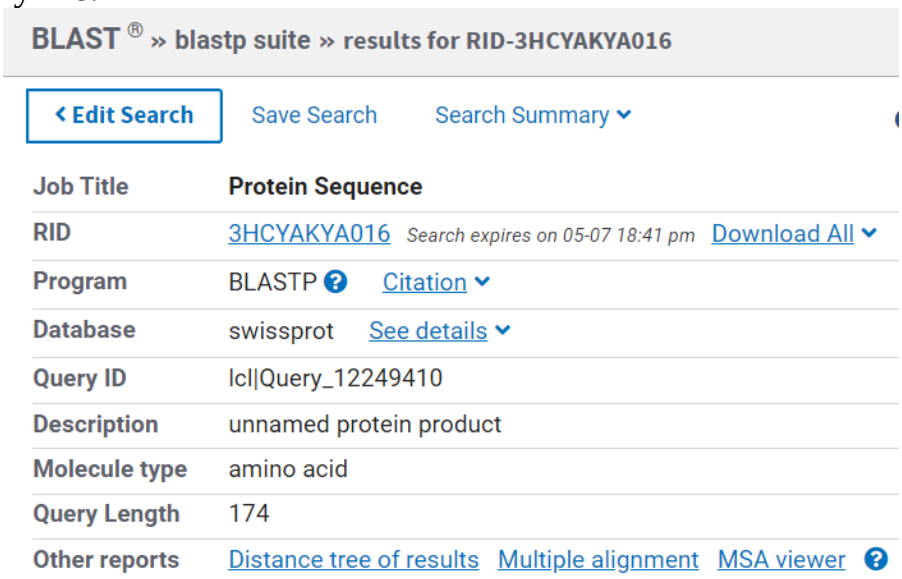
Білок: MKKKRRLFIRTGILLVLICALGYTIYNAVFAGKESISEGSDAPNFVLEDTNGKRIELSDL
KGKGVFLNFWGTWCEPCKKEFPYMANQYKHFKSQGVEIVAVNVGESKIAVHNFMKSYGVN
FPVVLDTDRQVLDAYDVSPLPTTFLINPEGKVVKVVTGTMTESMIHDYMNLIKPGETSG

Гомолог:
MKKQQRLVMRTAILLVLLAAIGYTIYTNFFTEKTAVAVGSTAPDFVLTDLKGHEHRLSDY
RGKGVFLNFWGTWCKPCEREMPYMNELYPIYKKQGVEILAVNVGEPKLSVEKFAERFGLT
FPIVIDRQDQVLNAYNVGPLPTTFLIDKNGEVKQIITGTMTKEDIERHLESIKP

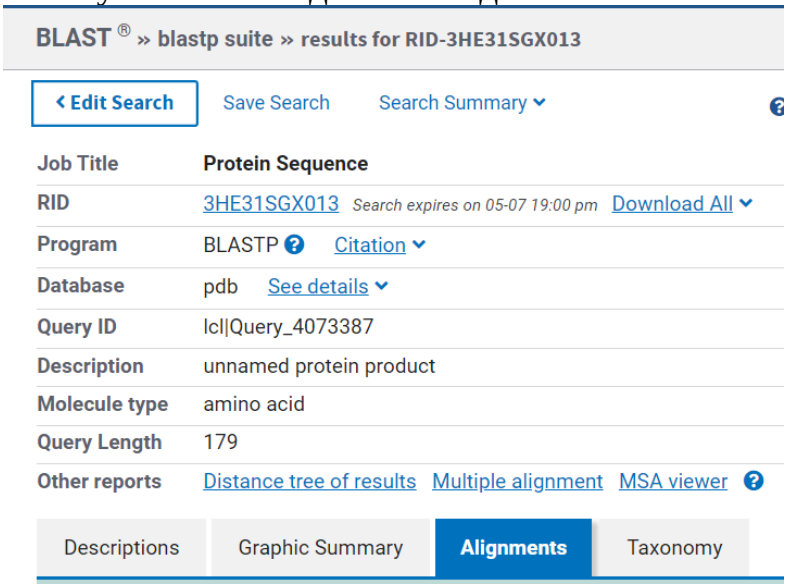
Далі проведемо пошук гомологів для в базі даних Swiss-Prot (аналогічно робимо і для інших баз даних)



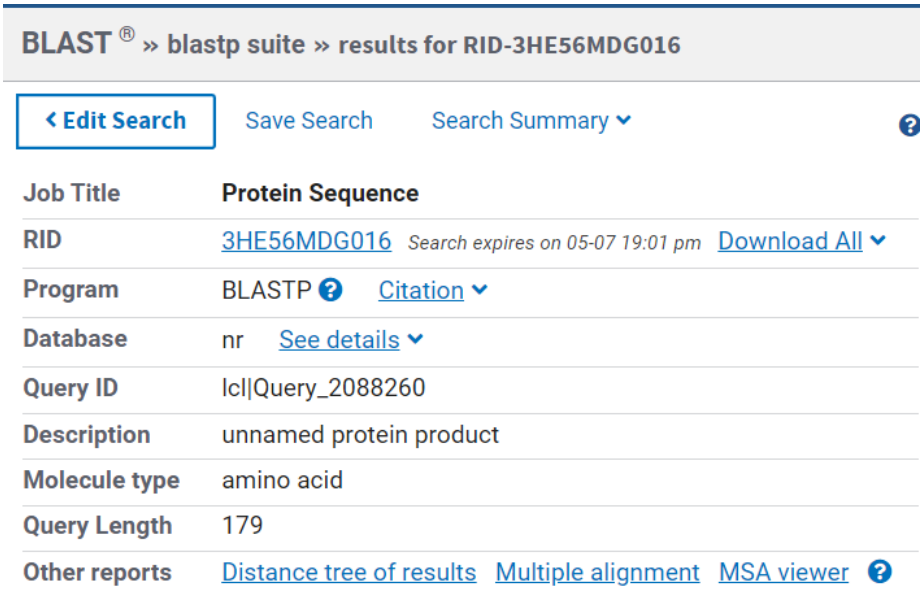
Маємо наступне:



Далі проведемо пошук гомологів для в базі даних PDB



Далі проведемо пошук гомологів для в базі даних nr



Виконаємо заповнення нижче наведеної таблиці згідно даних з різних БД:

	Пошук у БД Swiss-Prot	Пошук у БД PDB	Пошук у БД "nr"
1. Краща знахідка (повинна відповідати заданому білку)			
Accession	Q5KXL9	1ST9_A	WP_003230513
E-value	2e-129	1e-105	8e-130
Вага (у битах)	362 bits(930)	300 bits(767)	372 bits(954)
Відсоток ідентичності	100%	100%	100%
2.Скільки найкращих кандидатів по гомології знайдено? (число знахідок у списку опису з E-value <$1e^{-10}$)	20	24	100

3. "Гірша з задовільних" знахідка (E-value <1)			
Номер знахідки у списку описів	100	72	100
Accession	Q9XGS0	5JY5_A	WP_223062878
E-value	0.039	0.047	7e-109
Вага (у бітах)	36.6 bits(83)	33.9 bits(76)	319 bits(817)
Відсоток ідентичності	28%	24%	84%
Відсоток подібності	48%	40%	90%
Довжина вирівняної послідовності	177	110	179
Координати вирівнювання (від-до, у запиті та в знахідці)	65-125 92-151	65-125 21-61	2 -62 3 - 63
Число гепів	5/86	25/96	0/177

- Чи вдалося знайти вихідний білок у Swiss-Prot та "nr", а його структуру в PDB?

Так, вдалося

- Порівняйте число явних гомологів (E-value < $1e^{-10}$) при пошуку за різними БД та поясніть можливі причини відмінностей.

Пошук у БД Swiss-Prot – 20

Пошук у БД PDB – 24

Пошук у БД "nr" – 100

Найбільша кількіст у БД nr, так як вона є найбільшою базою даних білкових послідовностей.

➢ Скільки всього знахідок та яке E-value останньої знахідки?

Пошук у БД Swiss-Prot – 0.039

Пошук у БД PDB – 0.047

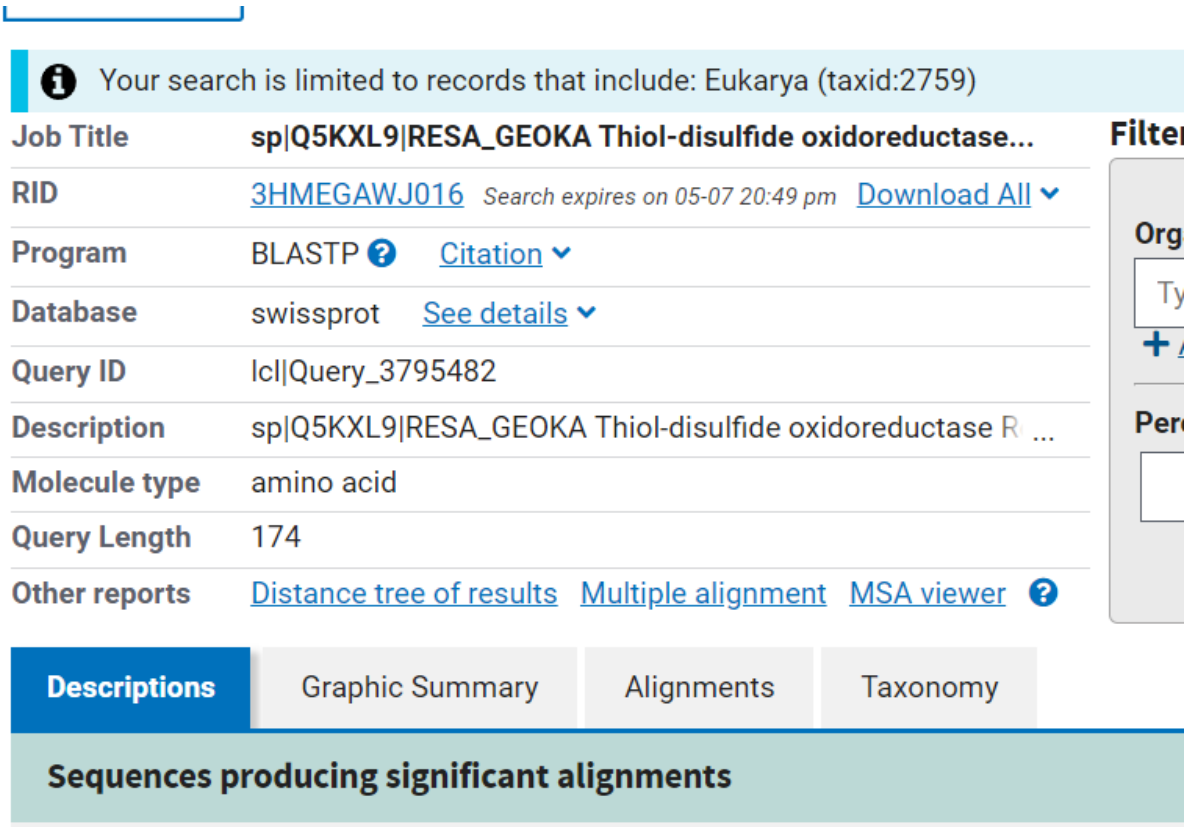
Пошук у БД "nr" – 7e-109

➢ Чим у вашому випадку було лімітовано число знахідок: значенням E-value або заданим за замовчуванням граничним розміром видачі ?

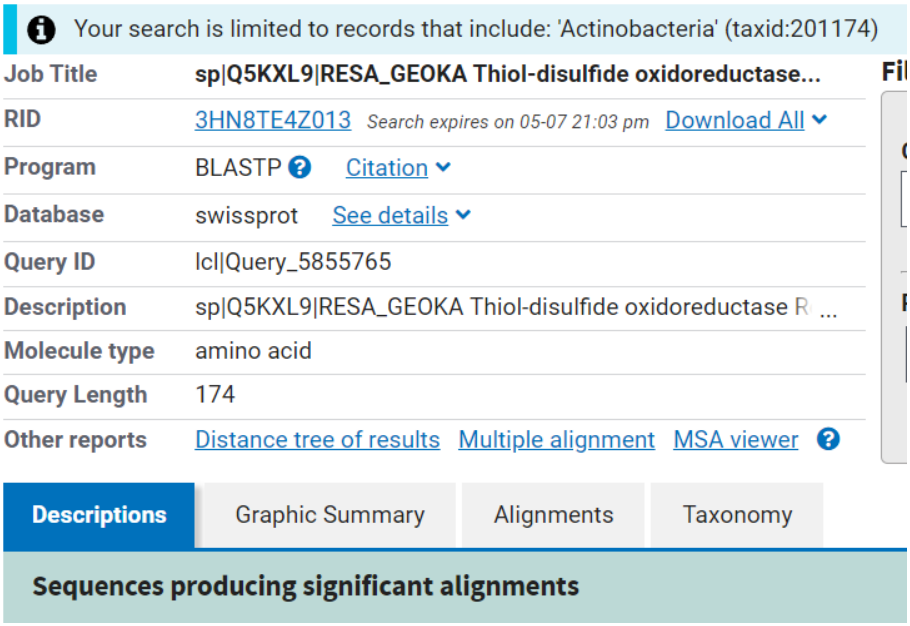
За замовчуанням.

2)Пошук гіпотетичних гомологів досліджуваного білка з використанням фільтра по таксонам. (RESA_GEOKA)
Для дослідження використовуються наступні таксони:

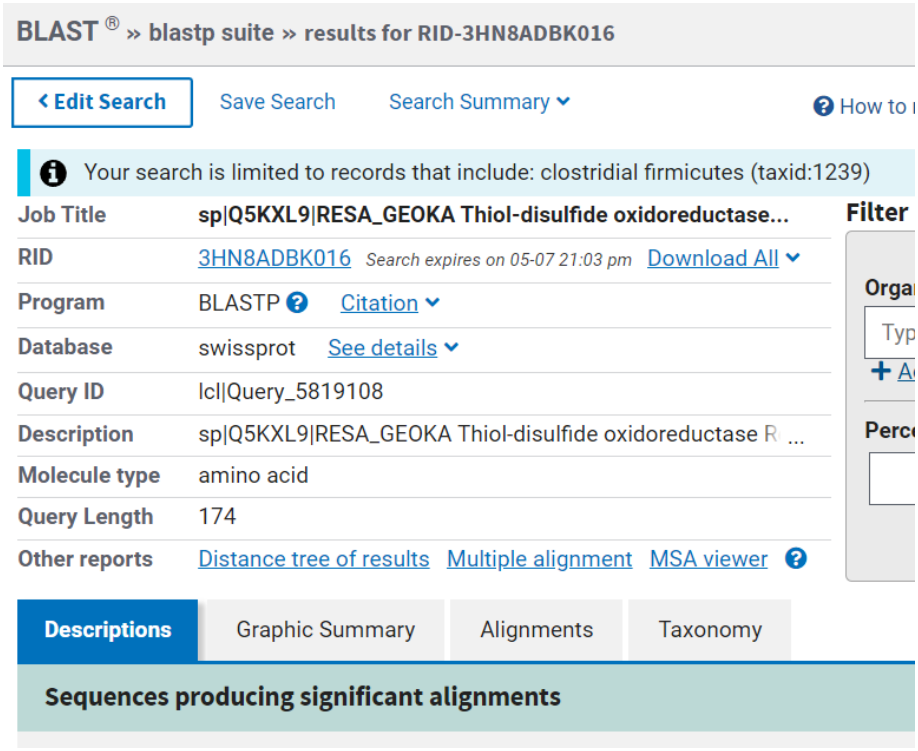
Eukaryota (інше царство);



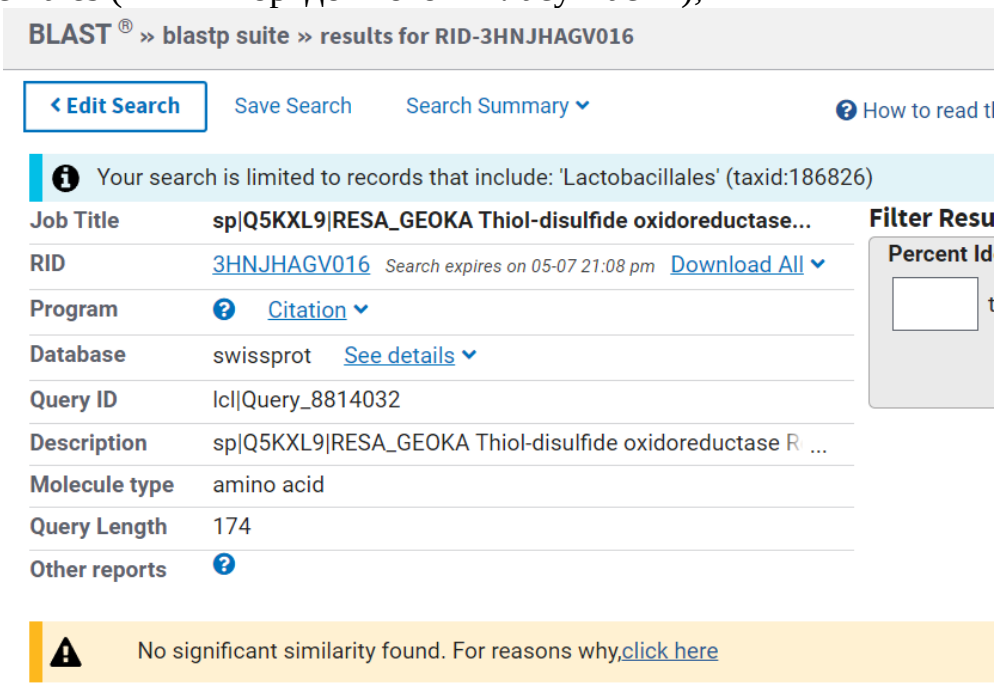
Actinobacteria (інший відділ того ж царства бактерій);



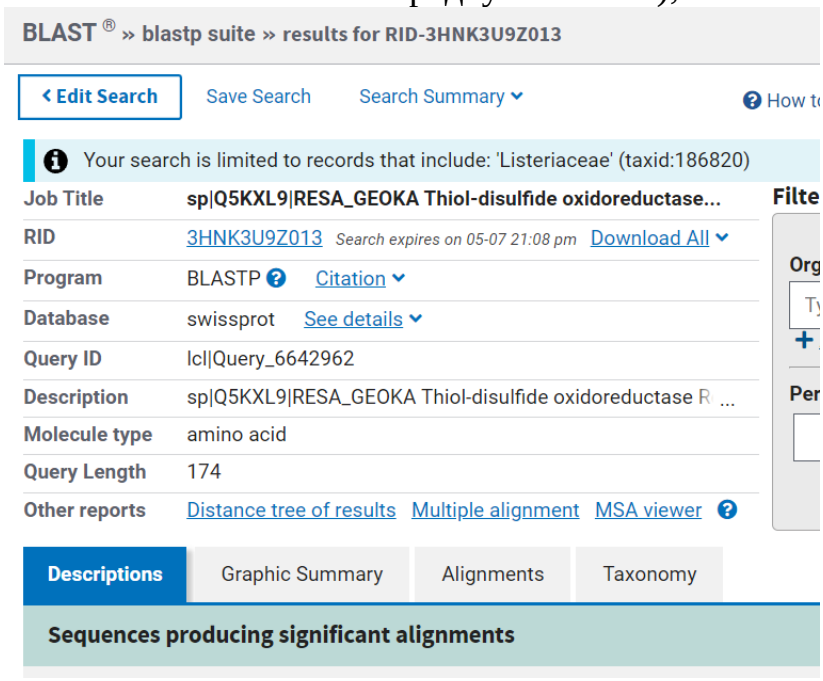
Clostridia (інший клас того ж відділу Firmicutes);



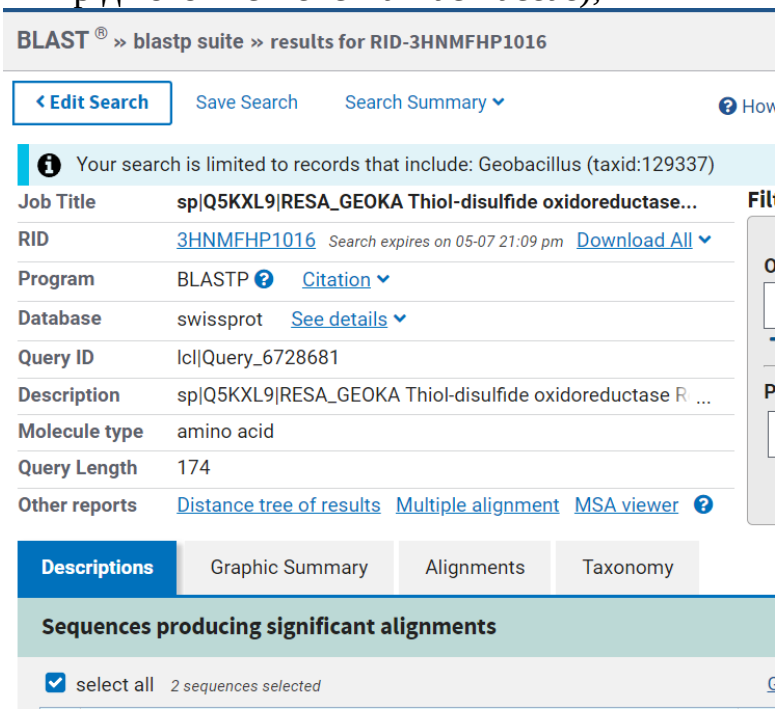
Lactobacillales (інший порядок того ж класу Bacilli);



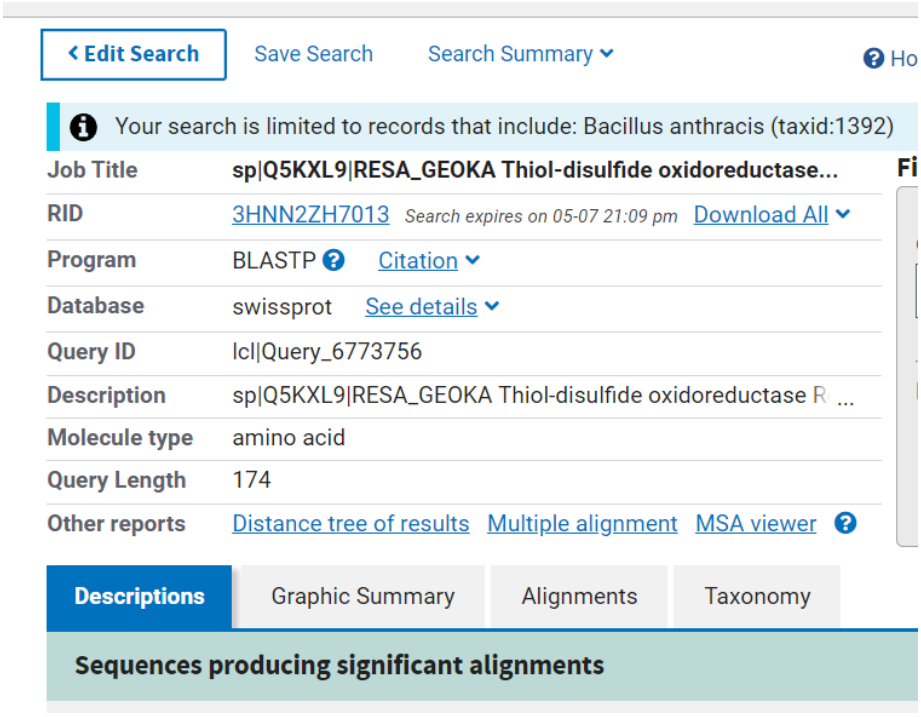
Listeriaceae (інше сімейство того же порядку Bacillales);



Geobacillus (інший рід того ж сімейства Bacillaceae);



Bacillus anthracis (інший вид того ж роду).



Гипотетичний гомолог	Arabidopsis thaliana
Знайдено в таксоні	Eukaryota
Accession	Q9LU86.1
E-value	1e-11
Вага (у бітах)	62.8 bits(151)
Ідентичність (%)	30.07%
Подібність (%)	48%
Довжина вирівнювання	174
Координати вирівнювання (від-до, у запиті і в знахідці)	36-95 69-129
Число гепів	12/143(8%)

OUTPUT FILE outfile

```
########################################
# Program: needle
# Rundate: Mon  6 May 2024 18:20:31
# Commandline: needle
#    -auto
#    -asequence /var/lib/emboss-explorer/output/811203/.asequence
#    -bsequence /var/lib/emboss-explorer/output/811203/.bsequence
#    -gapopen 10
#    -gapextend 0.5
#    -noendweight
#    -brief
#    -outfile outfile
#    -aformat3 srspair
# Align_format: srspair
# Report_file: outfile
########################################

#=======================================
#
# Aligned_sequences: 2
# 1: RESA_BACSU
# 2: STOA_BACSU
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 184
# Identity:      53/184 (28.8%)
# Similarity:    90/184 (48.9%)
# Gaps:          24/184 (13.0%)
# Score: 224.5
#
#
#=======================================

RESA_BACSU         1 MKKKRRLFIRTGILLVLICALGYTIYNAVFAGKESISEGSDA--PNFVLE     48
                     |..||      :|.:.|..||..   |.|.|.....|...|  ..|:::
STOA_BACSU         1 MLTKR-------LLTIYIMLLGLI---AWFPGAAQAEEKQPAVPAVFLMK     40

RESA_BACSU        49 DTNGKRIELSDLKGKGVFLNFWGTWCEPCKKEFPYMANQYKHFKSQGVEI     98
                     ...|:.|.:.: ||:...|:||.:||.|||||.|....:.|....|..|::
STOA_BACSU        41 TIEGEDISIPN-KGQKTILHFWTSWCPPCKKELPQFQSFYDAHPSDSVKL     89

RESA_BACSU        99 VAVNV---GESKIAVHNFMKSYGVNFPVVLDTDRQVLDAYDVSPLPTTFL    145
                     |.|||:   .:::..|.:|:|:...:||:|||:..::::..|.:..:||:||
STOA_BACSU        90 VTVNLVNSEQNQQVVEDFIKANKLTFPIVLDSKGELMKEYHIITIPTSFL    139

RESA_BACSU       146 INPEGKVVKVVTGTMTESMIHDYMNLIKPGETSG    179
                     :|.:|::.|...|.||...:.::...
STOA_BACSU       140 LNEKGEIEKTKIGPMTAEQLKEWTEE--------    165


#---------------------------------------
#---------------------------------------
```

OUTPUT FILE outfile

```
########################################
# Program: water
# Rundate: Mon  6 May 2024 18:20:26
# Commandline: water
#    -auto
#    -asequence /var/lib/emboss-explorer/output/848113/.asequence
#    -bsequence /var/lib/emboss-explorer/output/848113/.bsequence
#    -gapopen 10
#    -gapextend 0.5
#    -brief
#    -outfile outfile
#    -aformat3 srspair
# Align_format: srspair
# Report_file: outfile
########################################

#=======================================
#
# Aligned_sequences: 2
# 1: RESA_BACSU
# 2: STOA_BACSU
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 161
# Identity:      50/161 (31.1%)
# Similarity:    87/161 (54.0%)
# Gaps:           9/161 ( 5.6%)
# Score: 229.5
#
#
#=======================================

RESA_BACSU        13 ILLVLICALGYTIYNAVFAGKESISEGSDA--PNFVLEDTNGKRIELSDL     60
                     :|.:.|..||..   |.|.|.....|...|  ..|:::...|:.|.:.:
STOA_BACSU         6 LLTIYIMLLGLI---AWFPGAAQAEEKQPAVPAVFLMKTIEGEDISIPN-     51

RESA_BACSU        61 KGKGVFLNFWGTWCEPCKKEFPYMANQYKHFKSQGVEIVAVNV---GESK     107
                     ||:...|:||.:||.|||||.|...:.|....|..|::|.||:   .:::
STOA_BACSU        52 KGQKTILHFWTSWCPPCKKELPQFQSFYDAHPSDSVKLVTVNLVNSEQNQ     101

RESA_BACSU       108 IAVHNFMKSYGVNFPVVLDTDRQVLDAYDVSPLPTTFLINPEGKVVKVVT     157
                     ..|.:|:|:...:||:|||:..::::..|.:..:||:||:|.:|::.|...
STOA_BACSU       102 QVVEDFIKANKLTFPIVLDSKGELMKEYHIITIPTSFLLNEKGEIEKTKI     151

RESA_BACSU       158 GTMTESMIHDY    168
                     |.||...:.::
STOA_BACSU       152 GPMTAEQLKEW    162
```

	BLASTP	Needle (глобальне)	Water (локальне)
Вага	85.1 bits(209)	224.5	229.5
Довжина вирівнювання	165	184	161
Ідентичність (%)	38/129(29%)	53/184 (28.8%)	50/161 (31.1%)
Подібність (%)	77/129(59%)	90/184 (48.9%)	87/161 (54.0%)
Число гепів	4/129(3%)	24/184 (13.0%)	9/161 (5.6%)

Як можемо побачити, ми отримали дані що відрізняються, це тому що вони використовують різні алгоритми.

Висновок

У ході виконання лабораторної роботи №3 був виконаний пошук гіпотетичних гомологів досліджуваного білка в різних базах даних (swissprot, pdb, nr) та визначали різницю між ними. Після чого було зробленно порівняння Water та Needle.