МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»
ІНСТИТУТ ПРИКЛАДНОГО СИСТЕМНОГО АНАЛІЗУ

Лабораторна робота №1
з дисципліни “Теорія інформації і кодування”
на тему: “Визначення кількості інформації в дискретних повідомленнях”

Виконав:
студент III курсу
групи ДА-11
Сидько Н.С.

Київ-2023

Мета роботи: вивчення алгоритмів визначення кількості інформації в дискретних повідомленнях, оцінка надмірності повідомлень, розробка програми для дослідження ефективності кодування текстових даних у файлах довільної довжини.

Програма роботи

1. Ознайомитися з методикою визначення кількості інформації в дискретних повідомленнях

2. Використовуючи табличний процесор MS Excel визначити кількість інформації, що міститься в текстовому повідомленні, що складається з вашого прізвища, імені і по батькові. При цьому необхідно обчислити середню ентропію на символ кодованого повідомлення і середню довжину кодових комбінацій, необхідних для кодування кожного символу повідомлення. Знайти кількість інформації, що міститься в кодованому повідомленні, абсолютну і відносну надмірність повідомлення за умови кодування кожної букви повідомлення одним байтом.

3. Розробити програму на мові програмування високого рівня для обчислення ентропії та кількості інформації, що міститься в текстових файлах довільної довжини, максимально можливої ентропії за умови однакової імовірності символів алфавіту, абсолютної і відносної надмірності файлів. При вводі текстових даних передбачити два режиму вводу кодів: введення з клавіатури, а також введення даних з текстового файлу з використанням однобайтових кодових таблиць. За допомогою розробленої програми перевірити дані, отримані при виконанні п.3.2.

4.За допомогою розробленої при виконанні п.3.2 програми дослідити залежність ентропії від довжини тексту, а також залежність ентропіїї від мови. Для цього за допомогою доступних програм автоматичного перекладу підготувати однакові текстові файли на різних мовах (наприклад, англійська, українська, російська) різної довжини, для яких провести дослідження.

Хід роботи

В якості основної характеристики повідомлення теорія інформації використовує величину, яка називається кількістю інформації. Це поняття не зачіпає сенсу і важливості передаваного повідомлення, а пов'язано із ступенем його невизначеності.

Створимо таблицю з інформацією про алфавіт, визначимо кількість повторів символів, ймовірність і ентропію кожного символу

	A	B	C	D	E
1	Sydko Nikita Sergeevich				
2	Symbols	amount	P[i]	log(P[i])	entropy
3	space	2	0,086956522	-3,523561956	-0,306396692
4	n	1	0,043478261	-4,523561956	-0,196676607
5	s	2	0,086956522	-3,523561956	-0,306396692
6	a	1	0,043478261	-4,523561956	-0,196676607
7	c	1	0,043478261	-4,523561956	-0,196676607
8	d	1	0,043478261	-4,523561956	-0,196676607
9	e	3	0,130434783	-2,938599455	-0,383295581
10	g	1	0,043478261	-4,523561956	-0,196676607
11	h	1	0,043478261	-4,523561956	-0,196676607
12	i	3	0,130434783	-2,938599455	-0,383295581
13	k	2	0,086956522	-3,523561956	-0,306396692
14	o	1	0,043478261	-4,523561956	-0,196676607
15	r	1	0,043478261	-4,523561956	-0,196676607
16	t	1	0,043478261	-4,523561956	-0,196676607
17	v	1	0,043478261	-4,523561956	-0,196676607
18	y	1	0,043478261	-4,523561956	-0,196676607
19					
20	Summary	23	1	-66,2070663	3,849223912

Табл.1

Зробимо обрахунки кількості інформації, максимального значення ентропії, абсолютної та відносної надмірності.
n – всього букв
m – унікальні букви
H – ентропія
I – кількість інформації

23	Amount information	I = n*H	88,53214998
24	Max entropy	Log(m)	4
25	Абсолютна надмірність	H(max)-H	0,150776088
26	Відносна надмірність	(H(max)-H)/H	0,039170516
27			

Розробимо програму на мові програмування високого рівня C++ для обчислення ентропії та кількості інформації, що міститься в текстових файлах

довільної довжини, максимально можливої ентропії за умови однакової імовірності символів алфавіту, абсолютної і відносної надмірності файлів.

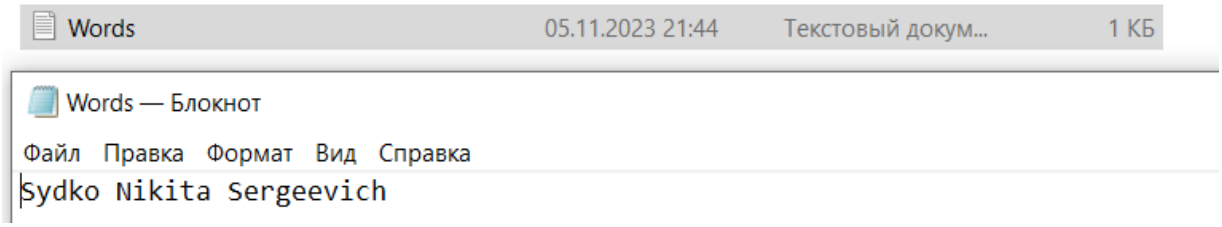


Рис.1 Дані з файлу

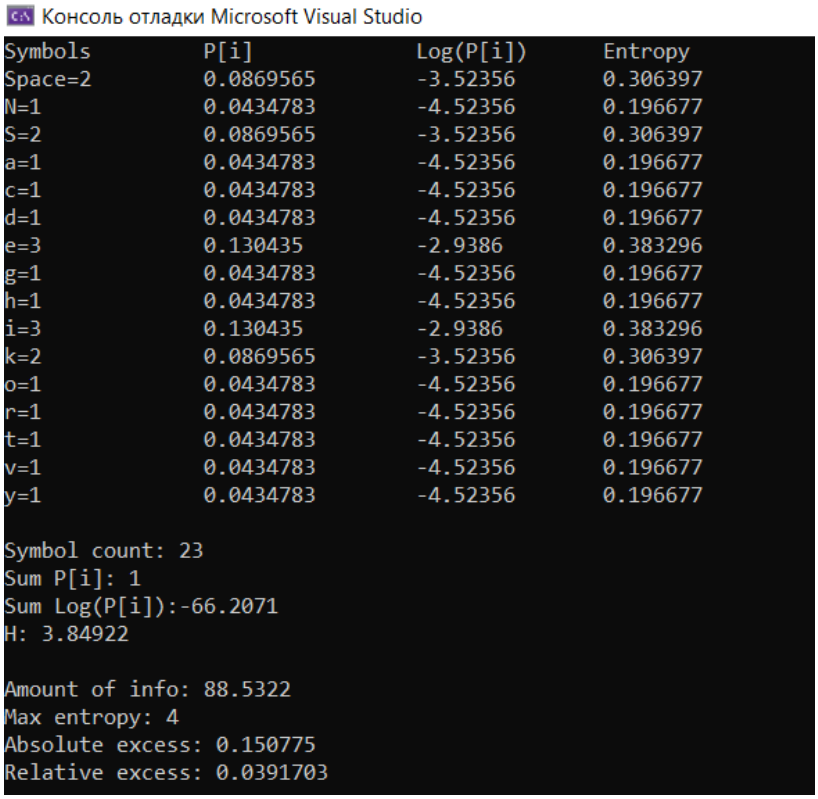


Рис.2 Результат роботи коду

Дослідимо залежність ентропії від довжини тексту, а також залежність ентропіїї від мови.

Для прикладу оберемо англійську та українську мови.

Мова	Англійська	Українська
Ентропія	3.84922	3.97017

За умови введеня у текстовий файл слів на англійській мові, отримуємо наступні залежності ентропії від довжини файлу

Довжина файлу	24 байт	34 байт	50 байт

Ентропія	3.85	3.98	4.32

Висновок

У ході виконання лабораторної роботи №1 було вивчено алгоритми визначення кількості інформації в дискретних повідомленнях, оцінку надмірності повідомлень, а також розроблено програму для дослідження ефективності кодування текстових даних у файлах довільної довжини. Використовуючи табличний процесор Excel було обраховано кількість інформації, що міститься в текстовому повідомленні, що складається з ПІБ. Також було обчислено середню ентропію на символ кодованого повідомлення. На мові програмування високого рівня C++ було написано програму для обчислення ентропії та кількості інформації, що міститься в текстових файлах довільної довжини, максимально можливої ентропії за умови однакової імовірності символів алфавіту, абсолютної і відносної надмірності файлів.

Лістинг до коду

```
#include <iostream>
#include <fstream>
#include <map>
#include "Windows.h"
int main()
{
    SetConsoleCP(1251);
    SetConsoleOutputCP(1251);

    std::map<char, int> charCount;
    char character;
    int all_char = 0;
    float PiSUM = 0;
    float LogSUM = 0;
    float EntrSUM = 0;

    std::ifstream inputFile("Words.txt", std::ios::binary);

    if (!inputFile.is_open())
    {
        std::cerr << "Unable to open file." << std::endl;
        return 1;
    }


    while (inputFile.get(character))
    {
        charCount[character]++;
        all_char++;
    }

    inputFile.close();

    std::cout << "Symbols " << "\tP[i] " << "\t\t Log(P[i]) " << "\tEntropy" <<
std::endl;
    for (const auto& pair : charCount) {
        PiSUM = PiSUM + float(pair.second) / all_char;
        LogSUM = LogSUM + log2(float(pair.second) / all_char);
```

```
        EntrSUM = EntrSUM + float(pair.second) / all_char *
log2(float(pair.second) / all_char);

        if (pair.first == ' ') {
            std::cout << "Space" << "=" << pair.second << "\t\t" <<
float(pair.second) / all_char << "\t " << log2(float(pair.second) / all_char) <<
"\t" << -1 * float(pair.second) / all_char * log2(float(pair.second) / all_char)
<< std::endl;
        }
        else {
            std::cout << pair.first << "=" << pair.second << "\t\t" <<
float(pair.second) / all_char << "\t " << log2(float(pair.second) / all_char) <<
"\t" << -1 * float(pair.second) / all_char * log2(float(pair.second) / all_char)
<< std::endl;
        }
    }

    EntrSUM = EntrSUM * (-1);
    std::cout << std::endl;
    std::cout << "Symbol count: " << all_char << std::endl;
    std::cout << "Sum P[i]: " << PiSUM << std::endl;
    std::cout << "Sum Log(P[i]): " << LogSUM << std::endl;
    std::cout << "H: " << EntrSUM << std::endl;
    std::cout << std::endl;

    std::cout << "Amount of info: " << all_char * EntrSUM << std::endl;
    std::cout << "Max entropy: " << log2(charCount.size()) << std::endl;
    std::cout << "Absolute excess: " << log2(charCount.size()) - EntrSUM <<
std::endl;
    std::cout << "Relative excess: " << (log2(charCount.size()) - EntrSUM) /
EntrSUM << std::endl;

    return 0;
}
```