МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ» ННК «ІПСА»

Кафедра системного проектування

РОЗРАХУНКОВО-ГРАФІЧНА РОБОТА № 2

з дисципліни

«ТЙ та МС»

Виконав студент

групи ДА-11

Сидько Нікіта

22 Варіант

Київ – 2023

Завдання

1. Проведіть первинний аналіз вибірки. Це включає статистичний ряд (для неперервних розподілів - інтервальний), емпіричну функцію розподілу (для неперервних розподілів - інтервальну), її графік, полігон частот (для дискретних розподілів), гістограму (для неперервних розподілів).

2. Знайдіть вибіркове середнє, вибіркову дисперсію, виправлену вибіркову дисперсію, вибіркову медіану, вибіркову моду, вибіркові коефіцієнти асиметрії та ексцесу.

3. Обгрунтуйте та висуньте (нову) гіпотезу про розподіл генеральної сукупності.

4. Методом моментів та методом максимальної вірогідності знайдіть оцінки параметрів розподілу.

5. Для кожного параметра кращу з цих двох оцінок перевірте на (асимптотичну) незміщеність, конзистентність та ефективність.

6. Побудуйте довірчі інтервали з рівнем надійності 0.95 для параметрів розподілу.

7. Нарешті, перевірте висунуту гіпотезу про розподіл генеральної сукупності за допомогою крітерію Якщо гіпотеза суперечить вибірковим даним, перейдіть до п. 3.

8. Проявіть усі свої літературні здібності та напишіть висновок.

Маємо наступну вибірку :

```
Варіант №22

 2  1  4  3  2  0  1  2  1  0  3  2  4  0  2  0  5  3  0  0  2  1  2  2  0
 2  2  3  2  5  2  0  1  2  1  0  1  3  1  0  1  0  1  1  1  1  2  0  0  1
 1  1  0  0  0  1  4  1  2  1  2  1  1  2  2  1  4  2  2  1  2  1  1  0  1
 0  0  0  2  1  1  0  1  0  1  1  0  6  0  1  2  1  4  2  3  2  0  4  0  2
```

1) Первинний аналіз вибірки.

- Статистичний ряд (для неперервних розподілів - інтервальний),
- Емпіричну функцію розподілу (для неперервних розподілів - інтервальну), її графік,
- Полігон частот (для дискретних розподілів),
- Гістограму (для неперервних розподілів).

Побудуємо варіаційний ряд вибірки (тут і далі буде наведений код частинами, повний код програми наведений у Лістинг1) :

```
import numpy as np
import pandas
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as stats

pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
file_path = r'D:\OperaDownloads\rgr\rgr2.xlsx'

df_import = pd.read_excel(file_path, engine="openpyxl", usecols=["Дані"])
l = [x for x in df_import['Дані'].tolist() if type(x) == int]

df = pd.DataFrame({'Варіаційний ряд': sorted(l)})
print(df)
```

Результат роботи цієї частини коду:

```
    Варіаційний ряд
0                 0
1                 0
2                 0
3                 0
4                 0
5                 0
6                 0
7                 0
8                 0
9                 0
10                0
11                0
12                0
13                0
14                0
15                0
16                0
17                0
```

18	0
19	0
20	0
21	0
22	0
23	0
24	0
25	0
26	1
27	1
28	1
29	1
30	1
31	1
32	1
33	1
34	1
35	1
36	1
37	1
38	1
39	1
40	1
41	1
42	1
43	1
44	1
45	1
46	1
47	1
48	1
49	1
50	1
51	1
52	1
53	1
54	1
55	1
56	1
57	1
58	1
59	2
60	2
61	2
62	2
63	2
64	2
65	2
66	2
67	2
68	2
69	2
70	2
71	2
72	2
73	2
74	2
75	2
76	2
77	2
78	2
79	2
80	2
81	2
82	2
83	2
84	2
85	3
86	3
87	3
88	3
89	3
90	3
91	4
92	4
93	4
94	4
95	4
96	4
97	5
98	5
99	6

Бачимо, що в нас наявні повторення значень, тоді можемо зробити висновок, шо в нас дискретний розподіл

Проаналізуємо вибірку та знайдемо наступні значення:

- Об’єм
- Мінімальний елемент
- Максимальний елемент
- Розмах вибірки

За це в нас відповідає наступна частина коду :

```
df_info = pd.DataFrame({
    "Об'єм вибірки": [len(l)],
    "Мінімальний елемент": [min(l)],
    "Максимальний елемент": [max(l)],
    "Розмах вибірки": [max(l) - min(l)]
})
print("\n")
df_info_string = df_info.to_string(index=False)
print(df_info_string)
print("\n")
```

Результат роботи цієї частини коду:

```
Об'єм вибірки  Мінімальний елемент  Максимальний елемент  Розмах вибірки
          100                    0                     6               6
```

Маючи дискретний розподіл, ми побудуємо статистичний ряд :

```
df_stat_dist = pd.DataFrame({'Значення': df['Варіаційний ряд'].unique(),
                             'Частоти': df['Варіаційний
ряд'].value_counts(sort=False),
                             'Кумулятивні частоти': df['Варіаційний
ряд'].value_counts(sort=False).cumsum(),
                             'Відносні частоти': df['Варіаційний
ряд'].value_counts(normalize=True, sort=False),
                             'Кумулятивні відносні частоти': df['Варіаційний
ряд'].value_counts(normalize=True, sort=False).cumsum()})

df_stat_dist_str = df_stat_dist.to_string(index=False, justify='left')
print(df_stat_dist_str)
print("\n")
```

Результат роботи цієї частини коду :

```
Значення  Частоти  Кумулятивні частоти  Відносні частоти  Кумулятивні відносні частоти
0         26        26                   0.26              0.26
1         33        59                   0.33              0.59
2         26        85                   0.26              0.85
3          6        91                   0.06              0.91
4          6        97                   0.06              0.97
5          2        99                   0.02              0.99
6          1       100                   0.01              1.00
```

Побудуємо емпіричну функцію розподілу

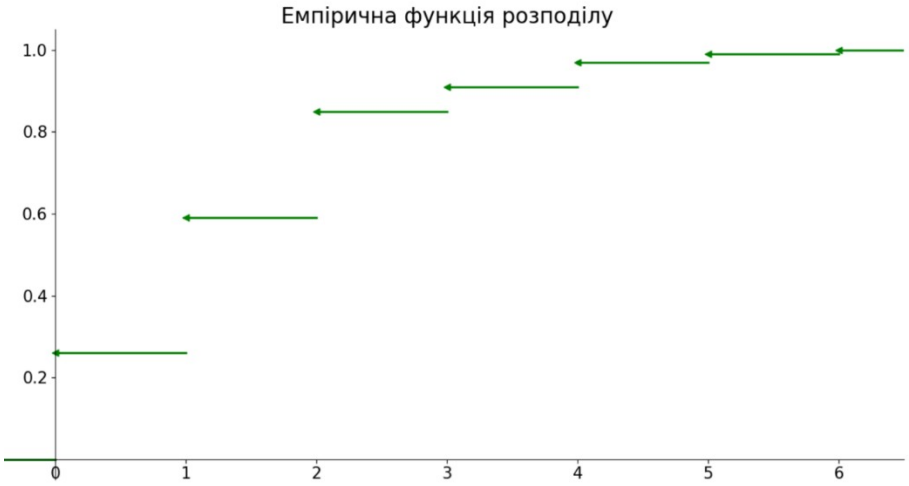
```
def plot_empirical_cdf(x_sample, y_sample):
    plt.plot([x_sample[0] - 0.5, x_sample[0]], [0, 0], linewidth=2, color='g')
    for i in range(len(x_sample)-1):
        plt.plot([x_sample[i], x_sample[i+1]],[y_sample[i], y_sample[i]],
linewidth=2, color='g')
        plt.scatter(x_sample[i], y_sample[i], marker='<', color='g')
    plt.plot([x_sample[len(x_sample)-1], x_sample[len(x_sample)-1] + 0.5], [1,
1], linewidth=2, color='g')
    plt.scatter(x_sample.max(), 1, marker='<', color='g')
    plt.show()

fig, ax = plt.subplots(figsize=(12, 4))
ax.spines['right'].set_visible(False)
ax.spines['top'].set_visible(False)
ax.spines['left'].set_position('zero')
ax.spines['bottom'].set_position('zero')
ax.xaxis.set_tick_params(labelsize=15)
ax.yaxis.set_tick_params(labelsize=15)
ax.set_xlim(df_stat_dist['Значення'].min() - 0.5, df_stat_dist['Значення'].max()
+ 0.5)
ax.set_yticks([0.2, 0.4, 0.6, 0.8, 1])

ax.set_title('Емпірична функція розподілу', fontsize=20)
plot_empirical_cdf(df_stat_dist['Значення'],         df_stat_dist['Кумулятивні

відносні частоти'])
```

Результат роботи коду :



У нас дискретний розподіл, тоді ми маємо побудувати полігон частот :

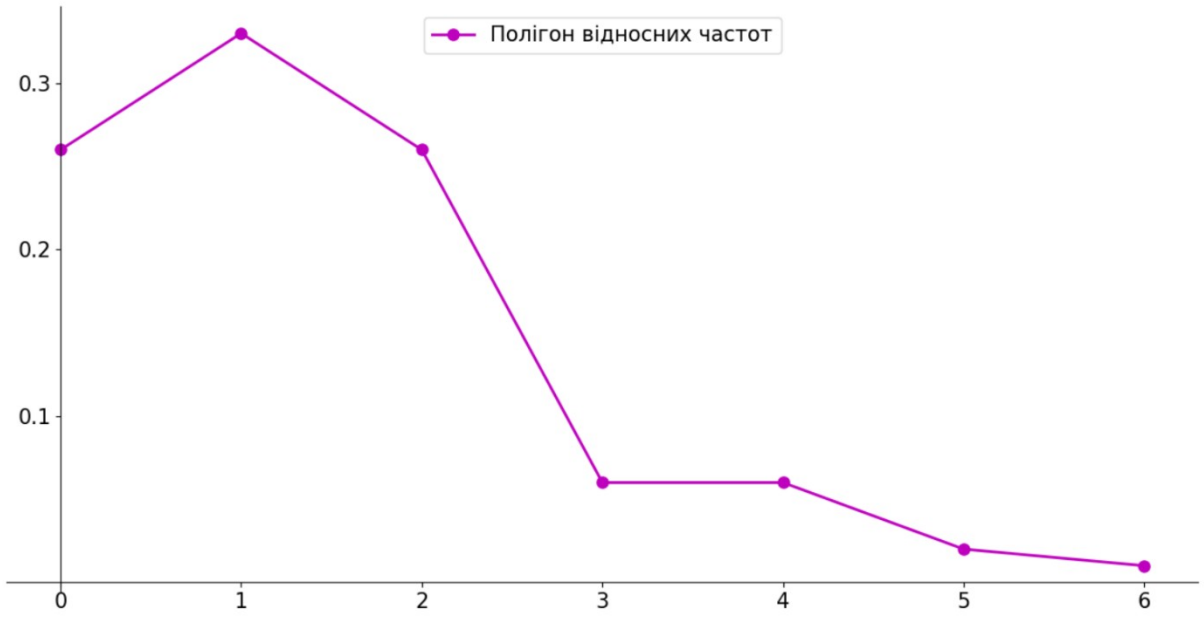
```
fig, ax = plt.subplots(figsize=(12, 4))
ax.spines['right'].set_visible(False)
ax.spines['top'].set_visible(False)
ax.spines['left'].set_position('zero')
ax.spines['bottom'].set_position('zero')
ax.xaxis.set_tick_params(labelsize=15)
```

```
ax.yaxis.set_tick_params(labelsize=15)
ax.set_yticks([0.1, 0.2, 0.3, 0.4, 0.5])

ax.plot(df_stat_dist['Значення'], df_stat_dist['Відносні частоти'],
        'o-', linewidth=2, markersize=8, color='m', label='Полігон відносних
частот')

ax.legend(fontsize=15, loc=9)
plt.show()
```

Результат роботи коду :



2) Вибіркові характеристики

- Знайдіть вибіркове середнє
- Вибіркову дисперсію
- Виправлену вибіркову дисперсію
- Вибіркову медіану
- Вибіркову моду
- Вибіркові коефіцієнти асиметрії та ексцесу

```
df_info['Вибіркове середнє'] = np.mean(df['Варіаційний ряд'])
df_info['Вибіркова дисперсія'] = np.var(df['Варіаційний ряд'])
df_info['Виправлена вибіркова дисперсія'] = np.var(df['Варіаційний ряд'], ddof=1)
df_info['Вибіркова медіана'] = np.median(df['Варіаційний ряд'])
df_info['Вибіркова мода'] = stats.mode(df['Варіаційний ряд'])[0]
df_info['Вибірковий коефіцієнт асиметрії'] = stats.skew(df['Варіаційний ряд'])
df_info['Вибірковий коефіцієнт ексцесу'] = stats.kurtosis(df['Варіаційний ряд'])
```

```
columns_order = ['Вибіркове середнє', 'Вибіркова дисперсія', 'Виправлена вибіркова дисперсія','Вибіркова медіана', 'Вибіркова мода', 'Вибірковий коефіцієнт асиметрії', 'Вибірковий коефіцієнт ексцесу']

print(df_info[columns_order].to_string(index=False))
```

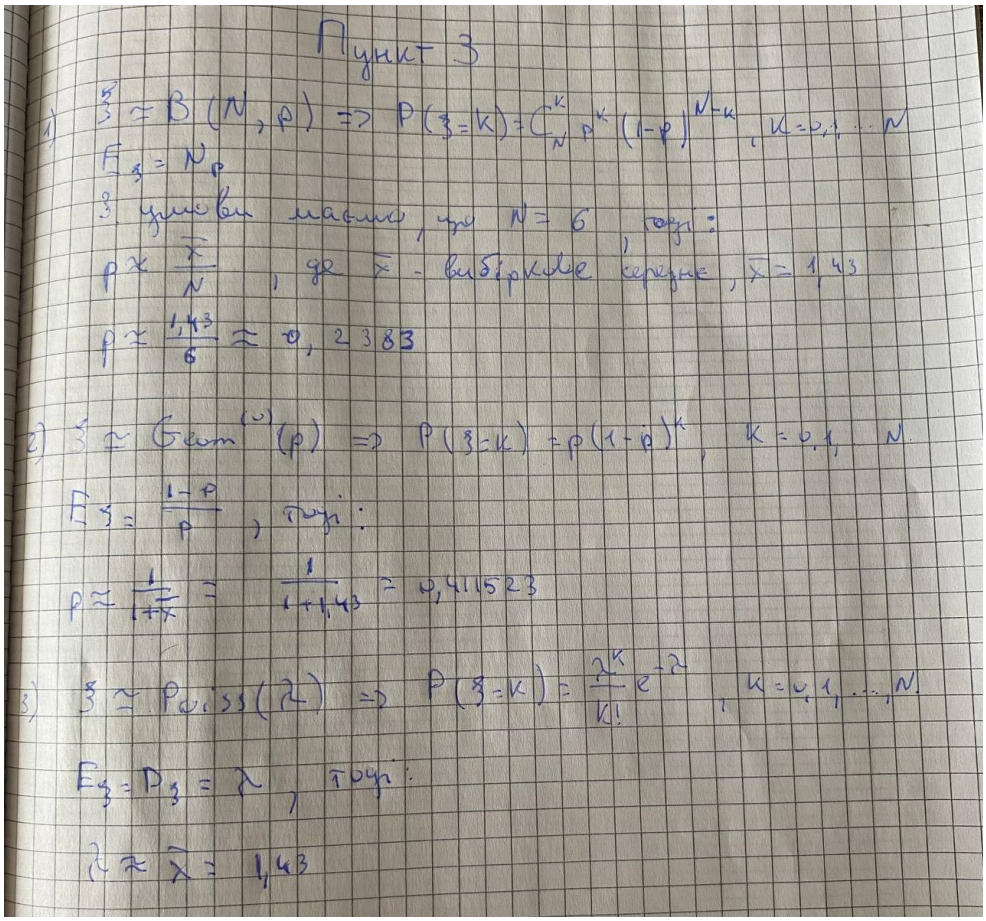
Результат роботи цієї частини коду:

Вибіркове середнє	Вибіркова дисперсія	Виправлена вибіркова дисперсія	Вибіркова медіана
1.43	1.6851	1.702121	1.0

Вибіркова мода	Вибірковий коефіцієнт асиметрії	Вибірковий коефіцієнт ексцесу
1	1.086522	1.126839

3) Спробуємо висунути гіпотезу про розподіл генеральної сукупності. Ми маємо дискретний розподіл. Порівняємо вигляд полігону відносних частот із відомими дискретними розподілами:

- Біноміальним,
- Геометричним
- Пуассона.



Зробимо графіки кожного з розподілів, і порівняємо з нашим.

```
fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(15, 5), sharey=True)
fig.tight_layout()
for i in range(3):
    ax[i].spines['right'].set_visible(False)
    ax[i].spines['top'].set_visible(False)
    ax[i].spines['left'].set_position('zero')
    ax[i].spines['bottom'].set_position('zero')

x = df_stat_dist['Значення']
y0 = stats.binom.pmf(x, 6, 0.238333333)
y1 = stats.geom.pmf(x, 0.411523, loc=-1)
y2 = stats.poisson.pmf(x, 1.43)

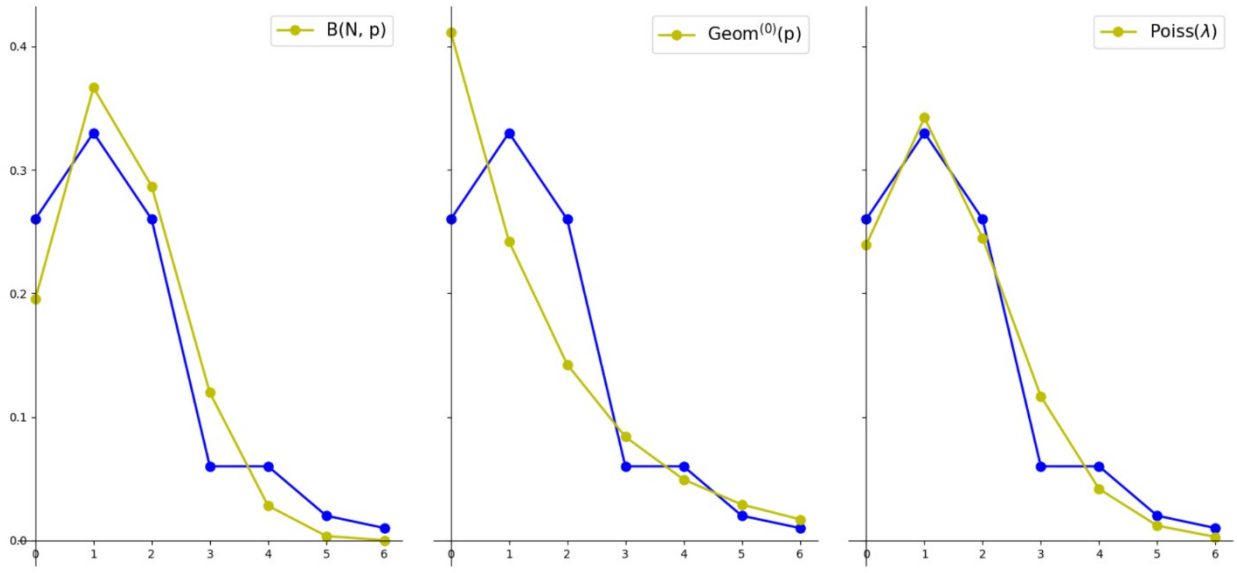

ax[0].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
ax[0].plot(x, y0, 'o-', linewidth=2, markersize=8, color='y', label='B(N, p)')
ax[0].legend(fontsize=15)

ax[1].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
ax[1].plot(x, y1, 'o-', linewidth=2, markersize=8, color='y', label=r'Geom$^{(0)}
$(p)')
ax[1].legend(fontsize=15)

ax[2].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
ax[2].plot(x, y2, 'o-', linewidth=2, markersize=8, color='y', label=r'Poiss($\
lambda$)')
ax[2].legend(fontsize=15)

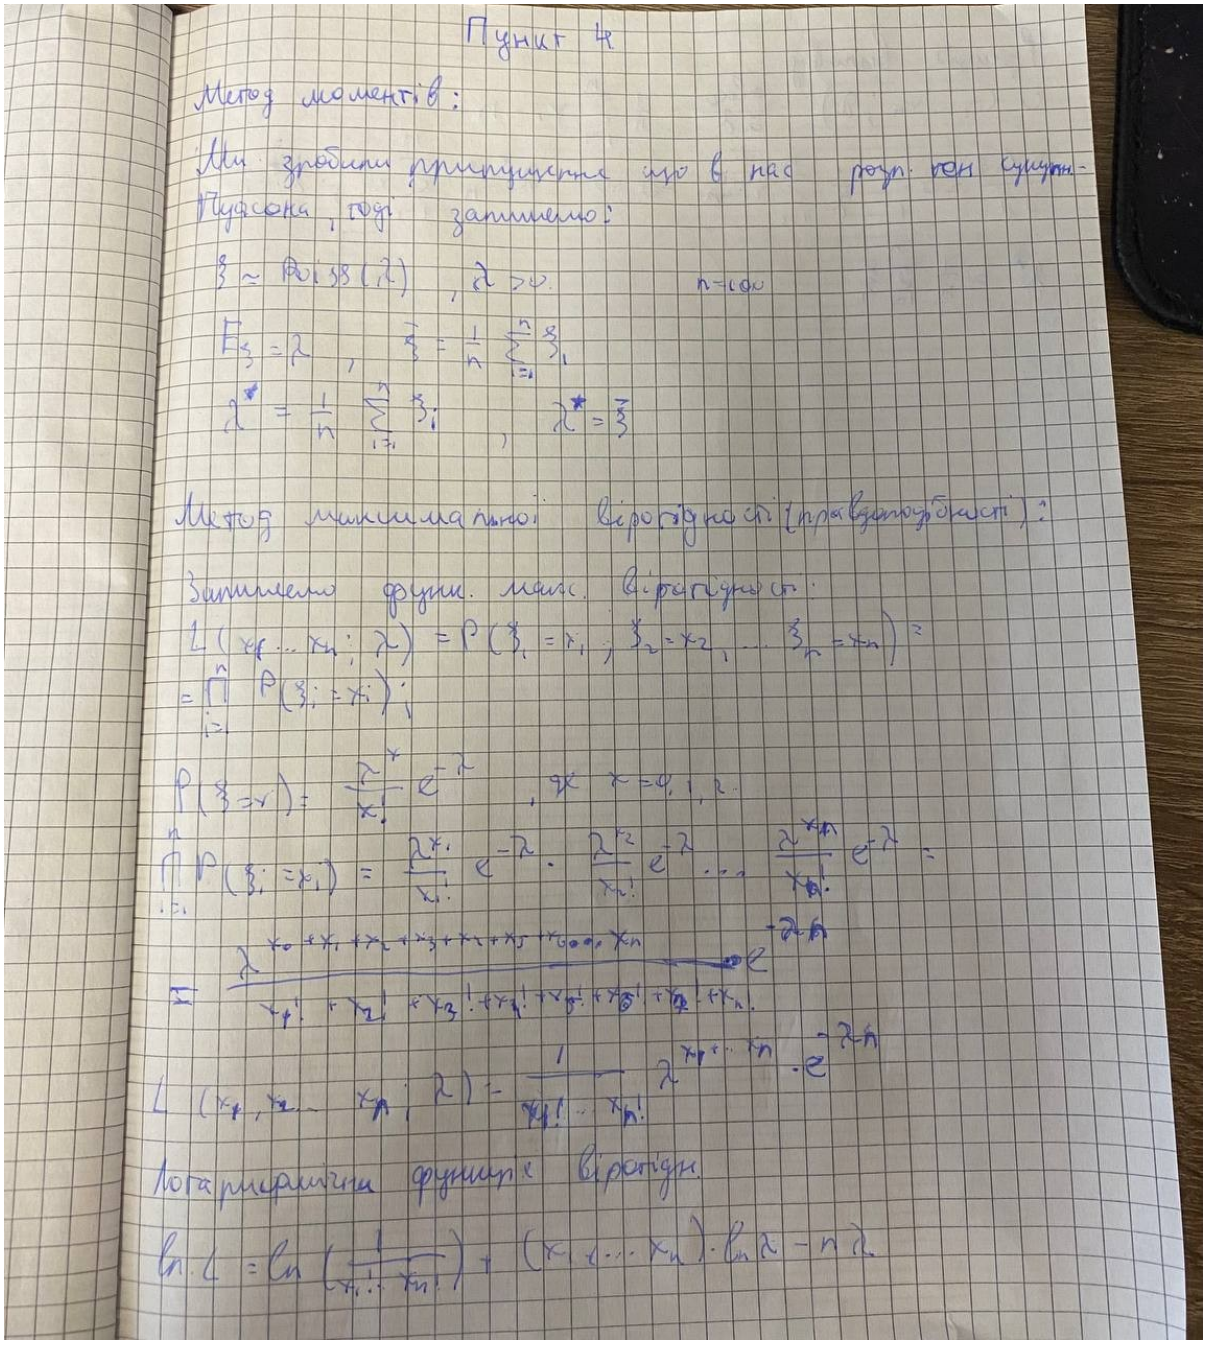
plt.show()
```

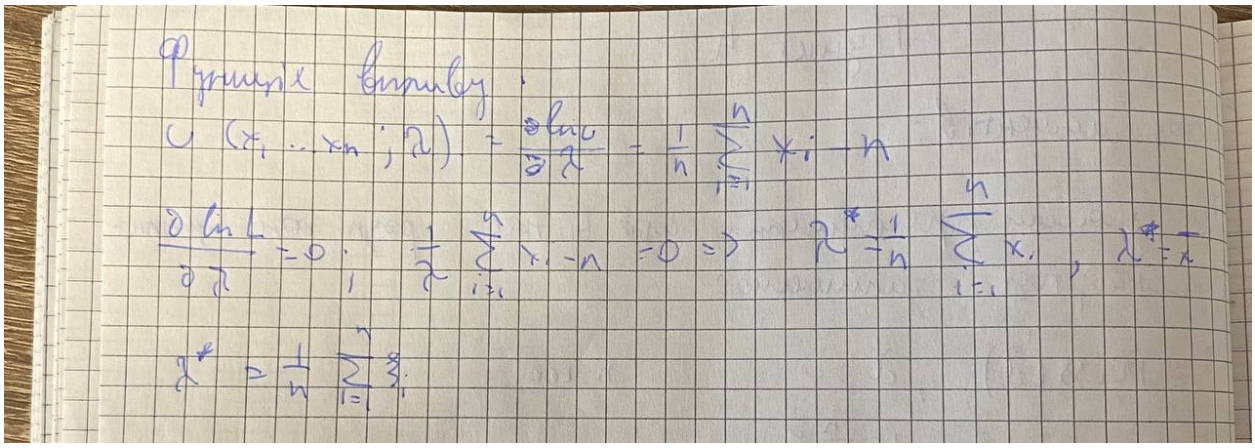
Результат роботи цієї частини коду :



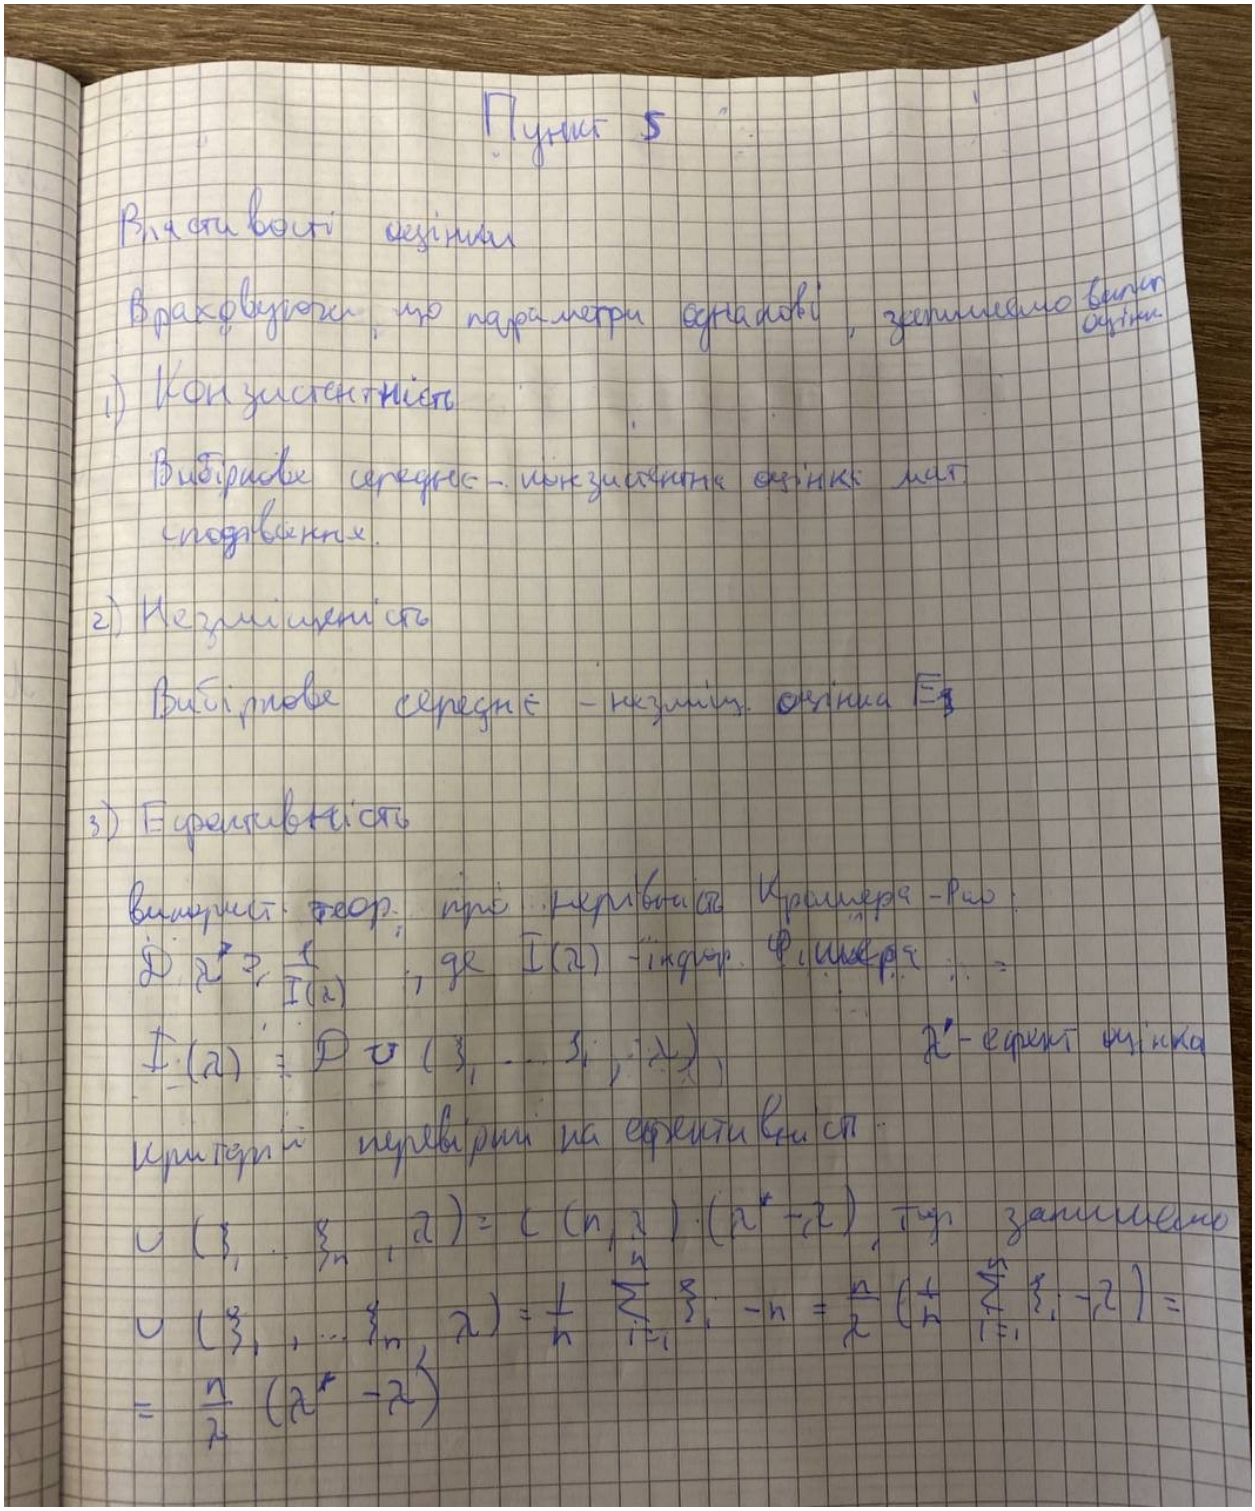
З графіків, можна зробити припущення, що в нас розподіл генеральної сукупності – Пуассона

4) Методом моментів та методом максимальної вірогідності знайти оцінки параметрів розподілу.





5) Для кожного параметра кращу з цих двох оцінок перевірте на (асимптотичну) незміщеність, конзистентність та ефективність.



Пункт 5

Властивості оцінки

Враховуючи, що параметри однакові, зручніше взяти оцінку

1) Конзистентність

Вибіркове середнє - конзистентна оцінка має сподівання.

2) Незміщеність

Вибіркове середнє - незміщ. оцінка $E\xi$

3) Ефективність

Використ. теор. про нерівність Крамера-Рао:

$D\lambda^* \geq \frac{1}{I(\lambda)}$, де $I(\lambda)$ - інформ. Фішера

$I(\lambda) = D\upsilon(\xi_1, \dots \xi_n, \lambda)$, λ^* - ефект. оцінка

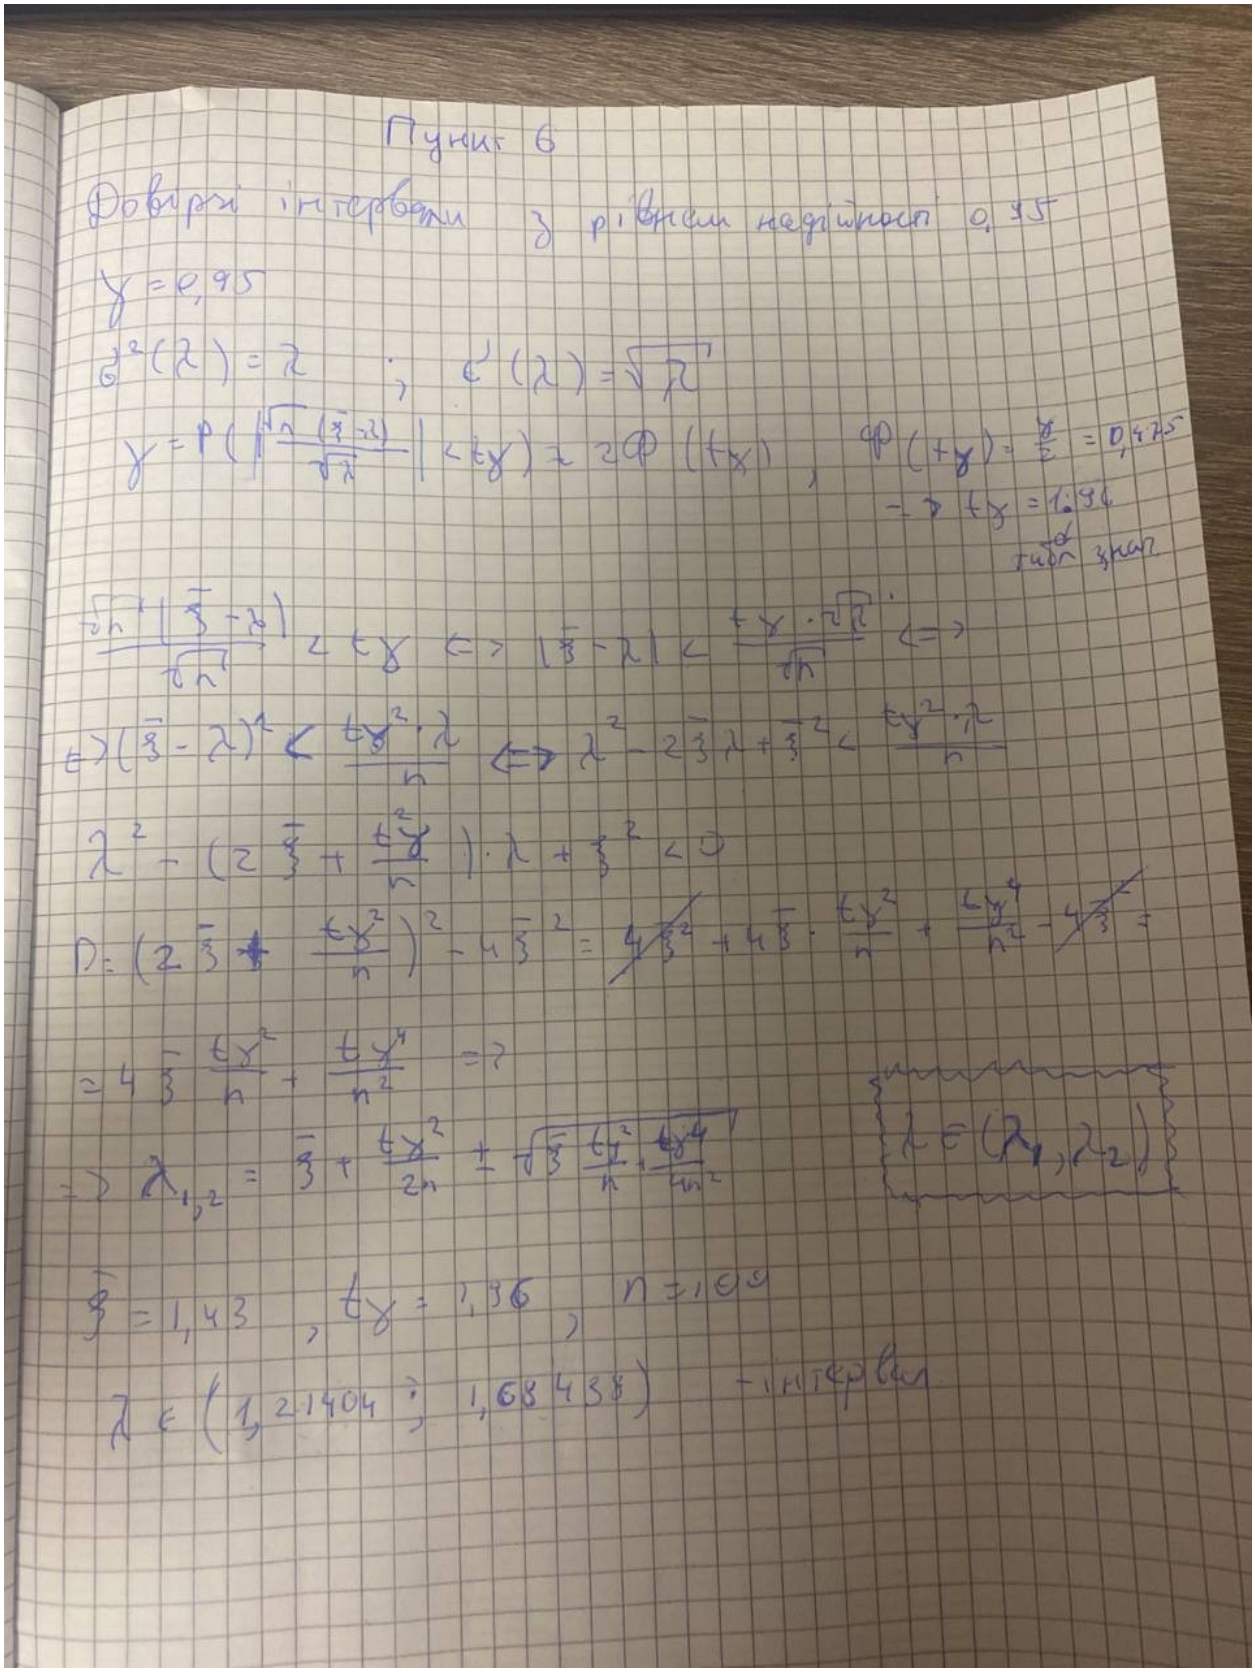
Критерій перевірки на ефективність:

$\upsilon(\xi_1, \dots \xi_n, \lambda) = C(n, \lambda)\cdot(\lambda^* - \lambda)$, тут запишемо

$\upsilon(\xi_1, \dots \xi_n, \lambda) = \frac{1}{n}\sum_{i=1}^{n}\xi_i - n = \frac{n}{\lambda}\left(\frac{1}{n}\sum_{i=1}^{n}\xi_i - \lambda\right) =$

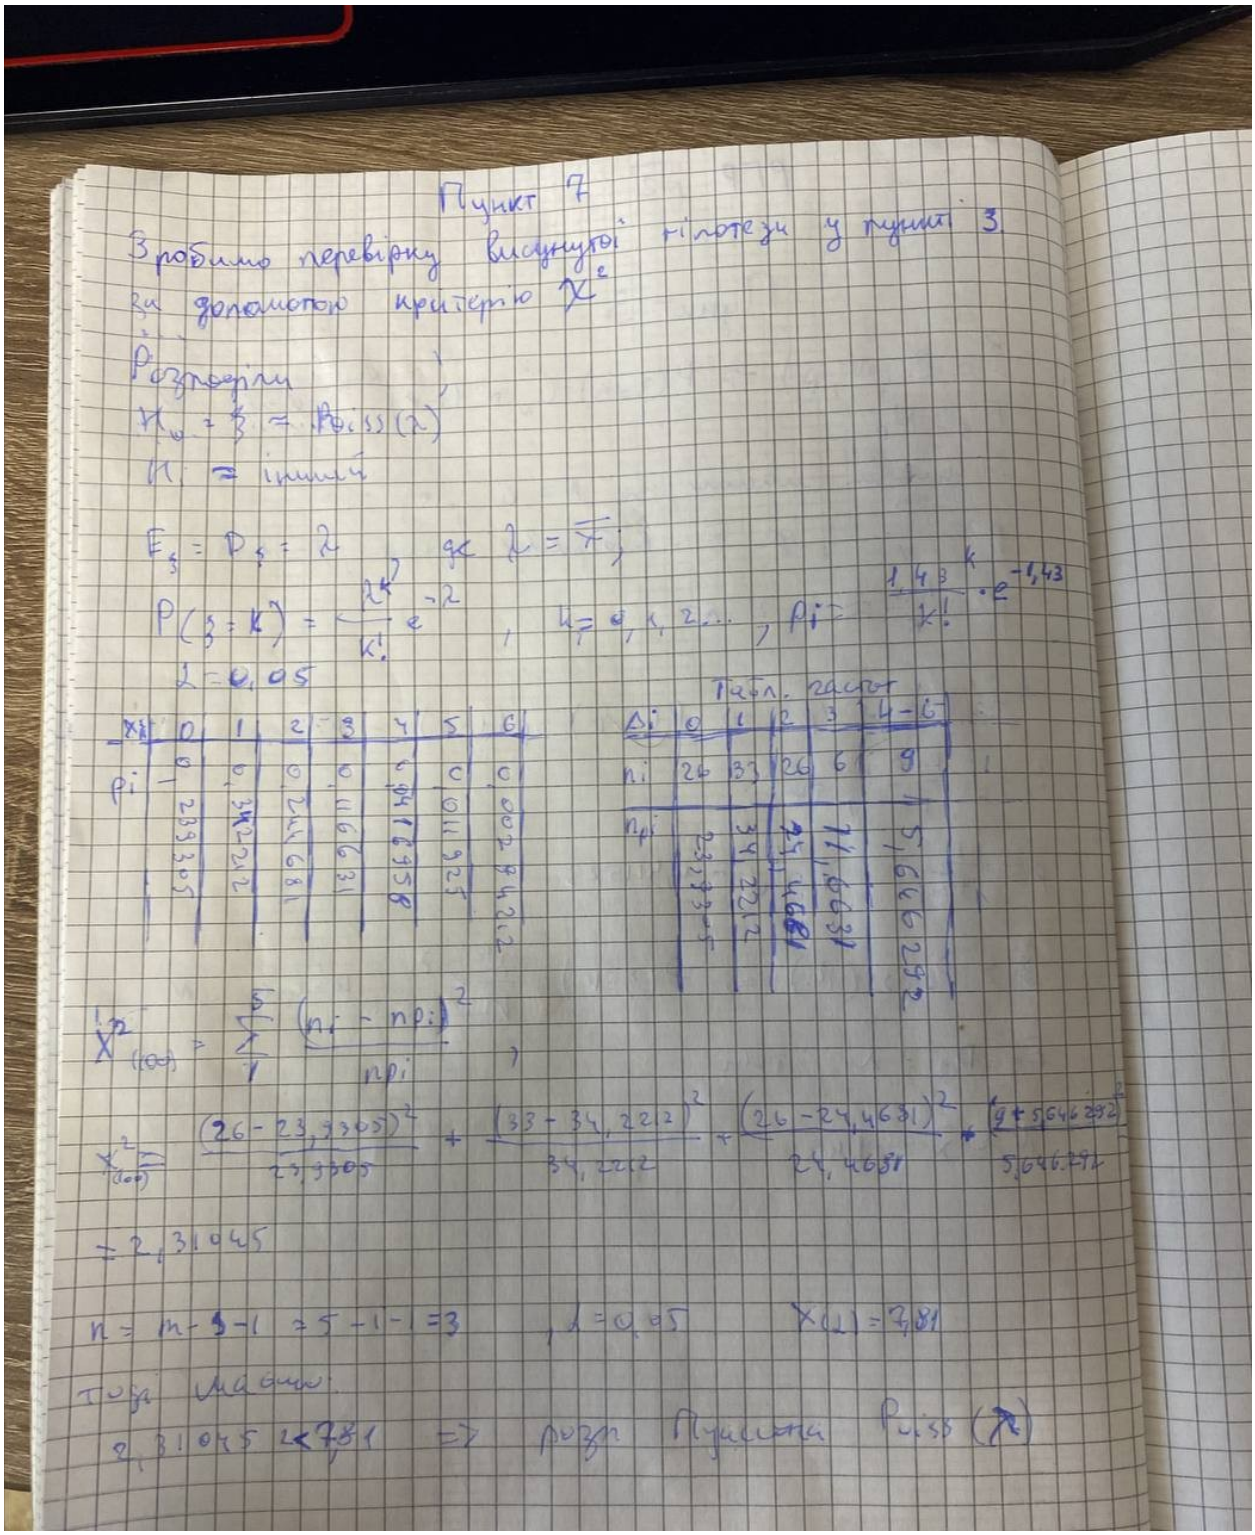
$= \frac{n}{\lambda}(\lambda^* - \lambda)$

6) Побудувати довірчі інтервали з рівнем надійності 0.95 для параметрів розподілу



7. Перевірка висунутої гіпотези про розподіл генеральної сукупності за допомогою крітерію

Слід зазначити, що значення *a* та X_a бралися з таблички (з лекції)



8. Висновок.

У ході виконання розрахункової роботи № 2 було досліджено задану за варіантом вибірку, було це досить таки непросто. Проаналізувавши вибірку, спочатку зробили висновок що в неї дискретний тип розподілу.

Ми провели її первинний аналіз, що включав в себе :

- статистичний ряд
- емпіричну функцію розподілу і її графік
- полігон частот

Після чого були знайдені такі наступні вибіркові характеристики як : вибіркове середнє, дисперсію медіану моду коефіцієнти асиметрії та ексцесу.

Було висунуто гіпотезу про те, що ГС є розподілом Пуассона, і у пункті 7 ми це перевірили за допомогою критерію X^2. Також знайдено оцінку параметра методами моментів та максимальної вірогідності, після чого перевірили властивості цієї оцінки після чого використовуючи матеріал з практичного заняття знайшли довірчий інтервал з рівнем надійності 0.95.

Для виконання роботи було використано мову програмування Python і середовище розробки Visual Studio.

Лістинг коду

```
import numpy as np
import pandas
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as stats

pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
file_path = r'D:\OperaDownloads\rgr\rgr2.xlsx'

df_import = pd.read_excel(file_path, engine="openpyxl", usecols=["Дані"])
l = [x for x in df_import['Дані'].tolist() if type(x) == int]

df = pd.DataFrame({'Варіаційний ряд': sorted(l)})
print(df)

df_info = pd.DataFrame({
    "Об'єм вибірки": [len(l)],
    "Мінімальний елемент": [min(l)],
    "Максимальний елемент": [max(l)],
    "Розмах вибірки": [max(l) - min(l)]
})
print("\n")
df_info_string = df_info.to_string(index=False)
print(df_info_string)
print("\n")


df_stat_dist = pd.DataFrame({'Значення': df['Варіаційний ряд'].unique(),
                             'Частоти': df['Варіаційний
ряд'].value_counts(sort=False),
                             'Кумулятивні частоти': df['Варіаційний
ряд'].value_counts(sort=False).cumsum(),
                             'Відносні частоти': df['Варіаційний
ряд'].value_counts(normalize=True, sort=False),
                             'Кумулятивні відносні частоти': df['Варіаційний
ряд'].value_counts(normalize=True, sort=False).cumsum()})


df_stat_dist_str = df_stat_dist.to_string(index=False, justify='left')

print(df_stat_dist_str)
print("\n")

fig, ax = plt.subplots(figsize=(12, 4))
ax.spines['right'].set_visible(False)
ax.spines['top'].set_visible(False)
ax.spines['left'].set_position('zero')
ax.spines['bottom'].set_position('zero')
ax.xaxis.set_tick_params(labelsize=15)
ax.yaxis.set_tick_params(labelsize=15)
ax.set_yticks([0.1, 0.2, 0.3, 0.4, 0.5])

ax.plot(df_stat_dist['Значення'], df_stat_dist['Відносні частоти'],
        'o-', linewidth=2, markersize=8, color='m', label='Полігон відносних
частот')

ax.legend(fontsize=15, loc=9)
plt.show()

def plot_empirical_cdf(x_sample, y_sample):
    plt.plot([x_sample[0] - 0.5, x_sample[0]], [0, 0], linewidth=2, color='g')
```

```
    for i in range(len(x_sample)-1):
        plt.plot([x_sample[i], x_sample[i+1]],[y_sample[i], y_sample[i]],
linewidth=2, color='g')
        plt.scatter(x_sample[i], y_sample[i], marker='<', color='g')
    plt.plot([x_sample[len(x_sample)-1], x_sample[len(x_sample)-1] + 0.5], [1,
1], linewidth=2, color='g')
    plt.scatter(x_sample.max(), 1, marker='<', color='g')
    plt.show()

fig, ax = plt.subplots(figsize=(12, 4))
ax.spines['right'].set_visible(False)
ax.spines['top'].set_visible(False)
ax.spines['left'].set_position('zero')
ax.spines['bottom'].set_position('zero')
ax.xaxis.set_tick_params(labelsize=15)
ax.yaxis.set_tick_params(labelsize=15)
ax.set_xlim(df_stat_dist['Значення'].min() - 0.5, df_stat_dist['Значення'].max()
+ 0.5)
ax.set_yticks([0.2, 0.4, 0.6, 0.8, 1])

ax.set_title('Емпірична функція розподілу', fontsize=20)
plot_empirical_cdf(df_stat_dist['Значення'], df_stat_dist['Кумулятивні відносні
частоти'])

df_info['Вибіркове середнє'] = np.mean(df['Варіаційний ряд'])
df_info['Вибіркова дисперсія'] = np.var(df['Варіаційний ряд'])
df_info['Виправлена вибіркова дисперсія'] = np.var(df['Варіаційний ряд'], ddof=1)
df_info['Вибіркова медіана'] = np.median(df['Варіаційний ряд'])
df_info['Вибіркова мода'] = stats.mode(df['Варіаційний ряд'])[0]
df_info['Вибірковий коефіцієнт асиметрії'] = stats.skew(df['Варіаційний ряд'])
df_info['Вибірковий коефіцієнт ексцесу'] = stats.kurtosis(df['Варіаційний ряд'])

columns_order = ['Вибіркове середнє', 'Вибіркова дисперсія', 'Виправлена
вибіркова дисперсія',
                 'Вибіркова медіана', 'Вибіркова мода', 'Вибірковий коефіцієнт
асиметрії', 'Вибірковий коефіцієнт ексцесу']

print(df_info[columns_order].to_string(index=False))
print("\n")

fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(15, 5), sharey=True)
fig.tight_layout()
for i in range(3):
    ax[i].spines['right'].set_visible(False)
    ax[i].spines['top'].set_visible(False)
    ax[i].spines['left'].set_position('zero')
    ax[i].spines['bottom'].set_position('zero')

x = df_stat_dist['Значення']
y0 = stats.binom.pmf(x, 6, 0.238333333)
y1 = stats.geom.pmf(x, 0.411523, loc=-1)
y2 = stats.poisson.pmf(x, 1.43)

ax[0].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
ax[0].plot(x, y0, 'o-', linewidth=2, markersize=8, color='y', label='B(N, p)')
ax[0].legend(fontsize=15)
ax[1].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
ax[1].plot(x, y1, 'o-', linewidth=2, markersize=8, color='y', label=r'Geom$^{(0)}
$(p)')
ax[1].legend(fontsize=15)
ax[2].plot(x, df_stat_dist['Відносні частоти'], 'o-', linewidth=2, markersize=8,
color='b')
```

```
ax[2].plot(x, y2, 'o-', linewidth=2, markersize=8, color='y', label=r'Poiss($\
lambda$)')
ax[2].legend(fontsize=15)
plt.show()
```